HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

Đồng Quốc Huy

ỨNG DỤNG MÔ HÌNH HỌC MÁY TRONG HỖ TRỢ KIỂM DUYỆT TÍN DỤNG

ĐỀ ÁN TỐT NGHIỆP THẠC SĨ KỸ THUẬT

(Theo định hướng ứng dụng)

HÀ NỘI – 2026

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

Đồng Quốc Huy

ỨNG DỤNG MÔ HÌNH HỌC MÁY TRONG HỖ TRỢ KIỂM DUYỆT TÍN DỤNG

CHUYÊN NGÀNH : Hệ thống thông tin
MÃ SỐ : 8.48.01.04

ĐỀ ÁN TỐT NGHIỆP THẠC SĨ KỸ THUẬT

(Theo định hướng ứng dụng)

NGƯỜI HƯỚNG DẪN KHOA HỌC: TS. Đỗ Tiến Dũng

HÀ NỘI – 2026

LỜI CAM ĐOAN

Tôi xin cam đoan đề án tốt nghiệp với đề tài *"ỨNG DỤNG MÔ HÌNH HỌC MÁY TRONG HỖ TRỢ KIỂM DUYỆT TÍN DỤNG"* là công trình nghiên cứu của riêng tôi, được thực hiện dưới sự hướng dẫn khoa học của TS. Đỗ Tiến Dũng.

Các nội dung nghiên cứu, kết quả thực nghiệm trình bày trong đề án là trung thực và chưa từng được công bố trong bất kỳ công trình nào khác. Toàn bộ mã nguồn của mô hình nguyên mẫu, quy trình sinh dữ liệu, kịch bản thực nghiệm và các bảng biểu, đồ thị trong đề án đều do tôi tự xây dựng và thực hiện.

Tôi xin nêu rõ về dữ liệu sử dụng trong đề án: do đặc thù bảo mật của dữ liệu tín dụng cá nhân và các quy định về bảo vệ dữ liệu khách hàng, đề án **không sử dụng dữ liệu thật của bất kỳ tổ chức tín dụng nào**. Toàn bộ dữ liệu phục vụ thực nghiệm được sinh mô phỏng bằng chương trình do tôi xây dựng, theo một mô hình xác suất được thiết kế và hiệu chỉnh để tái tạo các đặc điểm thống kê của dữ liệu tín dụng bán lẻ. Cơ sở và giới hạn của cách tiếp cận này được trình bày minh bạch tại mục 3.1.3 và mục 3.5.3.

Các thông tin trích dẫn trong đề án đều được chỉ rõ nguồn gốc và liệt kê đầy đủ trong danh mục tài liệu tham khảo. Tôi xin chịu hoàn toàn trách nhiệm về nội dung đề án của mình.

HÀ NỘI, tháng 12 năm 2026

Học viên thực hiện

Đồng Quốc Huy

LỜI CẢM ƠN

Trước hết, tôi xin bày tỏ lòng biết ơn sâu sắc tới TS. Đỗ Tiến Dũng – người đã trực tiếp hướng dẫn khoa học cho đề án này. Thầy đã định hướng cho tôi cách tiếp cận vấn đề một cách hệ thống, từ việc xác định phạm vi nghiên cứu, lựa chọn phương pháp, cho tới cách tổ chức thực nghiệm và trình bày kết quả một cách chặt chẽ, trung thực.

Tôi xin trân trọng cảm ơn các thầy, cô giáo Khoa Công nghệ thông tin và Khoa Đào tạo Sau đại học – HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG đã tận tình giảng dạy và tạo điều kiện thuận lợi cho tôi trong suốt quá trình học tập chương trình cao học, cũng như trong thời gian thực hiện đề án tốt nghiệp.

Tôi cũng xin gửi lời cảm ơn tới các đồng nghiệp trong lĩnh vực công nghệ ngân hàng đã chia sẻ những kinh nghiệm thực tiễn quý báu về quy trình phê duyệt tín dụng và vận hành mô hình, giúp đề án bám sát yêu cầu nghiệp vụ thực tế.

Cuối cùng, tôi xin cảm ơn gia đình và bạn bè đã luôn động viên, hỗ trợ tôi trong suốt quá trình học tập và nghiên cứu.

Do thời gian và năng lực còn hạn chế, đề án chắc chắn không tránh khỏi những thiếu sót. Tôi rất mong nhận được các ý kiến đóng góp của quý thầy, cô và các bạn đọc để đề án được hoàn thiện hơn.

HÀ NỘI, tháng 12 năm 2026

Học viên thực hiện

Đồng Quốc Huy

MỤC LỤC

LỜI CAM ĐOAN i

LỜI CẢM ƠN ii

MỤC LỤC iii

DANH MỤC THUẬT NGỮ VÀ CHỮ VIẾT TẮT viii

DANH MỤC BẢNG xi

DANH MỤC HÌNH VẼ xiii

MỞ ĐẦU 1

1. Lý do chọn đề tài 1
2. Tổng quan về vấn đề nghiên cứu 2
3. Mục tiêu nghiên cứu 3
4. Đối tượng và phạm vi nghiên cứu 5
5. Phương pháp nghiên cứu 6
6. Kết cấu của đề án 7

1 CƠ SỞ LÝ LUẬN 9

1.1 Tổng quan về tín dụng và kiểm duyệt tín dụng 9

1.1.1 Khái niệm tín dụng 9

1.1.2 Quy trình cấp và kiểm duyệt tín dụng 10

1.1.3 Các yếu tố ảnh hưởng đến quyết định tín dụng 11

1.1.4 Rủi ro tín dụng và đánh giá rủi ro tín dụng 12

1.1.5 Những hạn chế của phương pháp kiểm duyệt tín dụng truyền thống 13

1.2 Tổng quan về học máy trong đánh giá tín dụng 14

1.2.1 Khái niệm học máy 14

1.2.2 Phân loại các phương pháp học máy 15
1.2.3 Học máy có giám sát trong bài toán tín dụng 16
1.2.4 Quy trình xây dựng mô hình học máy 17
1.2.5 Vai trò của học máy trong hỗ trợ kiểm duyệt tín dụng 18
1.3 Dữ liệu và đặc trưng trong bài toán tín dụng 18
1.3.1 Đặc điểm dữ liệu tín dụng 18
1.3.2 Các nhóm dữ liệu sử dụng trong đánh giá tín dụng 19
1.3.3 Xây dựng và lựa chọn đặc trưng 20
1.4 Các mô hình học máy áp dụng trong đánh giá tín dụng 22
1.4.1 Hồi quy Logistic 22
1.4.2 Decision Tree 23
1.4.3 Random Forest 24
1.4.4 Support Vector Machine 25
1.4.5 Gradient Boosting 26
1.4.6 So sánh và lựa chọn mô hình phù hợp 27
Kết luận chương 1 30

2 XÂY DỰNG MÔ HÌNH HỌC MÁY TRONG HỖ TRỢ KIỂM DUYỆT TÍN DỤNG 32

2.1 Phân tích bài toán kiểm duyệt tín dụng 32
2.1.1 Xác định các mức độ rủi ro và trạng thái khoản vay cần dự báo 32
2.1.2 Đặc trưng đầu vào và đầu ra của mô hình kiểm duyệt tín dụng 33
2.1.3 Yêu cầu kỹ thuật và pháp lý đối với mô hình kiểm duyệt tín dụng 34
2.2 Thu thập và tổng hợp dữ liệu 35
2.2.1 Nguồn dữ liệu tín dụng truyền thống và dữ liệu bổ sung . . . 35
2.2.2 Thu thập và trích xuất dữ liệu khách hàng vay vốn 36
2.2.3 Phân tích thống kê mô tả tập dữ liệu tín dụng 37
2.2.4 Phát hiện và xử lý dữ liệu ngoại lệ, dữ liệu không hợp lệ . . . 37
2.2.5 Phân chia dữ liệu theo khoảng thời gian và nhóm khách hàng . 39
2.3 Tiền xử lý và làm sạch dữ liệu 40

2.3.1 Xử lý giá trị khuyết thiếu 40
2.3.2 Phát hiện và xử lý dữ liệu ngoại lệ 40
2.3.3 Chuẩn hóa và mã hóa biến định tính/định lượng 41
2.3.4 Phân chia tập dữ liệu huấn luyện, kiểm thử 42
2.4 Trích xuất và lựa chọn đặc trưng 42
2.4.1 Trích xuất nhóm đặc trưng thông tin cá nhân và tài chính . . . 42
2.4.2 Trích xuất nhóm đặc trưng lịch sử tín dụng và quan hệ CIC . . 42
2.4.3 Trích xuất nhóm đặc trưng hành vi và biến tương tác 43
2.4.4 Đánh giá mức độ quan trọng của các đặc trưng 44
2.4.5 Lựa chọn tập đặc trưng tối ưu cho mô hình 45
2.5 Xây dựng nhãn và xác định quy tắc phê duyệt 46
2.5.1 Định nghĩa trạng thái rủi ro và tiêu chuẩn nợ xấu 46
2.5.2 Phương pháp gán nhãn dữ liệu hồ sơ vay 47
2.5.3 Xác định điểm cắt phê duyệt 47
2.6 Thiết kế mô hình học máy kiểm duyệt tín dụng 48
2.6.1 Lựa chọn các thuật toán học máy dự kiến 48
2.6.2 Thiết kế kiến trúc tổng thể của mô hình học máy hỗ trợ ra quyết định 49
2.6.3 Xác định các hàm mất mát 51
2.6.4 Lựa chọn chỉ số đánh giá hiệu năng 52
2.6.5 Tích hợp cơ chế giải thích mô hình 53
2.7 Quy trình huấn luyện và tối ưu mô hình 53
2.7.1 Thiết lập môi trường và công cụ huấn luyện 53
2.7.2 Quy trình thử nghiệm và kiểm tra chéo 54
2.7.3 Phương pháp tối ưu hóa siêu tham số 54
2.7.4 Mức độ kiểm soát hiện tượng quá khớp 55
2.7.5 Phương pháp đánh giá độ ổn định mô hình theo thời gian . . . 55
Kết luận chương 2 56

3 TRIỂN KHAI THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ 57
3.1 Thiết lập kịch bản và môi trường thực nghiệm 57

3.1.1 Hạ tầng phần cứng, phần mềm và thư viện sử dụng 57
3.1.2 Kịch bản thực nghiệm các mô hình học máy 58
3.1.3 Thiết kế và kiểm chứng tập dữ liệu thực nghiệm 58
3.1.4 Phương pháp phân chia tập dữ liệu thử nghiệm 63
3.2 Kết quả huấn luyện và tính toán mô hình 64
3.2.1 Kết quả xây dựng và lựa chọn đặc trưng 64
3.2.2 Kết quả trên các mô hình cơ sở 67
3.2.3 Kết quả trên các mô hình học máy nâng cao 67
3.2.4 Tối ưu hóa siêu tham số cho mô hình 68
3.3 Đánh giá hiệu năng và so sánh kết quả thực nghiệm 69
3.3.1 Đánh giá qua các chỉ số phân loại 69
3.3.2 Đánh giá khả năng phân tách rủi ro 71
3.3.3 So sánh hiệu năng giữa các thuật toán 74
3.4 Mô phỏng và giải thích mô hình 79
3.4.1 Thử nghiệm giải thích quyết định mô hình 79
3.4.2 Mô phỏng xác định ngưỡng phê duyệt tín dụng 83
3.4.3 Thử nghiệm tích hợp API và luồng xử lý hồ sơ 87
3.5 Đánh giá chung 88
3.5.1 So sánh với quy trình thẩm định truyền thống 88
3.5.2 Đối chiếu kết quả với các công trình nghiên cứu liên quan . . 90
3.5.3 Nhận diện hạn chế và định hướng phát triển 91
Kết luận chương 3 92

KẾT LUẬN **94**
1. Kết quả nghiên cứu 94
2. Hạn chế của nghiên cứu 96
3. Hướng phát triển 97

DANH MỤC TÀI LIỆU THAM KHẢO **98**

A CẤU TRÚC MÃ NGUỒN VÀ HƯỚNG DẪN TÁI LẬP KẾT QUẢ **102**

A.1 Tổ chức mã nguồn 102
A.2 Hướng dẫn tái lập kết quả 103
A.2.1 Cài đặt môi trường 103
A.2.2 Chạy toàn bộ quy trình 103
A.2.3 Chạy nhanh để kiểm tra 104
A.2.4 Khởi động dịch vụ và giao diện 105
A.2.5 Biên dịch đề án 105

B DANH MỤC LUẬT NGHIỆP VỤ 106

C DANH MỤC ĐẶC TRƯNG 109

DANH MỤC THUẬT NGỮ VÀ CHỮ VIẾT TẮT

Viết tắt	Thuật ngữ tiếng Anh	Giải nghĩa tiếng Việt
API	Application Programming Interface	Giao diện lập trình ứng dụng
AUC	Area Under the ROC Curve	Diện tích dưới đường cong ROC
CART	Classification and Regression Tree	Cây phân loại và hồi quy
CIC	Credit Information Center	Trung tâm Thông tin tín dụng Quốc gia Việt Nam
DPD	Days Past Due	Số ngày quá hạn
DTI	Debt-to-Income ratio	Tỷ lệ nghĩa vụ trả nợ trên thu nhập
EAD	Exposure at Default	Dư nợ tại thời điểm vỡ nợ
ECE	Expected Calibration Error	Sai số hiệu chuẩn kỳ vọng
EL	Expected Loss	Tổn thất kỳ vọng
FN	False Negative	Âm tính giả (bỏ sót hồ sơ xấu)
FP	False Positive	Dương tính giả (từ chối nhầm hồ sơ tốt)
GBM	Gradient Boosting Machine	Máy tăng cường độ dốc
IV	Information Value	Giá trị thông tin của biến
JSON	JavaScript Object Notation	Định dạng trao đổi dữ liệu JSON
KS	Kolmogorov–Smirnov statistic	Thống kê Kolmogorov–Smirnov
LGD	Loss Given Default	Tỷ lệ tổn thất khi vỡ nợ
LR	Logistic Regression	Hồi quy logistic
LTV	Loan-to-Value ratio	Tỷ lệ vay trên giá trị tài sản bảo đảm
MLP	Multi-Layer Perceptron	Mạng nơ-ron truyền thẳng nhiều lớp
NHNN	—	Ngân hàng Nhà nước Việt Nam

(xem tiếp trang sau)

(tiếp theo trang trước)

Viết tắt	Thuật ngữ tiếng Anh	Giải nghĩa tiếng Việt
NPL	Non-Performing Loan	Nợ xấu (nợ nhóm 3–5)
PAVA	Pool Adjacent Violators Algorithm	Thuật toán gộp vi phạm liền kề
PD	Probability of Default	Xác suất vỡ nợ
PR-AUC	Area Under Precision–Recall Curve	Diện tích dưới đường Precision–Recall
PSI	Population Stability Index	Chỉ số ổn định phân phối
PTI	Payment-to-Income ratio	Tỷ lệ khoản trả góp trên thu nhập
RBF	Radial Basis Function	Hàm cơ sở bán kính (hạt nhân Gauss)
REST	Representational State Transfer	Kiến trúc dịch vụ web REST
RF	Random Forest	Rừng ngẫu nhiên
ROC	Receiver Operating Characteristic	Đường đặc trưng hoạt động của bộ thu nhận
SHAP	SHapley Additive exPlanations	Phương pháp giải thích mô hình dựa trên giá trị Shapley
SQL	Structured Query Language	Ngôn ngữ truy vấn có cấu trúc
SVM	Support Vector Machine	Máy vectơ hỗ trợ
TCTD	—	Tổ chức tín dụng
WOE	Weight of Evidence	Trọng số bằng chứng
XGBoost	eXtreme Gradient Boosting	Thư viện tăng cường độ dốc cực hạn

Một số thuật ngữ được sử dụng thống nhất trong đề án:

Thuật ngữ	Cách hiểu trong đề án
Kiểm duyệt tín dụng	Quá trình đánh giá, sàng lọc hồ sơ vay để hình thành đề xuất có căn cứ. Phân biệt với *phê duyệt* – hành vi ra quyết định của cấp có thẩm quyền.

Thuật ngữ	**Cách hiểu trong đề án**
Mô hình hỗ trợ kiểm duyệt	Mô hình cung cấp đánh giá rủi ro định lượng kèm lý giải làm đầu vào cho quyết định của con người, không thay thế thẩm quyền phê duyệt.
Tính đúng đắn theo thời điểm (*point-in-time correctness*)	Nguyên tắc bảo đảm mọi đặc trưng của một hồ sơ chỉ được tính từ dữ liệu đã tồn tại trước hoặc tại thời điểm nộp hồ sơ.
Rò rỉ nhãn (*label leakage*)	Hiện tượng đặc trưng chứa thông tin phát sinh sau thời điểm nộp hồ sơ, khiến mô hình cho kết quả cao giả tạo khi đánh giá và sụp đổ khi triển khai.
Cửa sổ quan sát (*performance window*)	Khoảng thời gian kể từ khi cấp tín dụng dùng để xác định hồ sơ có phát sinh nợ xấu hay không. Đề án sử dụng cửa sổ 12 tháng.
Kiểm định ngoài thời gian (*out-of-time validation*)	Cách đánh giá mô hình trên dữ liệu thuộc giai đoạn sau giai đoạn huấn luyện, phản ánh đúng điều kiện vận hành thực tế.
Trần Bayes	Giới hạn lý thuyết về chất lượng dự báo mà không mô hình nào vượt qua được, tính từ xác suất vỡ nợ thật của quá trình sinh dữ liệu.
Hiệu chuẩn xác suất (*calibration*)	Quá trình điều chỉnh để giá trị xác suất mô hình đưa ra trùng khớp với tần suất xảy ra thực tế – điều kiện cần để dùng PD trong phân vùng quyết định.
Khách hàng thin-file	Khách hàng có rất ít hoặc không có lịch sử tín dụng tại CIC, khiến việc đánh giá phải dựa chủ yếu vào dữ liệu hành vi giao dịch.
Cắt ngọn (*winsorize*)	Kỹ thuật giới hạn giá trị cực trị về mức phân vị biên thay vì loại bỏ quan sát, nhằm giữ nguyên cỡ mẫu.
Trôi dạt dữ liệu (*data drift*)	Hiện tượng phân phối dữ liệu hoặc quan hệ giữa đặc trưng và nhãn thay đổi theo thời gian, làm mô hình suy giảm chất lượng.

DANH MỤC BẢNG

1.1 Các nhóm nguồn dữ liệu sử dụng trong đánh giá tín dụng cá nhân . . 20
1.2 So sánh định tính các nhóm mô hình theo tiêu chí của bài toán tín dụng 28

2.1 Thang phân hạng rủi ro theo xác suất vỡ nợ 33
2.2 Lược đồ các bảng dữ liệu sử dụng trong đề án 36
2.3 Bộ ràng buộc kiểm tra tính hợp lệ của dữ liệu 38
2.4 Bốn phương án biến đổi dữ liệu theo yêu cầu của từng họ mô hình . . 41
2.5 Các biến tổ hợp và biến tương tác 45
2.6 Danh mục mô hình được thiết kế và so sánh 49
2.7 Cơ cấu bộ luật nghiệp vụ theo nhóm và mức hành động 51
2.8 Hệ thống chỉ tiêu đánh giá và vai trò trong quy trình 52

3.1 Cấu hình phần cứng và môi trường phần mềm 57
3.2 Quy mô các bảng dữ liệu sử dụng trong đề án 60
3.3 Kiểm chứng cơ chế phát hiện dữ liệu không hợp lệ bằng phép tiêm lỗi 61
3.4 Các đặc trưng có giá trị khuyết và chiến lược xử lý 62
3.5 Các đặc trưng có tỷ lệ giá trị ngoại lệ cao nhất (quy tắc 3×IQR) 62
3.6 Phân bố trạng thái rủi ro sau khi gán nhãn 63
3.7 Tỷ lệ nợ xấu tích luỹ theo số tháng kể từ khi cấp tín dụng 63
3.8 Phân chia dữ liệu theo thời gian 63
3.9 Cơ cấu tập đặc trưng theo nhóm và nguồn dữ liệu 64
3.10 Mười lăm đặc trưng có năng lực dự báo cao nhất theo Information Value 65
3.11 Information Value tổng hợp theo nhóm nguồn dữ liệu 65
3.12 Kết quả lựa chọn tập đặc trưng qua ba bộ lọc 66
3.13 Cơ cấu tập đặc trưng trước và sau lựa chọn 67
3.14 Kết quả tinh chỉnh siêu tham số bằng tìm kiếm ngẫu nhiên 68
3.15 So sánh chất lượng dự báo của các mô hình trên tập kiểm thử 69
3.16 Phân tích theo thập phân vị điểm rủi ro 72

3.17 Chi phí huấn luyện và thời gian chấm điểm một hồ sơ 75
3.18 Tác động nghiệp vụ của các mô hình tại ngưỡng tối ưu chi phí 77
3.19 Mức độ quá khớp đo bằng chênh lệch AUC giữa hai tập dữ liệu . . . 78
3.20 Mười đặc trưng có mức trôi dạt phân phối lớn nhất 79
3.21 Chất lượng dự báo của mô hình theo từng tháng của giai đoạn kiểm thử 79
3.22 Tỷ trọng đóng góp vào quyết định của mô hình theo nhóm đặc trưng . 80
3.23 So sánh ba tiêu chí xác định điểm cắt phê duyệt 83
3.24 Độ nhạy của kết quả kiểm duyệt theo điểm cắt 84
3.25 Cơ cấu khuyến nghị của mô hình và tỷ lệ nợ xấu thực tế theo từng nhóm 85
3.26 Tần suất vi phạm các luật nghiệp vụ 86
3.27 Kết quả thử nghiệm tích hợp dịch vụ REST 87
3.28 Thời gian xử lý một hồ sơ theo từng chặng 87
3.29 So sánh mô hình đề xuất với quy trình thẩm định truyền thống 88

B.1 Danh mục đầy đủ luật nghiệp vụ được cài đặt trong mô hình 106

C.1 Danh mục đặc trưng đầu vào của mô hình 109

DANH MỤC HÌNH VẼ

1.1 Quy trình xây dựng và vận hành mô hình học máy cho bài toán tín dụng 17

2.1 Quy trình lựa chọn tập đặc trưng qua ba bộ lọc nối tiếp 46
2.2 Kiến trúc phân tầng của mô hình hỗ trợ kiểm duyệt tín dụng 50

3.1 Phân bố các biến chính trong tập dữ liệu thực nghiệm 60
3.2 Xếp hạng đặc trưng theo Information Value 66
3.3 Đường cong ROC của các mô hình trên tập kiểm thử 70
3.4 Đường cong hiệu chuẩn xác suất sau khi hiệu chuẩn đẳng hướng . . . 71
3.5 Đường cong Kolmogorov–Smirnov của mô hình được chọn triển khai 72
3.6 Đường cong gains và lift theo thập phân vị điểm rủi ro 73
3.7 Phân bố xác suất vỡ nợ dự báo theo nhóm hồ sơ thực tế 73
3.8 Đánh đổi giữa chất lượng dự báo và thời gian chấm điểm một hồ sơ . 76
3.9 Diễn biến chất lượng dự báo theo tháng trên giai đoạn kiểm thử 80
3.10 Biểu đồ tóm tắt SHAP của hai mươi đặc trưng quan trọng nhất 81
3.11 Tỷ trọng đóng góp vào quyết định theo nhóm nguồn dữ liệu 82
3.12 Tầm quan trọng đặc trưng theo phép hoán vị 82
3.13 Đánh đổi giữa tỷ lệ duyệt và tỷ lệ nợ xấu theo điểm cắt 84
3.14 Cơ cấu khuyến nghị và tỷ lệ nợ xấu thực tế theo từng nhóm 85
3.15 Tần suất vi phạm các luật nghiệp vụ 86
3.16 So sánh mô hình đề xuất với quy trình thẩm định truyền thống 89

MỞ ĐẦU

1. Lý do chọn đề tài

Trong những năm gần đây, chuyển đổi số trong lĩnh vực ngân hàng đã thúc đẩy mạnh mẽ quá trình số hóa các sản phẩm và dịch vụ tín dụng. Cùng với sự phát triển của ngân hàng số, nhu cầu cấp tín dụng nhanh chóng, thuận tiện và có khả năng xử lý số lượng lớn hồ sơ ngày càng gia tăng. Đối với các tổ chức tín dụng, kiểm duyệt tín dụng là một trong những nghiệp vụ quan trọng, có ảnh hưởng trực tiếp đến chất lượng tài sản, khả năng kiểm soát rủi ro và hiệu quả kinh doanh. Do đó, việc ứng dụng các mô hình học máy hỗ trợ cán bộ tín dụng trong quá trình đánh giá và ra quyết định đang trở thành một yêu cầu thực tiễn.

Trong phương thức kiểm duyệt tín dụng truyền thống, thông tin khách hàng thường được tổng hợp từ nhiều nguồn khác nhau như hồ sơ đăng ký vay, thông tin khách hàng, lịch sử giao dịch, dữ liệu tín dụng và các thông tin liên quan khác. Quá trình tổng hợp, kiểm tra và đánh giá dữ liệu có thể mất nhiều thời gian, đặc biệt khi khối lượng hồ sơ lớn. Bên cạnh đó, việc đánh giá dựa nhiều vào các bộ quy tắc nghiệp vụ cố định có thể hạn chế khả năng phát hiện các mối quan hệ phức tạp giữa các đặc trưng của khách hàng và khả năng phát sinh rủi ro tín dụng.

Hạn chế nêu trên không nằm ở năng lực chuyên môn của cán bộ tín dụng mà nằm ở *bản chất của phương pháp đánh giá*. Một bộ quy tắc, dù được xây dựng công phu đến đâu, cũng chỉ biểu diễn được quan hệ giữa từng chỉ tiêu riêng lẻ với ngưỡng cho phép. Trong khi đó, rủi ro tín dụng thường phát sinh từ *tổ hợp* nhiều yếu tố: một khách hàng có thu nhập cao nhưng dòng tiền không ổn định, thâm niên công việc ngắn và đang có quan hệ tín dụng với nhiều tổ chức cùng lúc có thể rủi ro hơn một khách hàng thu nhập thấp hơn nhưng ổn định về mọi mặt. Bộ quy tắc xét từng điều kiện độc lập khó nắm bắt được kiểu tương tác này.

Sự phát triển của các phương pháp học máy mở ra khả năng khai thác dữ liệu lịch sử để xây dựng các mô hình dự đoán và hỗ trợ đánh giá rủi ro. Thay vì chỉ dựa trên các điều kiện kiểm tra cố định, mô hình học máy có thể học các mối quan hệ giữa đặc điểm khách hàng, hành vi tín dụng và kết quả tín dụng trong quá khứ để đưa ra dự đoán đối với hồ sơ mới. Khi được tích hợp vào quy trình nghiệp vụ, kết quả dự đoán có thể được sử dụng như một nguồn thông tin hỗ trợ cán bộ trong quá trình kiểm duyệt tín dụng.

Tuy nhiên, việc ứng dụng học máy vào kiểm duyệt tín dụng không chỉ là bài toán xây dựng mô hình dự đoán mà còn liên quan đến quá trình thu thập, chuẩn hóa, biến đổi dữ liệu, xây dựng đặc trưng, tích hợp mô hình và cung cấp kết quả dự đoán một cách ổn định. Thực tế cho thấy nhiều mô hình đạt chỉ tiêu tốt trong phòng thí nghiệm nhưng không áp dụng được, vì thiếu các yếu tố mà môi trường vận hành đòi hỏi: xác suất dự báo phải được hiệu chuẩn đúng để dùng làm căn cứ định giá, quyết định phải giải trình được trước cán bộ tín dụng và cơ quan quản lý, và mô hình phải xử lý được cả những hồ sơ thiếu dữ liệu. Vì vậy, cần có một giải pháp mang tính hệ thống, trong đó mô hình học máy được kết hợp với quy trình xử lý dữ liệu và các luật nghiệp vụ nhằm hỗ trợ quá trình kiểm duyệt tín dụng.

Xuất phát từ những yêu cầu trên, đề án lựa chọn đề tài *"ỨNG DỤNG MÔ HÌNH HỌC MÁY TRONG HỖ TRỢ KIỂM DUYỆT TÍN DỤNG"* nhằm nghiên cứu, thiết kế và xây dựng thử nghiệm một mô hình có khả năng tiếp nhận thông tin hồ sơ tín dụng, xử lý dữ liệu, tạo các đặc trưng đầu vào, sử dụng mô hình học máy để đánh giá khả năng rủi ro và cung cấp kết quả hỗ trợ kiểm duyệt. Đề tài có ý nghĩa cả về mặt khoa học và thực tiễn, đồng thời có tính khả thi nhờ sự phát triển của các công nghệ xử lý dữ liệu, học máy và các nền tảng triển khai hiện nay.

2. Tổng quan về vấn đề nghiên cứu

Kiểm duyệt tín dụng là một bài toán đã được nghiên cứu rộng rãi trong lĩnh vực tài chính – ngân hàng. Các phương pháp truyền thống thường sử dụng chấm điểm tín dụng và các bộ luật nghiệp vụ dựa trên những tiêu chí như thu nhập, lịch sử tín dụng, dư nợ, khả năng trả nợ và đặc điểm của khoản vay. Những phương pháp này có ưu điểm là dễ giải thích và phù hợp với các quy định nghiệp vụ, tuy nhiên khả năng biểu diễn các mối quan hệ phức tạp trong dữ liệu còn hạn chế.

Cùng với sự gia tăng về quy mô và đa dạng của dữ liệu, nhiều nghiên cứu đã tập trung áp dụng các thuật toán học máy cho bài toán đánh giá tín dụng. Một số phương pháp phổ biến gồm hồi quy Logistic, Decision Tree, Random Forest, Support Vector Machine, Gradient Boosting và các mô hình học sâu. Các nghiên cứu cho thấy mô hình học máy có khả năng khai thác nhiều đặc trưng đồng thời và cải thiện khả năng phân loại khách hàng có nguy cơ tín dụng cao hoặc thấp so với một số phương pháp truyền thống.

Công trình đối sánh quy mô lớn của Lessmann và cộng sự [8] trên nhiều bộ dữ liệu tín dụng là một mốc tham chiếu quan trọng: các phương pháp học tập hợp cho kết

quả tốt hơn mô hình đơn lẻ, song mức chênh lệch so với hồi quy logistic là *không lớn* – một kết luận thường bị bỏ qua khi lựa chọn mô hình trong thực tiễn. Các tổng quan hệ thống gần đây [9] tiếp tục khẳng định xu hướng này, đồng thời chỉ ra rằng yếu tố quyết định chất lượng mô hình thường nằm ở *chất lượng và độ phong phú của đặc trưng* hơn là ở việc lựa chọn thuật toán.

Bên cạnh vấn đề lựa chọn thuật toán, các nghiên cứu cũng tập trung vào các bước xử lý dữ liệu như làm sạch dữ liệu, xử lý giá trị thiếu, lựa chọn đặc trưng, cân bằng dữ liệu và đánh giá mô hình. Các chỉ số như Accuracy, Precision, Recall, F1-score, ROC-AUC và Gini thường được sử dụng để đánh giá hiệu quả của mô hình phân loại rủi ro tín dụng.

Tuy nhiên, một hạn chế thường gặp là nhiều nghiên cứu tập trung chủ yếu vào hiệu quả dự đoán của mô hình, trong khi chưa giải quyết đầy đủ bài toán tích hợp mô hình vào một quy trình hỗ trợ kiểm duyệt tín dụng hoàn chỉnh. Trong môi trường thực tế, dữ liệu tín dụng có thể đến từ nhiều nguồn, có cấu trúc và chất lượng khác nhau, đồng thời yêu cầu xử lý dữ liệu, kiểm tra điều kiện nghiệp vụ và cung cấp kết quả trong thời gian phù hợp với quy trình kinh doanh.

Do đó, đề án tập trung nghiên cứu theo hướng kết hợp giữa xử lý dữ liệu, xây dựng đặc trưng, mô hình học máy và luật nghiệp vụ để hình thành một mô hình hỗ trợ kiểm duyệt tín dụng. Đề án không hướng tới việc thay thế hoàn toàn quyết định của cán bộ hoặc tổ chức tín dụng mà tập trung xây dựng một công cụ hỗ trợ, cung cấp kết quả đánh giá rủi ro và thông tin tham khảo nhằm nâng cao hiệu quả và tính nhất quán của quá trình kiểm duyệt.

3. Mục tiêu nghiên cứu

3.1. Mục tiêu chung

Đề án nhằm nghiên cứu, thiết kế và xây dựng thử nghiệm mô hình học máy hỗ trợ kiểm duyệt tín dụng, trong đó khai thác dữ liệu khách hàng và thông tin tín dụng để xây dựng các đặc trưng đầu vào, huấn luyện mô hình học máy và đưa ra kết quả dự đoán mức độ rủi ro. Mô hình được xây dựng theo định hướng hỗ trợ quá trình kiểm duyệt tín dụng, giúp cung cấp thêm cơ sở định lượng cho việc đánh giá hồ sơ thay vì chỉ dựa trên các tiêu chí và quy tắc nghiệp vụ cố định.

3.2. Mục tiêu về mặt lý luận

Về mặt lý luận, đề án tập trung hệ thống hóa và làm rõ cơ sở lý thuyết về kiểm duyệt tín dụng, đánh giá rủi ro tín dụng và khả năng ứng dụng các phương pháp học máy trong bài toán hỗ trợ ra quyết định tín dụng. Đề án nghiên cứu quy trình từ thu thập và tiền xử lý dữ liệu, xây dựng đặc trưng, lựa chọn mô hình, huấn luyện, đánh giá đến tích hợp mô hình. Trên cơ sở đó, đề án phân tích và đánh giá mức độ phù hợp của các mô hình học máy đối với bài toán phân loại rủi ro tín dụng thông qua các tiêu chí như Accuracy, Precision, Recall, F1-score và ROC-AUC. Kết quả nghiên cứu góp phần làm rõ mối quan hệ giữa chất lượng dữ liệu, đặc trưng đầu vào, lựa chọn mô hình và hiệu quả dự đoán trong bài toán tín dụng, đồng thời bổ sung cơ sở tham khảo cho việc nghiên cứu ứng dụng học máy vào việc hỗ trợ ra quyết định trong lĩnh vực tài chính – ngân hàng.

3.3. Mục tiêu về mặt thực tiễn

Về mặt thực tiễn, đề án hướng tới xây dựng một mô hình học máy thử nghiệm có khả năng tiếp nhận thông tin hồ sơ tín dụng, thực hiện xử lý dữ liệu, tạo đặc trưng để đánh giá rủi ro và trả về kết quả hỗ trợ kiểm duyệt. Việc ứng dụng mô hình học máy giúp khai thác hiệu quả hơn dữ liệu lịch sử, hỗ trợ nhận diện các hồ sơ có mức độ rủi ro khác nhau và cung cấp kết quả đánh giá một cách nhất quán. Qua đó, có thể góp phần rút ngắn thời gian đánh giá hồ sơ, giảm khối lượng công việc thủ công, nâng cao khả năng phát hiện rủi ro và hỗ trợ cán bộ tín dụng trong quá trình ra quyết định. Kết quả của đề án cũng tạo cơ sở thực nghiệm để đánh giá khả năng áp dụng mô hình học máy vào quy trình kiểm duyệt tín dụng và làm tiền đề cho việc phát triển có quy mô lớn hơn trong môi trường thực tế.

3.4. Các mục tiêu cụ thể

Từ hai định hướng trên, đề án đặt ra các mục tiêu cụ thể sau:

(1) Hệ thống hóa cơ sở lý luận về tín dụng, kiểm duyệt tín dụng, rủi ro tín dụng và các phương pháp học máy áp dụng cho bài toán đánh giá tín dụng.

(2) Phân tích bài toán kiểm duyệt tín dụng: xác định các mức độ rủi ro cần dự báo, đặc trưng đầu vào, kết quả đầu ra và các yêu cầu kỹ thuật, pháp lý đối với mô hình.

(3) Xây dựng quy trình thu thập, tổng hợp, kiểm tra chất lượng và tiền xử lý dữ liệu hồ sơ tín dụng.

(4) Trích xuất và lựa chọn tập đặc trưng cho mô hình từ bốn nhóm nguồn dữ liệu: thông tin cá nhân và tài chính, tham số khoản vay, lịch sử tín dụng và quan hệ CIC, hành vi giao dịch tài khoản.

(5) Xây dựng nhãn rủi ro theo tiêu chuẩn nợ xấu và cửa sổ quan sát phù hợp; xác định điểm cắt phê duyệt theo các tiêu chí nghiệp vụ khác nhau.

(6) Thiết kế, huấn luyện, hiệu chuẩn và đánh giá so sánh các mô hình học máy theo bộ chỉ tiêu đầy đủ, bao gồm cả chỉ tiêu đặc thù của ngành tín dụng (KS, Gini, IV, PSI) và thời gian chấm điểm.

(7) Thiết kế và hiện thực bộ máy hỗ trợ ra quyết định kết hợp luật nghiệp vụ với mô hình học máy, có cơ chế giải thích kết quả cho từng hồ sơ.

(8) Mô phỏng luồng xử lý hồ sơ, thử nghiệm tích hợp qua dịch vụ REST và đối chiếu kết quả với quy trình thẩm định truyền thống chỉ dựa trên luật nghiệp vụ.

4. Đối tượng và phạm vi nghiên cứu

4.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề án là mô hình học máy hỗ trợ kiểm duyệt tín dụng, tập trung vào dữ liệu và quy trình đánh giá hồ sơ tín dụng. Cụ thể, đề án nghiên cứu các dữ liệu liên quan đến khách hàng và khoản vay như thông tin cá nhân, thông tin khoản vay, thu nhập, lịch sử tín dụng, tình trạng dư nợ và các đặc trưng có liên quan đến khả năng phát sinh rủi ro tín dụng. Trên cơ sở các dữ liệu này, đề án nghiên cứu phương pháp xử lý dữ liệu, xây dựng đặc trưng, huấn luyện mô hình học máy và sử dụng kết quả dự đoán để hỗ trợ quá trình kiểm duyệt tín dụng. Đối tượng nghiên cứu bao gồm mô hình học máy và kết quả đánh giá rủi ro thành một quy trình hỗ trợ kiểm duyệt thống nhất.

4.2. Phạm vi nghiên cứu

Về nội dung: Đề án giới hạn ở việc xây dựng và thử nghiệm mô hình hỗ trợ đánh giá rủi ro tín dụng, bao gồm các bước chính: tiếp nhận dữ liệu hồ sơ, tiền xử lý dữ liệu, xây dựng đặc trưng, áp dụng mô hình học máy, đánh giá kết quả dự đoán và cung cấp kết quả hỗ trợ kiểm duyệt. Đề án không đi sâu nghiên cứu toàn bộ quy trình nghiệp vụ tín dụng của ngân hàng, không xây dựng hệ thống quản lý tín dụng hoàn chỉnh và

không thay thế các quy định, chính sách hoặc quyết định phê duyệt chính thức của tổ chức tín dụng. Các nội dung sau *không* thuộc phạm vi: định giá và thẩm định tài sản bảo đảm, quy trình giải ngân và thu hồi nợ, mô hình ước lượng tổn thất khi vỡ nợ (LGD) và dư nợ tại thời điểm vỡ nợ (EAD).

Về không gian: Nghiên cứu được thực hiện trong phạm vi bài toán kiểm duyệt tín dụng tại tổ chức tín dụng/ngân hàng, tập trung vào việc xây dựng mô hình và thử nghiệm trong môi trường nghiên cứu. Đề án không giới hạn vào một địa bàn cụ thể và không thực hiện triển khai chính thức trên toàn bộ hệ thống nghiệp vụ của một ngân hàng.

Về dữ liệu: Do đặc thù bảo mật của dữ liệu tín dụng cá nhân, đề án sử dụng **dữ liệu mô phỏng** được sinh bằng chương trình tự xây dựng theo một mô hình xác suất có cấu trúc. Thiết kế, cơ sở hiệu chỉnh và giới hạn của cách tiếp cận này được trình bày minh bạch tại mục 3.1.3. Trong trường hợp áp dụng trên dữ liệu thực tế, dữ liệu cần được ẩn danh và giới hạn quyền truy cập nhằm bảo đảm yêu cầu về bảo mật thông tin.

Về thời gian: Đề án được thực hiện trong thời gian triển khai đề án tốt nghiệp. Bộ dữ liệu sử dụng để huấn luyện và đánh giá mô hình được giới hạn trong khoảng thời gian phù hợp với dữ liệu nghiên cứu và được phân chia thành các giai đoạn phục vụ huấn luyện, kiểm thử và đánh giá mô hình. Các kết quả nghiên cứu phản ánh phạm vi dữ liệu và điều kiện thực nghiệm trong thời gian thực hiện đề án, chưa nhằm đánh giá khả năng vận hành của mô hình trong thời gian dài hoặc trên quy mô dữ liệu sản xuất thực tế.

Về kết quả: Đề án tập trung đánh giá hai khía cạnh chính là hiệu quả của mô hình học máy trong dự đoán rủi ro tín dụng và khả năng hỗ trợ quá trình kiểm duyệt. Kết quả đầu ra của mô hình là thông tin đánh giá hoặc phân loại mức độ rủi ro nhằm hỗ trợ cán bộ tín dụng và quy trình nghiệp vụ; quyết định tín dụng cuối cùng vẫn thuộc về người hoặc bộ phận có thẩm quyền theo quy định của tổ chức tín dụng.

5. Phương pháp nghiên cứu

Đề án sử dụng kết hợp phương pháp nghiên cứu lý thuyết và phương pháp nghiên cứu thực nghiệm nhằm nghiên cứu, xây dựng và đánh giá mô hình học máy trong hỗ trợ kiểm duyệt tín dụng.

Phương pháp nghiên cứu lý thuyết. Đề án tiến hành thu thập, tổng hợp và phân tích các tài liệu, giáo trình, công trình nghiên cứu và các tài liệu chuyên ngành liên

quan đến tín dụng, kiểm duyệt tín dụng, đánh giá rủi ro tín dụng, chấm điểm tín dụng và ứng dụng học máy trong lĩnh vực tài chính – ngân hàng. Trên cơ sở nghiên cứu lý thuyết, đề án làm rõ các khái niệm, đặc điểm của bài toán đánh giá tín dụng, các yếu tố ảnh hưởng đến rủi ro tín dụng và nguyên lý hoạt động của các mô hình học máy phù hợp. Đồng thời, nghiên cứu các phương pháp tiền xử lý dữ liệu, lựa chọn và xây dựng đặc trưng, huấn luyện và đánh giá mô hình. Kết quả nghiên cứu lý thuyết được sử dụng làm cơ sở để lựa chọn mô hình học máy, thiết kế quy trình xử lý dữ liệu và xây dựng mô hình học máy hỗ trợ kiểm duyệt tín dụng.

Phương pháp nghiên cứu thực nghiệm. Đề án tiến hành xây dựng môi trường thực nghiệm để kiểm chứng các nội dung nghiên cứu lý thuyết trên bộ dữ liệu tín dụng phục vụ nghiên cứu. Dữ liệu được phân tích và xử lý thông qua các bước làm sạch, xử lý dữ liệu thiếu, mã hóa dữ liệu, xây dựng và lựa chọn đặc trưng trước khi đưa vào mô hình. Một số mô hình học máy phù hợp với bài toán phân loại rủi ro tín dụng được xây dựng, huấn luyện và kiểm thử trên dữ liệu thực nghiệm. Cụ thể, phương pháp thực nghiệm được triển khai qua bốn nhóm công việc:

- **Phân tích dữ liệu:** thống kê mô tả tập dữ liệu, kiểm tra tính hợp lệ theo ràng buộc nghiệp vụ, phân tích giá trị khuyết thiếu và giá trị ngoại lệ; đánh giá năng lực dự báo của từng đặc trưng thông qua chỉ số Information Value.
- **Thực nghiệm học máy:** huấn luyện, hiệu chuẩn và so sánh các mô hình theo phương pháp kiểm định ngoài thời gian (*out-of-time validation*); tinh chỉnh siêu tham số bằng kiểm định chéo theo chuỗi thời gian; giải thích mô hình bằng phương pháp SHAP và phép hoán vị.
- **Mô phỏng quy trình kiểm duyệt:** xây dựng bộ máy hỗ trợ ra quyết định, mô phỏng luồng xử lý hồ sơ, xác định ngưỡng phê duyệt theo ba tiêu chí nghiệp vụ và thử nghiệm tích hợp qua dịch vụ REST.
- **Đánh giá đối chiếu:** so sánh kết quả của mô hình đề xuất với quy trình thẩm định truyền thống chỉ dựa trên luật nghiệp vụ, và đối chiếu với các công trình nghiên cứu liên quan.

6. Kết cấu của đề án

Ngoài phần Mở đầu, Kết luận, Danh mục tài liệu tham khảo và Phụ lục, nội dung đề án được trình bày trong ba chương:

- **Chương 1 – Cơ sở lý luận:** trình bày tổng quan về tín dụng và kiểm duyệt tín dụng, tổng quan về học máy trong đánh giá tín dụng, dữ liệu và đặc trưng trong bài toán tín dụng, các mô hình học máy áp dụng trong đánh giá tín dụng cùng cơ sở so sánh và lựa chọn mô hình phù hợp.
- **Chương 2 – Xây dựng mô hình học máy trong hỗ trợ kiểm duyệt tín dụng:** phân tích bài toán kiểm duyệt tín dụng; trình bày quy trình thu thập và tổng hợp dữ liệu, tiền xử lý và làm sạch dữ liệu, trích xuất và lựa chọn đặc trưng, xây dựng nhãn và xác định quy tắc phê duyệt; thiết kế mô hình học máy và quy trình huấn luyện, tối ưu mô hình.
- **Chương 3 – Triển khai thực nghiệm và đánh giá kết quả:** trình bày kịch bản và môi trường thực nghiệm, kết quả huấn luyện các mô hình, đánh giá hiệu năng và so sánh giữa các thuật toán, mô phỏng và giải thích mô hình; cuối cùng là phần đánh giá chung, đối chiếu với quy trình thẩm định truyền thống và với các công trình nghiên cứu liên quan.

Chương 1

CƠ SỞ LÝ LUẬN

Chương 1 hệ thống hóa cơ sở lý thuyết của đề án. Nội dung chương lần lượt trình bày tổng quan về tín dụng và hoạt động kiểm duyệt tín dụng; tổng quan về học máy và vai trò của học máy trong đánh giá tín dụng; đặc điểm dữ liệu và phương pháp xây dựng đặc trưng cho bài toán tín dụng; và cuối cùng là các mô hình học máy được nghiên cứu trong đề án cùng cơ sở so sánh, lựa chọn mô hình phù hợp. Đây là nền tảng để Chương 2 xây dựng mô hình và Chương 3 tiến hành thực nghiệm.

1.1 Tổng quan về tín dụng và kiểm duyệt tín dụng

1.1.1 Khái niệm tín dụng

Tín dụng là quan hệ chuyển nhượng quyền sử dụng một lượng giá trị – thường dưới hình thái tiền tệ – từ bên cho vay sang bên đi vay trong một khoảng thời gian xác định, với cam kết hoàn trả cả gốc và lãi khi đến hạn. Ba đặc trưng cơ bản của quan hệ tín dụng gồm: *tính hoàn trả* (khoản vốn phải được trả lại, khác với cấp phát hay tài trợ không hoàn lại), *tính thời hạn* (quyền sử dụng vốn chỉ được chuyển giao trong một thời gian nhất định) và *tính sinh lời* (bên cho vay nhận được khoản lãi như phần bù cho việc từ bỏ quyền sử dụng vốn và cho rủi ro phải gánh chịu).

Đặc trưng thứ ba dẫn tới một hệ quả quan trọng về mặt kinh tế: lãi suất không chỉ phản ánh giá của vốn theo thời gian mà còn phải bao hàm *phần bù rủi ro*. Một tổ chức tín dụng cho vay với cùng một mức lãi suất đối với mọi khách hàng sẽ gặp hiện tượng lựa chọn ngược: khách hàng có rủi ro thấp thấy mức lãi suất đó không hấp dẫn và tìm nguồn vốn khác, còn khách hàng có rủi ro cao sẵn sàng chấp nhận. Kết quả là danh mục tín dụng dần tập trung vào nhóm rủi ro cao trong khi lãi suất không được điều chỉnh tương xứng. Đây chính là lý do nền tảng khiến việc *phân biệt được mức độ rủi ro của từng khách hàng* trở thành năng lực cốt lõi của hoạt động tín dụng, chứ không đơn thuần là một yêu cầu về tuân thủ.

Trong phạm vi đề án, đối tượng nghiên cứu là tín dụng bán lẻ đối với khách hàng cá nhân: các khoản vay tiêu dùng, vay mua ô tô, vay thế chấp bất động sản và thấu

chi. Nhóm sản phẩm này có hai đặc điểm khiến chúng đặc biệt phù hợp với phương pháp mô hình hóa thống kê. Thứ nhất, số lượng hồ sơ lớn nhưng giá trị mỗi khoản vay tương đối nhỏ, nên chi phí thẩm định thủ công cho từng hồ sơ khó có thể tương xứng với quy mô khoản vay. Thứ hai, các khoản vay trong cùng một sản phẩm có mức độ đồng nhất cao, cho phép rút ra quy luật thống kê từ dữ liệu lịch sử – điều khó thực hiện với tín dụng doanh nghiệp lớn, nơi mỗi khoản vay gần như là một trường hợp riêng biệt.

1.1.2 Quy trình cấp và kiểm duyệt tín dụng

Quy trình cấp tín dụng tại các tổ chức tín dụng thường được tổ chức thành năm bước chính:

(1) **Tiếp nhận hồ sơ.** Khách hàng nộp đề nghị vay vốn kèm các tài liệu chứng minh nhân thân, thu nhập, mục đích sử dụng vốn và tài sản bảo đảm (nếu có). Hồ sơ có thể được tiếp nhận tại quầy, qua kênh trực tuyến hoặc qua đối tác phân phối.

(2) **Thu thập và kiểm tra thông tin.** Cán bộ tín dụng đối chiếu thông tin khách hàng khai báo với dữ liệu nội bộ của ngân hàng (lịch sử quan hệ, số dư tài khoản, lịch sử giao dịch) và với dữ liệu bên ngoài, trong đó quan trọng nhất là bản tin tín dụng từ Trung tâm Thông tin tín dụng Quốc gia Việt Nam (CIC) [1].

(3) **Thẩm định và kiểm duyệt.** Đây là bước trọng tâm của quy trình: đánh giá năng lực tài chính, khả năng trả nợ, mức độ rủi ro của khách hàng và sự phù hợp của khoản vay với chính sách tín dụng hiện hành. Kết quả của bước này là đề xuất phê duyệt, từ chối hoặc yêu cầu bổ sung thông tin.

(4) **Phê duyệt.** Cấp có thẩm quyền – tùy theo hạn mức được phân cấp – ra quyết định cuối cùng trên cơ sở hồ sơ và đề xuất thẩm định.

(5) **Giải ngân và giám sát sau vay.** Sau khi hoàn tất thủ tục pháp lý, khoản vay được giải ngân và chuyển sang giai đoạn theo dõi việc trả nợ, phân loại nợ và trích lập dự phòng rủi ro theo quy định [2].

Phạm vi của đề án tập trung vào bước thứ ba – **kiểm duyệt tín dụng**. Cần phân biệt rõ hai khái niệm dễ nhầm lẫn: *kiểm duyệt* là quá trình đánh giá và sàng lọc hồ sơ để hình thành đề xuất có căn cứ, còn *phê duyệt* là hành vi ra quyết định của cấp có thẩm quyền. Hệ thống được xây dựng trong đề án hỗ trợ bước kiểm duyệt: nó cung cấp đánh giá rủi ro định lượng kèm lý giải, làm đầu vào cho quyết định của con người, chứ không thay thế thẩm quyền phê duyệt.

Sự phân biệt này không chỉ mang tính thuật ngữ mà có ý nghĩa thiết kế trực tiếp. Một mô hình *thay thế* con người buộc phải đưa ra quyết định nhị phân cho mọi hồ sơ, kể cả những hồ sơ mà bản thân nó không đủ chắc chắn. Một mô hình *hỗ trợ* có thể – và nên – thừa nhận vùng không chắc chắn của mình và chuyển những hồ sơ đó cho người có thẩm quyền xem xét. Toàn bộ thiết kế ba vùng quyết định được trình bày ở Chương 2 bắt nguồn từ nhận định này.

1.1.3 Các yếu tố ảnh hưởng đến quyết định tín dụng

Thực tiễn thẩm định tín dụng từ lâu đã tổng kết các yếu tố cần xem xét thành khung phân tích **5C** [31]:

- **Character** (Uy tín): thái độ và lịch sử thực hiện nghĩa vụ trả nợ của khách hàng. Trong dữ liệu, yếu tố này được phản ánh qua lịch sử tín dụng tại CIC: nhóm nợ, số ngày quá hạn, tiền sử nợ đã xử lý rủi ro.
- **Capacity** (Năng lực trả nợ): khả năng tạo ra dòng tiền để trả nợ, đo bằng thu nhập, tính ổn định của thu nhập và các chỉ tiêu như tỷ lệ nợ trên thu nhập (DTI) hay tỷ lệ khoản trả góp trên thu nhập.
- **Capital** (Vốn tự có): phần vốn khách hàng tự bỏ ra trong phương án vay, thể hiện mức độ "cùng chịu rủi ro". Với khoản vay có tài sản bảo đảm, yếu tố này gắn với tỷ lệ vay trên giá trị tài sản (LTV).
- **Collateral** (Tài sản bảo đảm): nguồn thu hồi nợ thứ cấp khi nguồn trả nợ chính không thực hiện được.
- **Conditions** (Điều kiện): bối cảnh kinh tế vĩ mô, đặc điểm ngành nghề và mục đích sử dụng vốn.

Khung 5C có giá trị định hướng nhưng bộc lộ một hạn chế khi chuyển thành quy tắc vận hành: nó liệt kê các yếu tố cần xem xét mà không quy định cách *kết hợp* chúng thành một đánh giá tổng thể. Trong thực tế, mức độ quan trọng tương đối của từng yếu tố thay đổi theo phân khúc khách hàng và theo thời gian; hơn nữa các yếu tố tương tác với nhau theo cách phi tuyến. Một khách hàng có DTI ở mức 0,45 có thể chấp nhận được nếu thu nhập ổn định và lịch sử tín dụng tốt, nhưng lại rủi ro cao nếu thâm niên công việc ngắn và đang có quan hệ tín dụng với nhiều tổ chức. Chính khoảng trống này – xác định trọng số và dạng tương tác giữa các yếu tố từ dữ liệu thay vì từ phán đoán chủ quan – là chỗ mà phương pháp học máy đóng góp giá trị.

1.1.4 Rủi ro tín dụng và đánh giá rủi ro tín dụng

Rủi ro tín dụng là khả năng bên đi vay không thực hiện được nghĩa vụ trả nợ theo cam kết, dẫn tới tổn thất cho bên cho vay. Theo khung Basel II [33], tổn thất kỳ vọng của một khoản tín dụng được phân rã thành tích của ba thành phần:

$$\mathrm{EL} = \mathrm{PD} \times \mathrm{LGD} \times \mathrm{EAD}, \tag{1.1}$$

trong đó PD (*Probability of Default*) là xác suất vỡ nợ trong một khoảng thời gian xác định – thường là 12 tháng; LGD (*Loss Given Default*) là tỷ lệ tổn thất khi vỡ nợ xảy ra; và EAD (*Exposure at Default*) là dư nợ tại thời điểm vỡ nợ.

Phân rã này cho thấy vị trí của bài toán mà đề án giải quyết. Trong ba thành phần, PD là đại lượng gắn trực tiếp với *đặc điểm của khách hàng* và được quyết định tại thời điểm cấp tín dụng; LGD và EAD phụ thuộc chủ yếu vào cấu trúc khoản vay, tài sản bảo đảm và quá trình thu hồi nợ sau này. Vì vậy PD là đại lượng mà hoạt động kiểm duyệt tín dụng có thể tác động và cũng là đại lượng mà mô hình học máy có thể ước lượng từ dữ liệu lịch sử. Đề án tập trung vào việc ước lượng PD; việc mô hình hóa LGD và EAD không thuộc phạm vi nghiên cứu.

Định nghĩa vỡ nợ. Để ước lượng PD, trước hết phải định nghĩa được thế nào là "vỡ nợ". Thông tư 11/2021/TT-NHNN [2] quy định việc phân loại nợ thành năm nhóm theo mức độ rủi ro, trong đó nợ thuộc nhóm 3 (Nợ dưới tiêu chuẩn), nhóm 4 (Nợ nghi ngờ) và nhóm 5 (Nợ có khả năng mất vốn) được xếp vào **nợ xấu**. Về mặt số ngày quá hạn, ranh giới của nợ nhóm 3 là 90 ngày. Định nghĩa này trùng với ngưỡng mà Basel sử dụng cho khái niệm *default*, nhờ đó kết quả nghiên cứu có thể đối chiếu với các công trình quốc tế. Đề án sử dụng thống nhất định nghĩa: một hồ sơ được gán nhãn *xấu* nếu phát sinh tình trạng quá hạn từ 90 ngày trở lên (tương đương nợ nhóm 3–5) trong cửa sổ quan sát kể từ thời điểm cấp tín dụng.

Ba thế hệ phương pháp đánh giá. Công tác đánh giá rủi ro tín dụng đã trải qua ba giai đoạn phát triển. Giai đoạn đầu dựa trên *phán đoán chuyên gia*: cán bộ tín dụng vận dụng kinh nghiệm để đưa ra nhận định, linh hoạt với trường hợp đặc thù nhưng thiếu nhất quán và khó mở rộng theo quy mô. Từ thập niên 1960, *thẻ điểm thống kê* (*scorecard*) dựa trên hồi quy logistic ra đời, quy đổi mỗi đặc điểm khách hàng thành một số điểm; phương pháp này bảo đảm tính nhất quán, cho phép kiểm định thống kê và dễ giải thích cho cơ quan quản lý. Từ thập niên 2000, *mô hình học máy* được áp

dụng ngày càng rộng rãi nhờ khả năng nắm bắt quan hệ phi tuyến và tương tác bậc cao mà không cần chỉ định trước dạng hàm, đổi lại khó giải thích hơn và đòi hỏi kiểm định chặt chẽ hơn.

Ba thế hệ này không thay thế nhau hoàn toàn. Trong thực tiễn hiện nay, các tổ chức tín dụng thường vận hành đồng thời cả ba: mô hình học máy cung cấp điểm rủi ro, bộ luật nghiệp vụ bảo đảm tuân thủ chính sách và ngưỡng pháp lý, còn phán đoán chuyên gia xử lý các hồ sơ nằm ngoài vùng mà mô hình đủ tin cậy. Hệ thống được xây dựng trong đề án đi theo mô hình kết hợp này.

1.1.5 Những hạn chế của phương pháp kiểm duyệt tín dụng truyền thống

Phương pháp kiểm duyệt truyền thống – dựa trên bộ quy tắc nghiệp vụ cố định kết hợp với phán đoán của cán bộ tín dụng – bộc lộ bốn hạn chế chính.

Thứ nhất, không biểu diễn được tương tác giữa các yếu tố. Một bộ quy tắc có dạng "nếu DTI > 0,6 thì từ chối" xét từng chỉ tiêu độc lập với các chỉ tiêu còn lại. Cách làm này ngầm giả định rằng ảnh hưởng của mỗi yếu tố tới rủi ro là cộng tính và không phụ thuộc giá trị của các yếu tố khác. Giả định đó thường bị vi phạm trong thực tế: tác động của tỷ lệ DTI cao lên xác suất vỡ nợ mạnh hơn nhiều ở nhóm khách hàng có thu nhập không ổn định so với nhóm có thu nhập ổn định. Về mặt hình thức, bộ quy tắc chỉ tạo ra được các mặt phân chia song song với trục tọa độ trong không gian đặc trưng, trong khi ranh giới rủi ro thực tế có dạng phức tạp hơn nhiều.

Thứ hai, ngưỡng được đặt theo phán đoán chứ không theo dữ liệu. Các ngưỡng như "DTI tối đa 60%" hay "thâm niên công việc tối thiểu 6 tháng" thường được kế thừa từ thông lệ hoặc từ kinh nghiệm của người xây dựng chính sách. Chúng hiếm khi được hiệu chỉnh lại theo dữ liệu thực tế của chính tổ chức, và càng hiếm khi được kiểm định xem mức ngưỡng đó có thực sự tối ưu về mặt đánh đổi giữa quy mô cấp tín dụng và chất lượng danh mục hay không.

Thứ ba, kết quả đầu ra mang tính nhị phân, không có thang đo mức độ. Một bộ quy tắc cho biết hồ sơ "đạt" hay "không đạt" nhưng không cho biết hồ sơ đạt ở mức nào. Điều này khiến tổ chức tín dụng không thể thực hiện hai nghiệp vụ quan trọng: định giá theo rủi ro (khách hàng rủi ro thấp được hưởng lãi suất ưu đãi hơn) và phân bổ nguồn lực thẩm định (tập trung nhân lực vào nhóm hồ sơ thực sự cần xem xét kỹ).

Thứ tư, tính nhất quán và tốc độ xử lý bị giới hạn bởi yếu tố con người. Cùng một hồ sơ có thể nhận được kết luận khác nhau từ hai cán bộ khác nhau, hoặc từ cùng một cán bộ ở hai thời điểm khác nhau. Khi khối lượng hồ sơ tăng, thời gian xử lý kéo dài và áp lực công việc làm gia tăng nguy cơ sai sót.

Bốn hạn chế trên đều có chung một đặc điểm: chúng không phải là vấn đề về năng lực chuyên môn mà là giới hạn cấu trúc của phương pháp. Do đó, hướng khắc phục không phải là tăng cường đào tạo hay bổ sung thêm quy tắc, mà là bổ sung một thành phần có khả năng học quan hệ từ dữ liệu và cho ra kết quả trên thang đo liên tục. Đó chính là vai trò của mô hình học máy mà đề án xây dựng.

1.2 Tổng quan về học máy trong đánh giá tín dụng

1.2.1 Khái niệm học máy

Học máy (*machine learning*) là lĩnh vực nghiên cứu các thuật toán cho phép hệ thống máy tính cải thiện hiệu quả thực hiện một nhiệm vụ thông qua kinh nghiệm, thay vì thông qua việc được lập trình tường minh từng bước. Định nghĩa được trích dẫn rộng rãi của Mitchell [19] phát biểu: một chương trình máy tính được gọi là *học* từ kinh nghiệm E đối với lớp nhiệm vụ T và độ đo hiệu quả P, nếu hiệu quả của nó trên nhiệm vụ T, đo bằng P, cải thiện theo kinh nghiệm E.

Áp dụng vào bài toán của đề án, ba thành phần này được xác định cụ thể như sau:

- **Nhiệm vụ** T: dự báo khả năng một hồ sơ vay sẽ phát sinh nợ xấu trong 12 tháng kể từ thời điểm cấp tín dụng.
- **Kinh nghiệm** E: tập hồ sơ vay trong quá khứ, mỗi hồ sơ gồm các đặc trưng được quan sát tại thời điểm nộp và kết quả trả nợ đã biết.
- **Độ đo hiệu quả** P: khả năng phân biệt giữa hồ sơ tốt và hồ sơ xấu, đo bằng các chỉ tiêu như AUC, hệ số Gini và thống kê KS.

Điểm khác biệt căn bản giữa học máy và lập trình theo quy tắc nằm ở chiều của quá trình suy luận. Lập trình theo quy tắc đi từ quy luật do con người phát biểu tới kết quả; học máy đi ngược lại – từ các cặp (dữ liệu đầu vào, kết quả đã biết) để suy ra quy luật. Trong bài toán tín dụng, chiều ngược này có ý nghĩa thực tiễn rõ rệt: thay vì yêu cầu chuyên gia phát biểu chính xác mối quan hệ giữa hàng trăm đặc trưng và xác suất

vỡ nợ (điều vượt quá khả năng của phán đoán chủ quan), thuật toán rút ra quan hệ đó từ chính dữ liệu lịch sử của tổ chức.

1.2.2 Phân loại các phương pháp học máy

Các phương pháp học máy thường được phân loại theo dạng thông tin giám sát có trong dữ liệu huấn luyện.

Học có giám sát (*supervised learning*). Dữ liệu huấn luyện gồm các cặp $(\mathbf{x}_i, y_i)$, trong đó $\mathbf{x}_i$ là vectơ đặc trưng và y_i là nhãn đã biết. Mục tiêu là học một ánh xạ $f : \mathcal{X} \to \mathcal{Y}$ sao cho $f(\mathbf{x})$ xấp xỉ tốt nhãn thật trên dữ liệu mới. Khi $\mathcal{Y}$ là tập hữu hạn các lớp, bài toán là *phân loại*; khi $\mathcal{Y}$ liên tục, bài toán là *hồi quy*.

Học không giám sát (*unsupervised learning*). Dữ liệu chỉ gồm $\mathbf{x}_i$ mà không có nhãn. Thuật toán tìm cấu trúc tiềm ẩn trong dữ liệu: phân cụm khách hàng thành các nhóm tương đồng, giảm chiều dữ liệu, hoặc phát hiện bất thường. Trong lĩnh vực tín dụng, nhóm phương pháp này thường được dùng cho phân khúc khách hàng và phát hiện gian lận.

Học bán giám sát (*semi-supervised learning*). Kết hợp một lượng nhỏ dữ liệu có nhãn với lượng lớn dữ liệu không nhãn. Trong bài toán tín dụng, tình huống này xuất hiện tự nhiên: các hồ sơ *bị từ chối* không có kết quả trả nợ nên không có nhãn, trong khi chúng chiếm một phần đáng kể tổng số hồ sơ nộp vào. Vấn đề này được biết đến với tên gọi *reject inference*.

Học tăng cường (*reinforcement learning*). Tác tử học chính sách hành động thông qua tương tác với môi trường và tín hiệu thưởng/phạt. Phương pháp này ít được dùng cho chấm điểm tín dụng do khó thiết lập môi trường thử nghiệm an toàn, nhưng có ứng dụng trong tối ưu hạn mức và chiến lược thu hồi nợ.

Bài toán của đề án – dự báo nhãn nhị phân "tốt/xấu" từ dữ liệu lịch sử đã có kết quả – thuộc nhóm **học có giám sát, bài toán phân loại nhị phân**. Tuy nhiên, cần lưu ý một đặc thù: kết quả cần có không phải là nhãn dự báo mà là *xác suất* vỡ nợ được hiệu chuẩn đúng, vì xác suất này được dùng trực tiếp để phân vùng quyết định và tính tổn thất kỳ vọng theo công thức (1.1).

1.2.3 Học máy có giám sát trong bài toán tín dụng

Phát biểu hình thức bài toán như sau. Cho tập huấn luyện $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n}$ với $\mathbf{x}_i \in \mathbb{R}^d$ là vectơ đặc trưng của hồ sơ thứ i và $y_i \in \{0, 1\}$ là nhãn ($y_i = 1$ nếu hồ sơ phát sinh nợ xấu). Cần tìm hàm f ước lượng xác suất có điều kiện

$$\mathrm{PD}(\mathbf{x}) = \Pr(y = 1 \mid \mathbf{X} = \mathbf{x}). \tag{1.2}$$

Hàm f được chọn bằng cách tối thiểu hóa một hàm mất mát trên tập huấn luyện, có bổ sung thành phần điều chuẩn để kiểm soát độ phức tạp:

$$\hat{f} = \arg\min_{f \in \mathcal{F}} \left[\frac{1}{n} \sum_{i=1}^{n} \ell(y_i, f(\mathbf{x}_i)) + \lambda\, \Omega(f) \right]. \tag{1.3}$$

Hàm mất mát chuẩn cho bài toán phân loại nhị phân có đầu ra xác suất là hàm **entropy chéo nhị phân** (*binary cross-entropy*, còn gọi là log-loss):

$$\ell(y, p) = -\big[\, y \log p + (1 - y) \log(1 - p) \,\big]. \tag{1.4}$$

Log-loss thuộc lớp *quy tắc chấm điểm chính đáng* (*strictly proper scoring rule*): kỳ vọng của nó đạt cực tiểu khi và chỉ khi p bằng đúng xác suất thật. Tính chất này có ý nghĩa quyết định đối với bài toán tín dụng, nơi giá trị xác suất được sử dụng trực tiếp chứ không chỉ dùng để xếp hạng. Nếu thay bằng một hàm mất mát không chính đáng, chẳng hạn tối ưu trực tiếp độ chính xác phân loại, mô hình có thể xếp hạng tốt nhưng cho ra giá trị xác suất sai lệch hệ thống.

Ba đặc thù của bài toán tín dụng. So với bài toán phân loại nhị phân thông thường, bài toán chấm điểm tín dụng có ba đặc thù cần được xử lý riêng:

(1) **Dữ liệu mất cân bằng.** Tỷ lệ hồ sơ xấu thường ở mức 3–20%, tùy sản phẩm và phân khúc. Mức mất cân bằng này khiến chỉ tiêu độ chính xác (*accuracy*) mất ý nghĩa: một mô hình dự báo "mọi hồ sơ đều tốt" vẫn đạt độ chính xác 85% mà không có giá trị sử dụng nào.

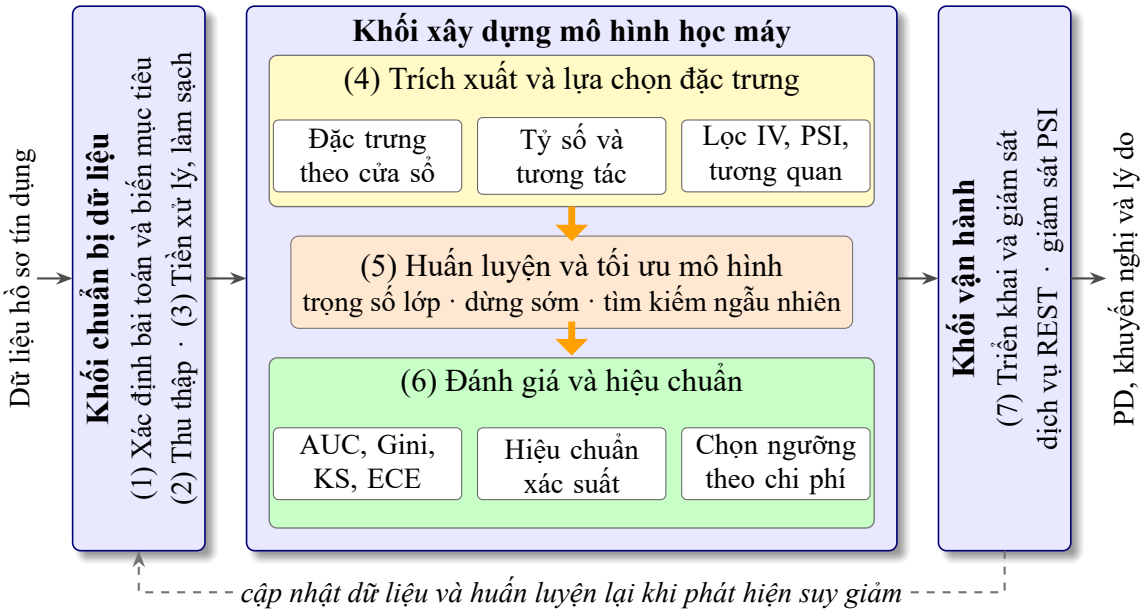
(2) **Chi phí hai loại sai lầm rất khác nhau.** Bỏ sót một hồ sơ xấu (*false negative*) gây tổn thất bằng một phần đáng kể dư nợ, trong khi từ chối sai một hồ sơ tốt (*false positive*) chỉ làm mất phần lãi biên. Tỷ lệ chi phí thường được ước lượng

trong khoảng 10:1 đến 15:1. Hệ quả là ngưỡng quyết định phải được chọn theo hàm chi phí [37] chứ không phải theo giá trị mặc định 0,5.

(3) **Trôi dạt theo thời gian.** Phân phối đặc trưng và quan hệ giữa đặc trưng với nhãn thay đổi theo chu kỳ kinh tế, theo chính sách sản phẩm và theo thành phần khách hàng [35]. Do đó việc đánh giá mô hình phải được thực hiện trên dữ liệu của giai đoạn *sau* giai đoạn huấn luyện, chứ không phải trên mẫu ngẫu nhiên trộn lẫn các giai đoạn.

1.2.4 Quy trình xây dựng mô hình học máy

Quy trình xây dựng một mô hình học máy phục vụ nghiệp vụ tín dụng gồm bảy bước, tổ chức thành ba khối như minh họa ở Hình 1.1: khối *chuẩn bị dữ liệu* (bước 1–3), khối *xây dựng mô hình* (bước 4–6) và khối *vận hành* (bước 7).



Hình 1.1: Quy trình xây dựng và vận hành mô hình học máy cho bài toán tín dụng

Bước (1) định nghĩa thế nào là hồ sơ "xấu", xác định cửa sổ quan sát và phạm vi khách hàng áp dụng; đây là bước có ảnh hưởng lớn nhất tới toàn bộ kết quả, vì một định nghĩa nhãn không phù hợp sẽ làm sai lệch mọi bước tiếp theo. Các bước (2) đến (6) lần lượt tổng hợp dữ liệu về cùng một đơn vị phân tích, làm sạch, tạo đặc trưng, huấn luyện và đánh giá mô hình. Bước (7) theo dõi mô hình trong vận hành để xác định thời điểm huấn luyện lại. Nội dung chi tiết của từng bước, gắn với bài toán cụ thể của đề án, được trình bày ở Chương 2.

Quy trình này có *tính lặp*: kết quả ở bước sau thường buộc phải quay lại điều chỉnh các bước trước. Chẳng hạn, một đặc trưng có chỉ số Information Value cao bất

thường ở bước (4) có thể là dấu hiệu biến đó chứa thông tin của tương lai, buộc phải xem lại cách tổng hợp dữ liệu ở bước (2).

1.2.5 Vai trò của học máy trong hỗ trợ kiểm duyệt tín dụng

Trong quy trình kiểm duyệt mà đề án xây dựng, mô hình học máy đảm nhiệm bốn vai trò. Thứ nhất, *lượng hóa rủi ro trên thang đo liên tục*: thay vì kết luận nhị phân "đạt/không đạt", mô hình cho ra giá trị PD $\in (0, 1)$, nhờ đó có thể phân hạng rủi ro, định giá theo rủi ro và phân bổ nguồn lực thẩm định theo mức độ cần thiết. Thứ hai, *phát hiện quan hệ mà bộ quy tắc bỏ sót*, kể cả những tương tác mà người xây dựng chính sách không dự liệu trước. Thứ ba, *bảo đảm tính nhất quán*: cùng một hồ sơ luôn nhận được cùng một kết quả đánh giá, không phụ thuộc người xử lý hay thời điểm xử lý. Thứ tư, *giảm khối lượng công việc thủ công* bằng cách tự động xử lý các hồ sơ nằm ở hai vùng biên, để cán bộ tín dụng tập trung vào nhóm hồ sơ thực sự cần cân nhắc.

Đi kèm là bốn giới hạn. Mô hình chỉ học được quy luật có trong dữ liệu lịch sử, nên những tình huống chưa từng xuất hiện nằm ngoài khả năng dự báo. Chất lượng mô hình phụ thuộc trực tiếp vào chất lượng dữ liệu. Các mô hình phức tạp khó giải thích hơn thẻ điểm truyền thống, đòi hỏi bổ sung công cụ giải thích. Cuối cùng, mô hình suy giảm theo thời gian và cần được giám sát, hiệu chỉnh định kỳ [34]. Bốn giới hạn này là cơ sở để đề án xác định vai trò của mô hình là *hỗ trợ* chứ không phải *thay thế* quá trình kiểm duyệt của con người.

1.3 Dữ liệu và đặc trưng trong bài toán tín dụng

1.3.1 Đặc điểm dữ liệu tín dụng

Dữ liệu phục vụ bài toán chấm điểm tín dụng có năm đặc điểm gây khó khăn riêng so với dữ liệu của nhiều lĩnh vực khác.

Tính đúng đắn theo thời điểm. Mọi đặc trưng của một hồ sơ chỉ được phép tính từ dữ liệu đã tồn tại *trước hoặc tại* thời điểm nộp hồ sơ. Vi phạm nguyên tắc này dẫn tới hiện tượng rò rỉ nhãn (*label leakage*): mô hình sử dụng thông tin của tương lai, cho kết quả đánh giá cao giả tạo trong môi trường thử nghiệm nhưng suy giảm nghiêm trọng khi triển khai. Đây là lỗi khó phát hiện, vì nó không sinh ra thông báo lỗi mà chỉ làm các chỉ tiêu chất lượng cao lên bất thường.

Độ trễ của nhãn. Kết quả trả nợ chỉ được biết sau cửa sổ quan sát, thường là 12 tháng. Do đó tại mọi thời điểm luôn tồn tại một khối hồ sơ gần đây chưa có nhãn. Điều này giới hạn lượng dữ liệu huấn luyện khả dụng và buộc phải cân nhắc đánh đổi: cửa sổ quan sát dài hơn cho nhãn đáng tin cậy hơn nhưng làm dữ liệu huấn luyện cũ hơn.

Mất cân bằng lớp. Tỷ lệ hồ sơ xấu thường thấp, khiến số quan sát của lớp thiểu số – vốn là lớp cần quan tâm – bị hạn chế.

Giá trị khuyết mang thông tin. Trong dữ liệu tín dụng, việc một trường bị trống thường không phải lỗi thu thập mà tự nó là một tín hiệu. Khách hàng không có bất kỳ thông tin nào tại CIC (*thin-file*) nghĩa là chưa từng có quan hệ tín dụng – đây là một trạng thái có ý nghĩa rủi ro riêng, khác hẳn với việc không truy vấn được dữ liệu. Cách xử lý đúng là phân biệt hai trường hợp và bổ sung biến chỉ báo khuyết thay vì đơn thuần điền giá trị thống kê.

Trôi dạt theo thời gian. Cả phân phối biên của đặc trưng lẫn quan hệ giữa đặc trưng và nhãn đều thay đổi theo thời gian, do biến động kinh tế vĩ mô, thay đổi chính sách sản phẩm hoặc dịch chuyển cơ cấu khách hàng.

1.3.2 Các nhóm dữ liệu sử dụng trong đánh giá tín dụng

Dữ liệu phục vụ đánh giá tín dụng khách hàng cá nhân được phân thành bốn nhóm nguồn, tổng hợp tại Bảng 1.1.

Trong bốn nhóm trên, nhóm dữ liệu hành vi giao dịch có ba đặc điểm riêng: tổ chức tín dụng *tự sở hữu* nên không phụ thuộc bên thứ ba, phản ánh tình trạng tài chính *hiện tại* thay vì lịch sử, và luôn có sẵn kể cả với khách hàng thiếu lịch sử tín dụng. Onay và Öztürk [10] nhấn mạnh vai trò ngày càng lớn của nhóm dữ liệu này trong bối cảnh dữ liệu lớn, đặc biệt với phân khúc khách hàng mà các nguồn dữ liệu truyền thống gần như không cung cấp thông tin. Một trong những nội dung thực nghiệm của đề án là định lượng mức đóng góp của nhóm dữ liệu này vào chất lượng dự báo.

Bảng 1.1: Các nhóm nguồn dữ liệu sử dụng trong đánh giá tín dụng cá nhân

Nhóm	Nội dung chính	Đặc điểm
Thông tin cá nhân và tài chính	Tuổi, giới tính, tình trạng hôn nhân, số người phụ thuộc, trình độ, nghề nghiệp, thâm niên, thu nhập, nơi cư trú	Khách hàng tự khai báo; cần đối chiếu với chứng từ. Thay đổi chậm theo thời gian
Tham số khoản vay	Sản phẩm, số tiền, kỳ hạn, lãi suất, mục đích vay, kênh tiếp nhận, tài sản bảo đảm	Xác định tại thời điểm nộp hồ sơ; phản ánh cả nhu cầu lẫn mức độ chấp nhận rủi ro của khách hàng
Lịch sử tín dụng và quan hệ CIC	Điểm CIC, nhóm nợ, số ngày quá hạn, số tổ chức có quan hệ, dư nợ, tỷ lệ sử dụng hạn mức, số lần truy vấn	Nguồn thông tin khách quan, có năng lực dự báo cao nhất; phụ thuộc dịch vụ bên ngoài và không có với khách hàng thin-file
Hành vi giao dịch tài khoản	Số lượng và giá trị giao dịch, dòng tiền vào/ra, tính đều đặn của thu nhập, cơ cấu chi tiêu theo nhóm	Chỉ có với khách hàng đã có quan hệ tài khoản; cập nhật liên tục và phản ánh tình trạng tài chính hiện tại

1.3.3 Xây dựng và lựa chọn đặc trưng

Xây dựng đặc trưng. Dữ liệu thô hiếm khi ở dạng phù hợp trực tiếp cho mô hình. Quá trình xây dựng đặc trưng (*feature engineering*) biến đổi dữ liệu thô thành các biến mang ý nghĩa dự báo, thông qua bốn kỹ thuật chính:

- **Tổng hợp theo cửa sổ thời gian**: từ danh sách giao dịch, tính tổng dòng tiền vào, số lần giao dịch, giá trị trung bình trong các cửa sổ 7, 30, 90 và 180 ngày trước thời điểm nộp hồ sơ.
- **Tạo tỷ số**: các chỉ tiêu nghiệp vụ như DTI, LTV, tỷ lệ thu nhập còn lại sau trả nợ. Tỷ số có ưu điểm là chuẩn hóa được sự khác biệt về quy mô giữa các khách hàng.
- **Tạo biến xu thế**: so sánh giá trị ở cửa sổ ngắn với cửa sổ dài để nắm bắt chiều hướng thay đổi, chẳng hạn dòng tiền vào 30 ngày gần nhất so với mức trung bình 90 ngày.
- **Tạo biến tương tác**: kết hợp hai hoặc nhiều biến để biểu diễn quan hệ phi cộng tính, chẳng hạn tích của số ngày quá hạn với số tổ chức tín dụng có quan hệ.

Weight of Evidence và Information Value. Trong ngành tín dụng, hai công cụ được sử dụng phổ biến để đánh giá và biến đổi đặc trưng là Weight of Evidence (WOE) và Information Value (IV) [30]. Với một biến được rời rạc hóa thành K khoảng, WOE của khoảng thứ k được định nghĩa:

$$\mathrm{WOE}_k = \ln \frac{\text{tỷ lệ hồ sơ tốt trong khoảng } k}{\text{tỷ lệ hồ sơ xấu trong khoảng } k} = \ln \frac{g_k/G}{b_k/B}, \tag{1.5}$$

trong đó g_k, b_k lần lượt là số hồ sơ tốt và xấu trong khoảng k; G, B là tổng số hồ sơ tốt và xấu. Information Value tổng hợp năng lực phân biệt của toàn bộ biến:

$$\mathrm{IV} = \sum_{k=1}^{K} \left(\frac{g_k}{G} - \frac{b_k}{B} \right) \mathrm{WOE}_k. \tag{1.6}$$

Thực hành ngành sử dụng thang diễn giải: $\mathrm{IV} < 0{,}02$ – biến không có khả năng phân biệt; $0{,}02 \le \mathrm{IV} < 0{,}1$ – yếu; $0{,}1 \le \mathrm{IV} < 0{,}3$ – trung bình; $0{,}3 \le \mathrm{IV} < 0{,}5$ – mạnh; $\mathrm{IV} \ge 0{,}5$ – rất mạnh, cần kiểm tra khả năng rò rỉ nhãn.

Phép biến đổi WOE có ba ưu điểm đối với bài toán tín dụng: nó đưa mọi biến về cùng một thang đo theo log-odds, xử lý được giá trị khuyết như một khoảng riêng, và cho phép áp đặt ràng buộc đơn điệu để bảo đảm mô hình phù hợp với trực giác nghiệp vụ (điểm tín dụng càng cao thì rủi ro càng thấp).

Lựa chọn đặc trưng. Khi tập đặc trưng ban đầu lớn, việc giữ lại toàn bộ gây ba vấn đề: hệ số của mô hình tuyến tính mất ổn định do đa cộng tuyến, chi phí tính toán tăng, và khả năng diễn giải giảm. Các phương pháp lựa chọn đặc trưng được chia thành ba nhóm:

- **Phương pháp lọc** (*filter*): đánh giá từng đặc trưng độc lập với mô hình, dựa trên IV, hệ số tương quan hoặc kiểm định thống kê. Chi phí tính toán thấp, phù hợp để sàng lọc sơ bộ.
- **Phương pháp bao** (*wrapper*): thử các tập con đặc trưng và đánh giá bằng chính mô hình đích. Cho kết quả tốt hơn nhưng chi phí tính toán cao.
- **Phương pháp nhúng** (*embedded*): việc lựa chọn diễn ra trong quá trình huấn luyện, chẳng hạn điều chuẩn L_1 hoặc tầm quan trọng đặc trưng của mô hình cây.

Đề án sử dụng quy trình lọc ba bước nối tiếp – theo năng lực dự báo (IV), theo mức tương quan, và theo độ ổn định theo thời gian (PSI) – được trình bày chi tiết ở mục 2.4.

1.4 Các mô hình học máy áp dụng trong đánh giá tín dụng

Mục này trình bày nguyên lý của năm nhóm thuật toán được đề án nghiên cứu và thực nghiệm, theo đúng thứ tự từ đơn giản đến phức tạp.

1.4.1 Hồi quy Logistic

Hồi quy logistic là mô hình tuyến tính tổng quát dùng cho biến phụ thuộc nhị phân. Mô hình giả định log-odds của xác suất vỡ nợ là hàm tuyến tính của các đặc trưng:

$$\ln \frac{\mathrm{PD}(\mathbf{x})}{1-\mathrm{PD}(\mathbf{x})} = \beta_0 + \sum_{j=1}^{d} \beta_j x_j, \qquad \text{tương đương} \qquad \mathrm{PD}(\mathbf{x}) = \frac{1}{1+e^{-(\beta_0+\boldsymbol{\beta}^\top \mathbf{x})}}. \tag{1.7}$$

Tham số $\boldsymbol{\beta}$ được ước lượng bằng phương pháp hợp lý cực đại, tương đương với việc tối thiểu hóa hàm log-loss (1.4). Để kiểm soát quá khớp, thường bổ sung thành phần điều chuẩn L_2:

$$\hat{\boldsymbol{\beta}} = \arg\min_{\boldsymbol{\beta}} \left[-\sum_{i=1}^{n} \Big(y_i \log p_i + (1-y_i)\log(1-p_i) \Big) + \frac{1}{2C}\|\boldsymbol{\beta}\|_2^2 \right]. \tag{1.8}$$

Ưu điểm. Hồi quy logistic có ba ưu thế khiến nó vẫn là mô hình chuẩn mực trong ngành tín dụng sau hơn nửa thế kỷ. Thứ nhất, *khả năng giải thích*: mỗi hệ số β_j cho biết trực tiếp mức thay đổi của log-odds khi đặc trưng x_j tăng một đơn vị, và dấu của hệ số có thể được đối chiếu với kỳ vọng nghiệp vụ. Thứ hai, *xác suất đầu ra được hiệu chuẩn tốt* do hàm mất mát chính là log-loss. Thứ ba, *tính ổn định*: mô hình có ít tham số nên ít nhạy cảm với nhiễu trong dữ liệu huấn luyện.

Hạn chế. Giả định tuyến tính trên thang log-odds là hạn chế cơ bản: mô hình không tự nắm bắt được quan hệ phi tuyến hay tương tác giữa các biến, trừ khi những quan hệ này được đưa vào tường minh dưới dạng biến phái sinh.

Thẻ điểm dựa trên biến đổi WOE. Trong thực tiễn ngân hàng, hồi quy logistic thường được áp dụng trên các đặc trưng đã qua biến đổi WOE (1.5) thay vì trên giá trị gốc. Cách làm này khắc phục một phần hạn chế tuyến tính – vì việc rời rạc hóa cho

phép biểu diễn quan hệ phi tuyến theo từng khoảng – đồng thời cho phép quy đổi kết quả thành thang điểm nguyên dễ vận hành:

$$\text{Điểm} = \text{Offset} + \text{Factor} \times \ln(\text{odds}), \qquad \text{Factor} = \frac{\text{PDO}}{\ln 2}, \tag{1.9}$$

trong đó PDO (*Points to Double the Odds*) là số điểm tương ứng với việc tỷ số odds tăng gấp đôi. Thẻ điểm xây dựng theo cách này có thể in ra thành bảng tra, giúp cán bộ tín dụng hiểu chính xác vì sao một hồ sơ đạt mức điểm cụ thể.

1.4.2 Decision Tree

Cây quyết định [17] phân chia đệ quy không gian đặc trưng thành các vùng con, tại mỗi bước chọn cặp (đặc trưng, ngưỡng) làm giảm nhiều nhất độ không thuần khiết của nút. Với bài toán phân loại, độ không thuần khiết thường được đo bằng chỉ số Gini:

$$G(t) = 1 - \sum_{c \in \{0,1\}} p_c(t)^2, \tag{1.10}$$

trong đó $p_c(t)$ là tỷ lệ quan sát thuộc lớp c tại nút t. Phép chia tốt nhất là phép chia làm cực đại mức giảm độ không thuần khiết có trọng số:

$$\Delta G = G(t) - \frac{n_L}{n_t} G(t_L) - \frac{n_R}{n_t} G(t_R). \tag{1.11}$$

Ưu điểm. Cây quyết định tự động nắm bắt quan hệ phi tuyến và tương tác giữa các biến, không yêu cầu chuẩn hóa thang đo, xử lý được cả biến định lượng lẫn định tính, và – với cây nông – có thể diễn giải trực tiếp thành chuỗi điều kiện gần với ngôn ngữ nghiệp vụ.

Hạn chế. Cây đơn có phương sai cao: một thay đổi nhỏ trong dữ liệu huấn luyện có thể dẫn tới cấu trúc cây hoàn toàn khác. Cây sâu dễ quá khớp, trong khi cây nông lại quá đơn giản để nắm bắt quan hệ phức tạp. Để kiểm soát, đề án sử dụng kỹ thuật tỉa nhánh theo độ phức tạp chi phí (*cost-complexity pruning*) với tiêu chí:

$$R_\alpha(T) = R(T) + \alpha\, |\tilde{T}|, \tag{1.12}$$

trong đó $R(T)$ là sai số của cây T, $|\tilde{T}|$ là số nút lá và α là tham số phạt độ phức tạp.

Chính hạn chế về phương sai cao của cây đơn là động lực dẫn tới hai nhóm phương pháp học tập hợp trình bày ở hai mục tiếp theo.

1.4.3 Random Forest

Rừng ngẫu nhiên [23] xây dựng nhiều cây quyết định độc lập và tổng hợp kết quả bằng cách lấy trung bình xác suất dự báo:

$$\mathrm{PD}_{\mathrm{RF}}(\mathbf{x}) = \frac{1}{M}\sum_{m=1}^{M} \mathrm{PD}_m(\mathbf{x}). \tag{1.13}$$

Tính đa dạng giữa các cây – yếu tố quyết định hiệu quả của phương pháp – được tạo ra bằng hai cơ chế ngẫu nhiên hóa. Thứ nhất, mỗi cây được huấn luyện trên một mẫu bootstrap lấy có hoàn lại từ tập huấn luyện. Thứ hai, tại mỗi nút, chỉ một tập con ngẫu nhiên gồm $\sqrt{d}$ đặc trưng được xem xét để tìm phép chia.

Cơ sở lý thuyết của phương pháp [18] nằm ở công thức phương sai của trung bình M biến ngẫu nhiên có cùng phương sai σ^2 và tương quan cặp ρ:

$$\mathrm{Var}\left(\frac{1}{M}\sum_{m=1}^{M} Z_m\right) = \rho\sigma^2 + \frac{1-\rho}{M}\sigma^2. \tag{1.14}$$

Số hạng thứ hai giảm về 0 khi M tăng, nhưng số hạng thứ nhất chỉ giảm được bằng cách làm giảm tương quan ρ giữa các cây. Đây chính là lý do của cơ chế lấy mẫu ngẫu nhiên đặc trưng tại mỗi nút: nếu mọi cây đều được phép dùng đặc trưng mạnh nhất, chúng sẽ giống nhau và việc lấy trung bình mất tác dụng.

Ưu điểm. Rừng ngẫu nhiên giữ được khả năng biểu diễn phi tuyến của cây nhưng có phương sai thấp hơn nhiều, ít nhạy cảm với siêu tham số, và cung cấp sẵn thước đo tầm quan trọng của đặc trưng.

Hạn chế. Mô hình mất khả năng diễn giải trực tiếp; chi phí bộ nhớ và thời gian suy luận tăng theo số cây; và xác suất đầu ra thường bị lệch về phía trung tâm, cần hiệu chuẩn lại trước khi dùng làm PD.

1.4.4 Support Vector Machine

Máy vectơ hỗ trợ (SVM) [13, 14] tiếp cận bài toán phân loại từ góc nhìn hình học: tìm siêu phẳng phân tách hai lớp sao cho *lề* – khoảng cách từ siêu phẳng tới các điểm gần nhất của mỗi lớp – là lớn nhất. Với dữ liệu không phân tách tuyến tính hoàn hảo, bài toán được phát biểu ở dạng lề mềm:

$$\begin{aligned} &\min_{\mathbf{w},b,\xi} \quad \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{n}\xi_i \\ &\text{với ràng buộc} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \end{aligned} \tag{1.15}$$

trong đó ξ_i là biến bù cho phép một số điểm nằm sai phía, còn C điều tiết đánh đổi giữa độ rộng lề và mức chấp nhận vi phạm.

Thủ thuật hạt nhân. Điểm mạnh đặc trưng của SVM nằm ở chỗ bài toán đối ngẫu chỉ phụ thuộc vào tích vô hướng giữa các cặp quan sát. Nhờ đó có thể thay tích vô hướng bằng một hàm hạt nhân $K(\mathbf{x}_i, \mathbf{x}_j)$ tương ứng với tích vô hướng trong một không gian đặc trưng có số chiều cao hơn, mà không cần tính toán tường minh phép ánh xạ. Hạt nhân được dùng phổ biến nhất là hạt nhân Gauss (RBF):

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma\|\mathbf{x}_i - \mathbf{x}_j\|^2). \tag{1.16}$$

Ưu điểm. SVM có nền tảng lý thuyết chặt chẽ dựa trên nguyên lý cực tiểu hóa rủi ro cấu trúc, hoạt động tốt trong không gian nhiều chiều, và nhờ thủ thuật hạt nhân có thể biểu diễn ranh giới quyết định rất linh hoạt.

Hạn chế trong bài toán tín dụng. SVM gặp ba trở ngại thực tế đáng kể khi áp dụng cho chấm điểm tín dụng ở quy mô lớn:

(1) **Chi phí tính toán.** Việc giải bài toán đối ngẫu có độ phức tạp từ $O(n^2)$ đến $O(n^3)$ theo số quan sát, khiến SVM hạt nhân đầy đủ không khả thi với tập dữ liệu hàng chục nghìn hồ sơ trở lên.

(2) **Đầu ra không phải xác suất.** SVM cho ra giá trị hàm quyết định – khoảng cách có dấu tới siêu phẳng – chứ không phải xác suất. Để dùng được trong hệ thống tín dụng, giá trị này phải được quy đổi bằng phương pháp Platt [16]: khớp một hồi quy logistic một biến trên giá trị hàm quyết định.

(3) **Khó giải thích.** Ranh giới quyết định trong không gian hạt nhân không có biểu diễn tường minh theo các đặc trưng gốc.

Để khắc phục trở ngại thứ nhất, đề án sử dụng phép xấp xỉ Nystroem [15]: thay vì tính ma trận hạt nhân đầy đủ kích thước $n \times n$, phương pháp chọn $m \ll n$ điểm mốc và xây dựng một ánh xạ tường minh $\phi : \mathbb{R}^d \to \mathbb{R}^m$ sao cho $\phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) \approx K(\mathbf{x}_i, \mathbf{x}_j)$. Sau phép ánh xạ này, một SVM tuyến tính – có chi phí tuyến tính theo n – cho nghiệm xấp xỉ nghiệm của SVM hạt nhân đầy đủ.

1.4.5 Gradient Boosting

Khác với rừng ngẫu nhiên xây dựng các cây *song song và độc lập*, gradient boosting [24] xây dựng các cây *tuần tự*, trong đó mỗi cây mới học phần sai số còn lại của tổ hợp các cây trước đó. Mô hình được xây dựng theo sơ đồ cộng tính:

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta\, h_m(\mathbf{x}), \tag{1.17}$$

trong đó h_m là cây thứ m được khớp với gradient âm của hàm mất mát tại dự báo hiện tại, còn $\eta \in (0, 1]$ là tốc độ học đóng vai trò điều chuẩn: giá trị η nhỏ buộc mô hình cải thiện từ từ, giảm nguy cơ quá khớp nhưng đòi hỏi nhiều cây hơn.

Các biến thể hiện đại. Ba thư viện được sử dụng rộng rãi hiện nay cải tiến ý tưởng gốc theo những hướng khác nhau:

- **XGBoost** [20] bổ sung thành phần điều chuẩn tường minh vào hàm mục tiêu và sử dụng khai triển Taylor bậc hai để xác định phép chia tối ưu, thay vì chỉ dùng gradient bậc nhất.
- **LightGBM** [21] sinh cây theo chiều lá (*leaf-wise*) – mở rộng lá có mức giảm mất mát lớn nhất – thay vì theo chiều sâu, kết hợp với kỹ thuật rời rạc hóa đặc trưng thành histogram để tăng tốc độ huấn luyện.
- **CatBoost** [22] xử lý đặc trưng định tính bằng thống kê mục tiêu có thứ tự (*ordered target statistics*), khắc phục hiện tượng rò rỉ mục tiêu vốn xảy ra khi mã hóa biến định tính theo giá trị trung bình của nhãn.

Ưu điểm. Gradient boosting thường cho chất lượng dự báo cao nhất trong các bài toán dữ liệu dạng bảng, nhờ khả năng nắm bắt tương tác bậc cao và cơ chế tập trung vào các quan sát khó phân loại.

Hạn chế. Mô hình nhạy cảm với siêu tham số hơn rừng ngẫu nhiên, dễ quá khớp nếu không dừng sớm, khó diễn giải trực tiếp, và xác suất đầu ra cần được hiệu chuẩn – đặc biệt khi sử dụng trọng số lớp để bù mất cân bằng dữ liệu.

1.4.6 So sánh và lựa chọn mô hình phù hợp

1.4.6.1 Hệ thống chỉ tiêu đánh giá

Việc so sánh các mô hình đòi hỏi một bộ chỉ tiêu phản ánh đầy đủ các khía cạnh mà bài toán quan tâm. Đề án sử dụng bốn nhóm chỉ tiêu.

Nhóm 1 – Chỉ tiêu phân loại phổ quát. Xuất phát từ ma trận nhầm lẫn với bốn ô TP, FP, TN, FN:

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{TP + FN}, \tag{1.18}$$

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \tag{1.19}$$

Độ chính xác (*accuracy*) được báo cáo nhưng không dùng làm tiêu chí chính, vì lý do đã nêu ở mục 1.2.3.

Nhóm 2 – Chỉ tiêu đặc thù ngành tín dụng. Ba chỉ tiêu dưới đây được sử dụng phổ biến trong kiểm định mô hình tín dụng [32]:

- AUC – diện tích dưới đường cong ROC, bằng xác suất một hồ sơ xấu chọn ngẫu nhiên nhận điểm rủi ro cao hơn một hồ sơ tốt chọn ngẫu nhiên. Chỉ tiêu này không phụ thuộc ngưỡng quyết định, nên phù hợp để so sánh mô hình.
- **Hệ số Gini** $= 2 \cdot \text{AUC} - 1$, là cách biểu diễn quen thuộc hơn trong ngành ngân hàng, với thang giá trị từ 0 (không phân biệt) đến 1 (phân biệt hoàn hảo).
- **Thống kê** KS – khoảng cách lớn nhất giữa hàm phân phối tích lũy của điểm số ở nhóm tốt và nhóm xấu:

$$\text{KS} = \max_{s} |F_{\text{tốt}}(s) - F_{\text{xấu}}(s)|. \tag{1.20}$$

  Ý nghĩa vận hành của KS là nó chỉ ra điểm cắt tại đó mô hình phân tách hai nhóm mạnh nhất.

Nhóm 3 – Chất lượng hiệu chuẩn xác suất. Một mô hình có thể xếp hạng rất tốt nhưng cho giá trị xác suất sai lệch. Vì đề án sử dụng PD trực tiếp để phân vùng quyết định, chất lượng hiệu chuẩn phải được đo tường minh bằng điểm Brier và sai số hiệu chuẩn kỳ vọng:

$$\text{Brier} = \frac{1}{n}\sum_{i=1}^{n}(p_i - y_i)^2, \qquad \text{ECE} = \sum_{b=1}^{B}\frac{n_b}{n}|\bar{y}_b - \bar{p}_b|. \tag{1.21}$$

Hai kỹ thuật hiệu chuẩn phổ biến là hồi quy đẳng hướng (*isotonic regression*) [27] và phương pháp Platt. Nghiên cứu của Niculescu-Mizil và Caruana [28] cho thấy các mô hình học tập hợp thường cho xác suất bị nén về phía trung tâm và cần hiệu chuẩn lại.

Nhóm 4 – Chỉ tiêu vận hành. Bao gồm thời gian huấn luyện, thời gian chấm điểm một hồ sơ và mức độ giải thích được. Đây là những chỉ tiêu quyết định khả năng triển khai thực tế nhưng thường bị bỏ qua trong các so sánh học thuật.

1.4.6.2 Cơ sở lựa chọn mô hình

Bảng 1.2 tổng hợp đặc điểm của năm nhóm mô hình theo các tiêu chí quan trọng đối với bài toán kiểm duyệt tín dụng.

Bảng 1.2: So sánh định tính các nhóm mô hình theo tiêu chí của bài toán tín dụng

Mô hình	Năng lực dự báo	Giải thích	Hiệu chuẩn	Chi phí huấn luyện	Độ ổn định
Hồi quy logistic	Trung bình	Rất cao	Rất tốt	Rất thấp	Cao
Thẻ điểm WOE	Trung bình	Rất cao	Rất tốt	Thấp	Cao
Cây quyết định	Thấp	Cao	Trung bình	Rất thấp	Thấp
Rừng ngẫu nhiên	Cao	Trung bình	Cần hiệu chuẩn	Trung bình	Cao
Máy vectơ hỗ trợ	Cao	Thấp	Cần hiệu chuẩn	Cao	Trung bình
Gradient boosting	Rất cao	Thấp	Cần hiệu chuẩn	Trung bình	Trung bình

Bảng trên cho thấy không tồn tại một mô hình tối ưu trên mọi tiêu chí: các mô hình có năng lực dự báo cao nhất lại là những mô hình khó giải thích nhất và cần hiệu

chuẩn xác suất. Do vậy việc lựa chọn phải dựa trên đánh đổi phù hợp với bối cảnh sử dụng cụ thể.

Kết quả đối sánh quy mô lớn của Lessmann và cộng sự [8] cung cấp căn cứ định lượng cho đánh đổi này: trên nhiều bộ dữ liệu tín dụng, khoảng cách AUC giữa mô hình học tập hợp tốt nhất và hồi quy logistic thường chỉ ở mức 0,01–0,03. Mức chênh lệch khiêm tốn này đặt ra câu hỏi liệu việc chấp nhận mất khả năng giải thích và tăng chi phí vận hành có tương xứng với mức cải thiện đó hay không. Câu trả lời phụ thuộc quy mô danh mục: với danh mục lớn, mức cải thiện 0,01 AUC có thể tương ứng khoản tiết kiệm đáng kể về tổn thất tín dụng; với danh mục nhỏ, yêu cầu về tính minh bạch và chi phí vận hành thường được ưu tiên hơn.

Trên cơ sở phân tích đó, đề án xác định nguyên tắc lựa chọn gồm bốn tiêu chí, theo thứ tự ưu tiên: (i) năng lực phân biệt đo bằng AUC và KS trên tập kiểm thử ngoài thời gian; (ii) chất lượng hiệu chuẩn xác suất sau khi đã hiệu chuẩn; (iii) thời gian chấm điểm một hồ sơ trong điều kiện xử lý trực tuyến; và (iv) khả năng giải thích kết quả cho từng hồ sơ. Việc so sánh thực nghiệm theo bốn tiêu chí này được trình bày ở Chương 3.

1.4.6.3 Xử lý mất cân bằng dữ liệu

Ba nhóm kỹ thuật thường được dùng để xử lý mất cân bằng lớp: *lấy mẫu lại* – tăng mẫu lớp thiểu số (chẳng hạn SMOTE [36]) hoặc giảm mẫu lớp đa số; *trọng số lớp* – gán trọng số lớn hơn cho quan sát thuộc lớp thiểu số trong hàm mất mát; và *học nhạy cảm chi phí* – đưa ma trận chi phí vào quá trình huấn luyện hoặc vào việc chọn ngưỡng [37].

Đề án sử dụng **trọng số lớp** kết hợp **lựa chọn ngưỡng theo hàm chi phí**, không sử dụng kỹ thuật lấy mẫu lại. Ở mức mất cân bằng vừa phải (khoảng 15%), việc lấy mẫu lại làm thay đổi phân phối tiên nghiệm của dữ liệu, khiến xác suất đầu ra bị lệch hệ thống và phải điều chỉnh lại, trong khi lợi ích về năng lực phân biệt không rõ ràng. Trọng số lớp giữ nguyên phân phối gốc, còn phần lệch xác suất do trọng số gây ra được xử lý ở bước hiệu chuẩn.

1.4.6.4 Giải thích mô hình

Với mô hình sử dụng trong hoạt động cấp tín dụng, khả năng giải thích là điều kiện bắt buộc: cán bộ tín dụng cần hiểu căn cứ của khuyến nghị để quyết định chấp nhận hay bác bỏ, còn khách hàng có quyền được biết lý do hồ sơ bị từ chối.

Phương pháp SHAP (*SHapley Additive exPlanations*) [25, 26] dựa trên giá trị Shapley trong lý thuyết trò chơi hợp tác. Với mỗi hồ sơ, SHAP phân rã chênh lệch giữa dự báo của mô hình và giá trị dự báo trung bình thành tổng đóng góp của từng đặc trưng:

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^{d} \phi_j, \tag{1.22}$$

trong đó ϕ_0 là giá trị kỳ vọng của dự báo và ϕ_j là đóng góp của đặc trưng thứ j. Tính cộng tính này cho phép chuyển kết quả SHAP thành danh sách lý do (*reason codes*) trình bày được cho người sử dụng.

1.4.6.5 Giám sát trôi dạt

Sau khi triển khai, mô hình cần được giám sát liên tục. Chỉ số được dùng phổ biến nhất là Population Stability Index, đo mức chênh lệch phân phối của một biến giữa giai đoạn tham chiếu và giai đoạn hiện tại:

$$\mathrm{PSI} = \sum_{k=1}^{K} (p_k^{\text{hiện tại}} - p_k^{\text{tham chiếu}}) \ln \frac{p_k^{\text{hiện tại}}}{p_k^{\text{tham chiếu}}}. \tag{1.23}$$

Thực hành ngành sử dụng ngưỡng: PSI $<$ 0,10 – phân phối ổn định; 0,10 $\leq$ PSI $<$ 0,25 – cần theo dõi; PSI $\geq$ 0,25 – thay đổi đáng kể, cần xem xét huấn luyện lại mô hình.

Kết luận chương 1

Chương 1 đã hệ thống hóa cơ sở lý luận làm nền tảng cho đề án, với bốn kết quả chính.

Thứ nhất, chương phân biệt rành mạch giữa kiểm duyệt (quá trình đánh giá, sàng lọc hồ sơ) với phê duyệt (hành vi ra quyết định của cấp có thẩm quyền). Sự phân biệt này xác định vai trò *hỗ trợ* của mô hình và là cơ sở cho thiết kế ba vùng quyết định ở chương sau. Chương cũng chỉ ra bốn hạn chế mang tính cấu trúc của phương pháp kiểm duyệt truyền thống: không biểu diễn được tương tác giữa các yếu tố, ngưỡng đặt theo phán đoán, kết quả nhị phân thiếu thang đo mức độ, và giới hạn về tính nhất quán cùng tốc độ xử lý.

Thứ hai, trong phân rã EL = PD × LGD × EAD, đề án xác định phạm vi là ước lượng thành phần PD, với định nghĩa vỡ nợ thống nhất theo quy định phân loại nợ hiện hành: quá hạn từ 90 ngày trở lên, tương ứng nợ nhóm 3–5.

Thứ ba, chương phân tích ba đặc thù của bài toán tín dụng (dữ liệu mất cân bằng, chi phí hai loại sai lầm chênh lệch lớn, trôi dạt theo thời gian) và năm đặc điểm của dữ liệu tín dụng, trong đó quan trọng nhất là yêu cầu về tính đúng đắn theo thời điểm. Những đặc thù này quy định ba lựa chọn phương pháp ở các chương sau: dùng trọng số lớp thay vì lấy mẫu lại, chọn ngưỡng theo hàm chi phí thay vì giá trị mặc định, và chia dữ liệu theo thời gian thay vì chia ngẫu nhiên.

Thứ tư, chương trình bày nguyên lý, ưu điểm và hạn chế của năm nhóm thuật toán được nghiên cứu cùng bốn nhóm chỉ tiêu đánh giá. Phân tích cho thấy không tồn tại mô hình tối ưu trên mọi tiêu chí, nên việc lựa chọn phải dựa trên đánh đổi giữa năng lực dự báo, khả năng giải thích, chất lượng hiệu chuẩn và chi phí vận hành.

Chương 2

XÂY DỰNG MÔ HÌNH HỌC MÁY TRONG HỖ TRỢ KIỂM DUYỆT TÍN DỤNG

Chương 2 trình bày thực trạng quy trình thẩm định tín dụng, xác định bài toán học máy và phương pháp thu thập, tiền xử lý dữ liệu hồ sơ vay. Nội dung chương tập trung vào kỹ thuật trích xuất đặc trưng, gán nhãn rủi ro và thiết lập quy trình huấn luyện, tối ưu mô hình làm tiền đề cho các thực nghiệm trình bày ở Chương 3.

2.1 Phân tích bài toán kiểm duyệt tín dụng

2.1.1 Xác định các mức độ rủi ro và trạng thái khoản vay cần dự báo

Biến mục tiêu. Đối tượng dự báo của mô hình là xác suất một hồ sơ vay phát sinh nợ xấu trong cửa sổ quan sát kể từ thời điểm cấp tín dụng. Biến mục tiêu được định nghĩa nhị phân:

$$y_i = \begin{cases} 1, & \text{nếu hồ sơ } i \text{ phát sinh nợ nhóm 3–5 (quá hạn} \geq 90 \text{ ngày)} \\ & \text{trong vòng 12 tháng kể từ ngày cấp tín dụng,} \\ 0, & \text{trong trường hợp còn lại.} \end{cases} \tag{2.1}$$

Ba trạng thái thay vì hai. Mặc dù biến mục tiêu là nhị phân, quá trình gán nhãn phải phân biệt **ba** trạng thái. Ngoài hai trạng thái *Tốt* và *Xấu*, cần nhận diện trạng thái *Chưa xác định* dành cho các hồ sơ chưa đi hết cửa sổ quan sát tại thời điểm trích xuất dữ liệu. Nếu bỏ qua và mặc định xếp nhóm này vào loại Tốt, dữ liệu huấn luyện sẽ chứa nhãn sai một cách có hệ thống ở chính những hồ sơ mới nhất – nhóm gần nhất với điều kiện hiện tại. Hệ quả là mô hình đánh giá thấp rủi ro của các hồ sơ gần đây. Đề án loại nhóm Chưa xác định khỏi tập huấn luyện và tập đánh giá.

Thang phân hạng rủi ro. Kết quả đầu ra không dừng ở một giá trị xác suất. Để phục vụ nghiệp vụ, thang PD liên tục được ánh xạ sang bảy hạng rủi ro theo thông lệ xếp hạng tín dụng, trình bày tại Bảng 2.1.

Bảng 2.1: Thang phân hạng rủi ro theo xác suất vỡ nợ

Hạng	**Khoảng** PD	**Mức rủi ro**	**Định hướng xử lý**
AA	[0,00; 0,02)	Rất thấp	Ưu tiên duyệt, có thể ưu đãi lãi suất
A	[0,02; 0,05)	Thấp	Duyệt theo điều kiện chuẩn
BBB	[0,05; 0,08)	Trung bình thấp	Duyệt, có thể yêu cầu bổ sung điều kiện
BB	[0,08; 0,15)	Trung bình	Chuyển thẩm định thủ công
B	[0,15; 0,25)	Trung bình cao	Chuyển thẩm định thủ công
CCC	[0,25; 0,40)	Cao	Thẩm định kỹ hoặc từ chối
D	[0,40; 1,00]	Rất cao	Từ chối

2.1.2 Đặc trưng đầu vào và đầu ra của mô hình kiểm duyệt tín dụng

Đầu vào. Vectơ đặc trưng của mỗi hồ sơ được tổng hợp từ bốn nhóm nguồn dữ liệu đã phân tích ở mục 1.3.2, bổ sung thêm nhóm thứ năm gồm các biến tổ hợp và biến tương tác. Nguyên tắc bắt buộc đối với mọi đặc trưng là **tính đúng đắn theo thời điểm**: giá trị của mọi biến chỉ được tính từ dữ liệu tồn tại trước hoặc tại thời điểm nộp hồ sơ.

Đầu ra. Khác với bài toán phân loại thông thường chỉ trả về một nhãn, kết quả đầu ra của mô hình gồm năm thành phần, phản ánh vai trò hỗ trợ chứ không thay thế con người:

(1) **Xác suất vỡ nợ** PD $\in (0, 1)$ đã được hiệu chuẩn;

(2) **Hạng rủi ro** theo thang bảy mức ở Bảng 2.1;

(3) **Khuyến nghị** thuộc một trong ba giá trị: `APPROVE` (khuyến nghị duyệt), `REVIEW` (chuyển thẩm định thủ công), `REJECT` (khuyến nghị từ chối);

(4) **Danh sách lý do** (*reason codes*) gồm các luật nghiệp vụ bị vi phạm và các chỉ tiêu định lượng có ảnh hưởng lớn nhất tới kết quả;

(5) **Đề xuất điều kiện cấp tín dụng** gồm hạn mức, kỳ hạn và mức lãi suất theo rủi ro, trong trường hợp khuyến nghị duyệt.

Thành phần thứ tư (danh sách lý do) là điểm phân biệt giữa mô hình đóng vai trò hỗ trợ và mô hình ra quyết định tự động. Thiếu thành phần này, cán bộ tín dụng chỉ

nhận được một con số mà không có căn cứ để chấp nhận hay bác bỏ, dẫn tới hai thái cực đều không mong muốn: chấp nhận kết quả một cách thụ động hoặc bỏ qua hoàn toàn khuyến nghị của mô hình.

2.1.3 Yêu cầu kỹ thuật và pháp lý đối với mô hình kiểm duyệt tín dụng

2.1.3.1 Yêu cầu chức năng

Quy trình kiểm duyệt phải thực hiện được tám chức năng, tương ứng các chặng của một lượt xử lý hồ sơ. Trên *đường xử lý chính*, quy trình **tiếp nhận hồ sơ** qua giao diện dịch vụ và kiểm tra tính đầy đủ, hợp lệ của dữ liệu đầu vào; **tổng hợp dữ liệu** khách hàng, tài khoản, giao dịch và bản tin CIC về cấp độ hồ sơ; **xây dựng đặc trưng** theo đúng định nghĩa đã dùng khi huấn luyện, bảo đảm tính đúng đắn theo thời điểm; **chấm điểm rủi ro** bằng mô hình đã hiệu chuẩn; **áp dụng bộ luật nghiệp vụ**; và **đưa ra khuyến nghị** ba mức theo thứ tự ưu tiên xác định, kèm **danh sách lý do** và **đề xuất điều kiện cấp tín dụng** (hạn mức, kỳ hạn, lãi suất theo rủi ro).

Ngoài đường xử lý chính, quy trình cần hỗ trợ **chấm điểm theo lô** phục vụ tái đánh giá danh mục hiện hữu, và **giám sát mô hình** thông qua theo dõi trôi dạt dữ liệu cùng chất lượng dự báo theo thời gian.

2.1.3.2 Yêu cầu phi chức năng

- **Tính nhất quán:** cùng một hồ sơ với cùng dữ liệu đầu vào phải luôn cho cùng kết quả. Yêu cầu này đòi hỏi định nghĩa đặc trưng khi huấn luyện và khi chấm điểm phải trùng khớp tuyệt đối.
- **Thời gian phản hồi:** thời gian chấm điểm một hồ sơ phải đủ nhỏ để tích hợp được vào giao diện làm việc trực tuyến của cán bộ tín dụng. Đề án đặt mục tiêu thời gian xử lý một hồ sơ ở mức dưới 100 ms.
- **Khả năng hoạt động khi thiếu dữ liệu:** mô hình phải trả về kết quả cả khi không truy vấn được bản tin CIC. Trong trường hợp đó, kết quả là `REVIEW` kèm lý do, chứ không phải một thông báo lỗi.
- **Khả năng tái lập:** toàn bộ quy trình từ dữ liệu tới kết quả phải tái lập được với cùng một hạt giống ngẫu nhiên.

2.1.3.3 Yêu cầu pháp lý và tuân thủ

Mô hình sử dụng trong hoạt động cấp tín dụng chịu ràng buộc bởi các quy định pháp lý, trong đó năm nhóm yêu cầu sau ảnh hưởng trực tiếp tới thiết kế.

Giải trình được: mọi khuyến nghị phải kèm lý do có thể trình bày cho khách hàng và cơ quan quản lý. Yêu cầu này loại trừ khả năng sử dụng mô hình như một hộp đen, và là lý do đề án tích hợp cơ chế giải thích SHAP ngay trong thiết kế chứ không coi đó là phần bổ sung.

Không phân biệt đối xử: mô hình không được sử dụng các biến bị cấm hoặc biến đại diện cho chúng làm căn cứ phân biệt. Trong tập đặc trưng của đề án, biến giới tính được giữ lại phục vụ phân tích thống kê mô tả nhưng cần cân nhắc loại bỏ khi triển khai thực tế, tùy quy định áp dụng.

Tuân thủ định nghĩa phân loại nợ: nhãn rủi ro phải được xây dựng theo đúng quy định hiện hành [2], bảo đảm kết quả của mô hình tương thích với các báo cáo quản trị rủi ro và trích lập dự phòng.

Bảo mật dữ liệu cá nhân: đề án sử dụng dữ liệu mô phỏng; khi áp dụng trên dữ liệu thực, dữ liệu cần được ẩn danh và giới hạn quyền truy cập [1].

Thẩm quyền quyết định thuộc về con người: đây là ràng buộc bao trùm – mô hình cung cấp thông tin hỗ trợ, quyết định cấp tín dụng cuối cùng thuộc về người hoặc bộ phận có thẩm quyền theo phân cấp của tổ chức tín dụng.

2.2 Thu thập và tổng hợp dữ liệu

2.2.1 Nguồn dữ liệu tín dụng truyền thống và dữ liệu bổ sung

Hệ thống sử dụng năm bảng dữ liệu, chia thành hai nhóm.

Dữ liệu tín dụng truyền thống. Gồm ba nguồn đã được sử dụng từ lâu trong thẩm định tín dụng: (i) *hồ sơ khách hàng* chứa thông tin nhân khẩu học, nghề nghiệp và thu nhập khai báo; (ii) *đơn đề nghị vay* chứa tham số khoản vay; và (iii) *bản tin CIC* chứa lịch sử quan hệ tín dụng của khách hàng với toàn hệ thống tổ chức tín dụng.

Dữ liệu bổ sung. Gồm hai nguồn mà tổ chức tín dụng tự sở hữu nhưng thường chưa được khai thác đầy đủ trong thẩm định: (iv) *thông tin tài khoản* và (v) *lịch sử giao dịch*. Nhóm này có ba ưu thế: không phụ thuộc dịch vụ bên ngoài, phản ánh tình trạng

tài chính hiện tại thay vì lịch sử, và đặc biệt có giá trị với nhóm khách hàng thiếu lịch sử tín dụng – nhóm mà bản tin CIC gần như không cung cấp thông tin.

Bảng 2.2 mô tả lược đồ của năm nguồn dữ liệu.

Bảng 2.2: Lược đồ các bảng dữ liệu sử dụng trong đề án

Bảng	Khóa chính	Nội dung
`customers`	`customer_id`	Nhân khẩu học, nghề nghiệp, thu nhập khai báo, nơi cư trú và thời gian quan hệ với ngân hàng
`accounts`	`account_id`	Loại tài khoản, ngày mở, số dư bình quân ba tháng, số dư hiện tại, trạng thái
`transactions`	`txn_id`	Thời điểm, chiều giao dịch, số tiền, nhóm giao dịch và kênh thực hiện
`applications`	`application_id`	Thời điểm nộp, sản phẩm, số tiền đề nghị, kỳ hạn, lãi suất, mục đích vay, kênh tiếp nhận, tài sản bảo đảm và khoản trả góp
`cic_reports`	`report_id`	Thời điểm truy vấn, điểm CIC, nhóm nợ, số ngày quá hạn, số tổ chức có quan hệ, dư nợ, hạn mức và số lần truy vấn tín dụng

2.2.2 Thu thập và trích xuất dữ liệu khách hàng vay vốn

Đơn vị phân tích. Toàn bộ dữ liệu được quy về đơn vị phân tích là *hồ sơ vay*: mỗi dòng trong ma trận đặc trưng cuối cùng tương ứng một hồ sơ, được xác định bởi cặp (mã hồ sơ, thời điểm nộp). Việc chọn hồ sơ – thay vì khách hàng – làm đơn vị phân tích là cần thiết vì một khách hàng có thể nộp nhiều hồ sơ ở các thời điểm khác nhau, và tình trạng tài chính tại mỗi thời điểm là khác nhau.

Quy tắc ghép nối theo thời điểm. Đây là điểm kỹ thuật quan trọng nhất của bước thu thập dữ liệu. Với mỗi hồ sơ nộp tại thời điểm t, việc ghép nối các nguồn phải tuân thủ:

- Thông tin khách hàng và tài khoản: lấy trạng thái tại thời điểm t;
- Bản tin CIC: chỉ sử dụng bản tin được truy vấn tại thời điểm không muộn hơn t;
- Giao dịch: chỉ tổng hợp các giao dịch có thời điểm phát sinh nhỏ hơn hoặc bằng t.

Vi phạm bất kỳ quy tắc nào trong ba quy tắc trên đều dẫn tới rò rỉ thông tin từ tương lai. Đề án đưa quy tắc thứ nhất và thứ ba vào chính thuật toán tính đặc trưng (mục 2.4.3), còn quy tắc thứ hai được kiểm tra tường minh trong bước kiểm tra tính hợp lệ dữ liệu.

2.2.3 Phân tích thống kê mô tả tập dữ liệu tín dụng

Bước thống kê mô tả lập bảng đặc tả cho từng biến, gồm: kiểu dữ liệu, số quan sát hợp lệ, tỷ lệ giá trị khuyết, số giá trị phân biệt, và với biến định lượng là các phân vị 1%, 25%, 50%, 75%, 99% cùng trung bình và độ lệch chuẩn.

Bảng mô tả phục vụ ba quyết định ở các bước sau. Tỷ lệ khuyết của từng biến quyết định chiến lược điền khuyết và xác định biến nào cần loại bỏ do độ phủ quá thấp. Khoảng cách giữa phân vị 99% và giá trị lớn nhất cho biết mức độ nặng của đuôi phân phối, làm căn cứ quyết định có cần cắt ngọn hay không. Số giá trị phân biệt của biến định tính quyết định cách mã hóa: biến có ít hạng mục phù hợp với mã hóa one-hot, biến có nhiều hạng mục cần cơ chế xử lý riêng.

2.2.4 Phát hiện và xử lý dữ liệu ngoại lệ, dữ liệu không hợp lệ

Hai khái niệm dưới đây thường bị gộp chung nhưng có bản chất khác nhau và đòi hỏi cách xử lý khác nhau.

Dữ liệu không hợp lệ là dữ liệu *sai* – vi phạm ràng buộc nghiệp vụ hoặc ràng buộc logic. Ví dụ: tuổi khách hàng bằng 15, thu nhập âm, nhóm nợ xấu nhất trong 12 tháng lại tốt hơn nhóm nợ hiện tại, hoặc bản tin CIC được truy vấn sau thời điểm nộp hồ sơ. Đây là lỗi dữ liệu và phải được loại bỏ hoặc sửa chữa.

Giá trị ngoại lệ là giá trị nằm xa phần lớn quan sát nhưng *có thể đúng*. Một khách hàng có thu nhập gấp hai mươi lần trung vị hoặc một giao dịch trị giá vài tỷ đồng là bất thường về mặt thống kê nhưng hoàn toàn có thể có thật. Loại bỏ những quan sát này đồng nghĩa với việc loại bỏ chính nhóm khách hàng mà tổ chức tín dụng quan tâm.

Đề án xây dựng bộ mười lăm ràng buộc nghiệp vụ để phát hiện dữ liệu không hợp lệ, chia theo ba bảng dữ liệu chính. Bảng 2.3 trình bày các ràng buộc này.

Bảng 2.3: Bộ ràng buộc kiểm tra tính hợp lệ của dữ liệu

Bảng	Mã ràng buộc	Nội dung
customers	CUS_AGE_RANGE	Tuổi khách hàng trong khoảng 18–75
	CUS_INCOME_POSITIVE	Thu nhập khai báo lớn hơn 0
	CUS_TENURE_NONNEG	Thâm niên công việc không âm
	CUS_DEPENDENTS_RANGE	Số người phụ thuộc trong khoảng 0–10
applications	APP_AMOUNT_POSITIVE	Số tiền đề nghị vay lớn hơn 0
	APP_TENOR_RANGE	Kỳ hạn vay trong khoảng 3–360 tháng
	APP_RATE_RANGE	Lãi suất trong khoảng 0–40%/năm
	APP_INSTALLMENT_POSITIVE	Khoản trả góp hàng tháng lớn hơn 0
	APP_LTV_RANGE	Tỷ lệ vay trên giá trị tài sản bảo đảm không vượt 1,2
cic_reports	CIC_SCORE_RANGE	Điểm CIC trong khoảng 300–850
	CIC_GROUP_RANGE	Nhóm nợ trong khoảng 1–5
	CIC_GROUP_ORDER	Nhóm nợ xấu nhất 12 tháng không tốt hơn nhóm nợ hiện tại
	CIC_DPD_NONNEG	Số ngày quá hạn không âm
	CIC_UTILIZATION_RANGE	Tỷ lệ sử dụng hạn mức trong khoảng 0–2
	CIC_QUERY_BEFORE_APPLY	Bản tin CIC được truy vấn không muộn hơn thời điểm nộp hồ sơ

Kiểm chứng cơ chế phát hiện. Một bảng kết quả kiểm tra không ghi nhận vi phạm nào có thể tương ứng hai khả năng: dữ liệu thực sự sạch, hoặc cơ chế kiểm tra không hoạt động. Để phân biệt, đề án thực hiện phép **tiêm lỗi**: tạo một bản sao dữ liệu, cố ý đưa vào một tỷ lệ lỗi đã biết trước ứng với từng ràng buộc, rồi chạy lại cơ chế kiểm tra và đối chiếu số lỗi phát hiện được với số lỗi đã tiêm. Kết quả kiểm chứng được trình bày ở mục 3.1.3.4.

Xử lý giá trị ngoại lệ. Đối với giá trị ngoại lệ, đề án không loại bỏ quan sát mà áp dụng kỹ thuật **cắt ngọn** (*winsorize*) tại phân vị 1% và 99% học từ tập huấn luyện. Cách này giữ nguyên số quan sát – do đó không làm mất nhóm khách hàng đặc thù – đồng thời hạn chế ảnh hưởng quá mức của vài giá trị cực trị lên các mô hình nhạy cảm với thang đo như hồi quy logistic, SVM và mạng nơ-ron. Việc phát hiện ngoại lệ sử dụng quy tắc $k \times \text{IQR}$ với $k = 3$ thay vì giá trị thông thường $k = 1{,}5$, bởi các biến tiền tệ trong dữ liệu tín dụng có phân phối lệch phải mạnh; ngưỡng $1{,}5 \times \text{IQR}$ sẽ đánh dấu một tỷ lệ rất lớn quan sát là ngoại lệ mà không mang lại thông tin hữu ích.

2.2.5 Phân chia dữ liệu theo khoảng thời gian và nhóm khách hàng

Đề án sử dụng hai chiến lược phân chia với hai mục đích khác nhau.

Phân chia theo thời gian (chính). Dữ liệu được sắp xếp theo thời điểm nộp hồ sơ và chia thành ba đoạn liên tiếp: 70% đầu làm tập huấn luyện, 15% tiếp theo làm tập kiểm định, 15% cuối làm tập kiểm thử. Chiến lược này mô phỏng đúng điều kiện vận hành thực tế – mô hình luôn được huấn luyện trên quá khứ và áp dụng cho tương lai – nên phản ánh cả ảnh hưởng của trôi dạt dữ liệu.

Phân chia theo nhóm khách hàng (phương án bổ sung). Toàn bộ hồ sơ của một khách hàng được đặt vào cùng một tập. Chiến lược này loại trừ rò rỉ thông tin theo khách hàng nhưng không phản ánh trôi dạt theo thời gian, nên chỉ phù hợp khi tập dữ liệu có nhiều khách hàng nộp lặp nhiều hồ sơ. Hệ thống hiện thực sẵn phương án này để có thể đối chiếu khi áp dụng trên dữ liệu thực; toàn bộ kết quả thực nghiệm trình bày ở Chương 3 sử dụng cách chia theo thời gian.

Tách riêng vai trò trong tập huấn luyện. Với các mô hình có cơ chế dừng sớm (gradient boosting), cần một tập dữ liệu độc lập để đánh giá tiêu chí dừng. Nếu lấy tập này từ tập kiểm định, tập kiểm định sẽ đồng thời phục vụ hai mục đích – dừng sớm và hiệu chuẩn xác suất – làm suy giảm tính độc lập của cả hai. Đề án tách 15% cuối của tập huấn luyện thành tập dừng sớm riêng biệt, cho cấu trúc bốn phần:

Tập	Tỷ trọng	Vai trò	Sử dụng
`train_fit`	59,5%	Huấn luyện	Mọi mô hình
`train_es`	10,5%	Dừng sớm	Mô hình boosting
`valid`	15,0%	Hiệu chuẩn xác suất, chọn ngưỡng	Mọi mô hình
`test`	15,0%	Đánh giá cuối cùng	Chỉ dùng một lần

Nguyên tắc quan trọng nhất là tập `test` chỉ được sử dụng *một lần duy nhất* ở bước báo cáo kết quả cuối cùng. Mọi quyết định về lựa chọn mô hình, siêu tham số và ngưỡng đều dựa trên tập `valid`.

2.3 Tiền xử lý và làm sạch dữ liệu

Nguyên tắc xuyên suốt của toàn bộ khối tiền xử lý: **mọi tham số biến đổi chỉ được ước lượng trên tập huấn luyện** rồi áp dụng cho các tập còn lại. Nếu ước lượng trung vị, trung bình hay phân vị trên toàn bộ dữ liệu, thông tin từ tập kiểm thử rò rỉ vào quá trình huấn luyện và kết quả đánh giá sẽ lạc quan hơn thực tế.

2.3.1 Xử lý giá trị khuyết thiếu

Trong dữ liệu tín dụng, giá trị khuyết không đồng nghĩa với lỗi thu thập. Đề án phân biệt hai loại và xử lý theo hai cách khác nhau.

Khuyết mang thông tin. Khách hàng chưa từng có quan hệ tín dụng (*thin-file*) sẽ có toàn bộ trường CIC trống. Bản thân trạng thái "không có lịch sử tín dụng" là một tín hiệu rủi ro riêng biệt. Cách xử lý đúng gồm hai phần: điền giá trị theo *quy ước nghiệp vụ* và bổ sung *biến chỉ báo khuyết* để mô hình tự học mức rủi ro thực tế của nhóm này. Quy ước điền được chọn theo hướng trung tính – không giả định khách hàng tốt cũng không giả định khách hàng xấu: điểm CIC đặt bằng 600 (mức giữa của thang 300–850), nhóm nợ đặt bằng 1 (chưa phát sinh nợ), các chỉ tiêu đếm và dư nợ đặt bằng 0.

Khuyết ngẫu nhiên. Với các trường như thu nhập khai báo hay thâm niên công việc, giá trị khuyết phản ánh việc khách hàng không cung cấp thông tin. Đề án điền bằng *trung vị của tập huấn luyện* kèm biến chỉ báo. Trung vị được chọn thay vì trung bình vì ít nhạy cảm với đuôi phân phối lệch phải điển hình của các biến tiền tệ.

Việc điền theo thống kê được thực hiện *bên trong* pipeline huấn luyện của scikit-learn, nhờ đó tham số điền được ước lượng lại ở mỗi lần khớp mô hình trong kiểm định chéo, loại bỏ hoàn toàn nguy cơ rò rỉ.

2.3.2 Phát hiện và xử lý dữ liệu ngoại lệ

Quy trình xử lý ngoại lệ gồm hai bước. Bước thứ nhất – thống kê – sử dụng quy tắc $3 \times \text{IQR}$ để lập bảng các biến có giá trị nằm ngoài ngưỡng, kèm tỷ lệ và giá trị các phân vị biên. Bảng này là cơ sở để đánh giá mức độ lệch của từng biến.

Bước thứ hai – xử lý – áp dụng phép cắt ngọn tại phân vị 1% và 99%. Ngưỡng cắt được học từ tập huấn luyện và áp dụng nguyên vẹn cho tập kiểm định và tập kiểm

thử; nếu học lại trên từng tập, phép biến đổi sẽ khác nhau giữa các tập và làm sai lệch kết quả đánh giá.

Phép cắt ngọn chỉ cần thiết với nhóm mô hình nhạy cảm với thang đo. Các mô hình dựa trên cây chia theo ngưỡng nên bất biến với phép biến đổi đơn điệu, do đó không chịu ảnh hưởng của giá trị cực trị theo cách tương tự.

2.3.3 Chuẩn hóa và mã hóa biến định tính/định lượng

Mỗi họ mô hình có yêu cầu khác nhau về dạng đầu vào, nên đề án sử dụng bốn phương án biến đổi song song thay vì một phương án chung (Bảng 2.4).

Bảng 2.4: Bốn phương án biến đổi dữ liệu theo yêu cầu của từng họ mô hình

Phương án	Nội dung biến đổi	Mô hình áp dụng và lý do
`numeric_ohe`	Điền khuyết bằng trung vị, chuẩn hóa z-score cho biến định lượng; mã hóa one-hot cho biến định tính	Hồi quy logistic, SVM, mạng nơ-ron. Các mô hình dựa trên khoảng cách hoặc gradient nhạy cảm với chênh lệch thang đo giữa các biến
`ordinal`	Điền khuyết; mã hóa thứ tự cho biến định tính	Cây quyết định, rừng ngẫu nhiên, Extra Trees, Hist Gradient Boosting. Cây chia theo ngưỡng nên bất biến với phép biến đổi đơn điệu; chuẩn hóa không cần thiết và làm mất khả năng diễn giải ngưỡng
`native_cat`	Giữ nguyên biến định tính ở dạng hạng mục	XGBoost, LightGBM, CatBoost. Các thư viện này có cơ chế xử lý biến định tính riêng, hiệu quả hơn mã hóa bên ngoài
`woe`	Rời rạc hóa và thay mỗi khoảng bằng giá trị WOE	Mô hình thẻ điểm. Đưa mọi biến về thang log-odds và cho phép áp ràng buộc đơn điệu

Toàn bộ phép biến đổi được gói trong cấu trúc `ColumnTransformer` của scikit-learn, bảo đảm tham số chỉ được ước lượng trên dữ liệu huấn luyện của từng lần khớp mô hình.

Xử lý hạng mục chưa từng xuất hiện. Khi chấm điểm một hồ sơ mới, biến định tính có thể nhận giá trị chưa từng xuất hiện trong tập huấn luyện. Đề án "đóng băng" danh mục hạng mục theo tập huấn luyện và lưu kèm mô hình; hạng mục lạ được quy

về giá trị khuyết. Đây là hành vi đúng khi triển khai: mô hình không có cơ sở nào để đánh giá một hạng mục chưa từng quan sát.

2.3.4 Phân chia tập dữ liệu huấn luyện, kiểm thử

Cấu trúc bốn tập dữ liệu đã được trình bày ở mục 2.2.5. Nội dung cần làm rõ ở đây là **thứ tự thao tác** giữa việc phân chia và các phép tiền xử lý:

gán nhãn → loại hồ sơ chưa đủ cửa sổ quan sát → chia tập → học tham số biến đổi trên tập huấn luyện → áp dụng cho các tập còn lại.

Việc phân chia phải diễn ra *trước* mọi phép biến đổi có ước lượng tham số. Nếu đảo ngược, chẳng hạn chuẩn hóa trên toàn bộ dữ liệu rồi mới chia tập, trung bình và độ lệch chuẩn dùng để chuẩn hóa sẽ chứa thông tin của tập kiểm thử; mô hình khi đó được đánh giá trên dữ liệu mà nó đã gián tiếp tiếp xúc, cho kết quả lạc quan hơn thực tế.

2.4 Trích xuất và lựa chọn đặc trưng

2.4.1 Trích xuất nhóm đặc trưng thông tin cá nhân và tài chính

Nhóm này gồm mười lăm đặc trưng lấy trực tiếp từ hồ sơ khách hàng và thông tin tài khoản, chia thành ba mảng: *nhân khẩu học* (tuổi, giới tính, tình trạng hôn nhân, số người phụ thuộc, trình độ học vấn, tỉnh/thành cư trú, hình thức nhà ở); *nghề nghiệp và thu nhập* (nghề nghiệp, loại hình tổ chức làm việc, thâm niên công việc, thu nhập khai báo); và *quan hệ với ngân hàng* (thời gian quan hệ, việc có tài khoản nhận lương, số tài khoản đang mở, tổng số dư bình quân ba tháng). Danh mục đầy đủ kèm mô tả từng đặc trưng được liệt kê tại Phụ lục C.

Mảng thứ ba phản ánh *mức độ gắn bó* của khách hàng với tổ chức tín dụng, yếu tố có giá trị dự báo nhưng không xuất hiện trong bộ quy tắc thẩm định truyền thống.

2.4.2 Trích xuất nhóm đặc trưng lịch sử tín dụng và quan hệ CIC

Nhóm này gồm mười sáu đặc trưng lấy từ bản tin CIC, phản ánh bốn khía cạnh của quan hệ tín dụng: *mức độ tín nhiệm* (điểm CIC), *lịch sử trả nợ* (nhóm nợ hiện tại, nhóm nợ xấu nhất 12 tháng, số ngày quá hạn tối đa, nợ đã xử lý rủi ro, số tổ chức từng phát sinh nợ xấu), *mức độ và cơ cấu dư nợ* (số tổ chức đang có quan hệ, số hợp đồng

còn hiệu lực và đã tất toán, tổng dư nợ, tỷ lệ sử dụng hạn mức, nghĩa vụ trả nợ hàng tháng, độ dài lịch sử tín dụng), và *mức độ tìm kiếm tín dụng* (số lần truy vấn trong 3 tháng).

Bổ sung vào nhóm là hai biến chỉ báo tạo ra ở bước xử lý khuyết, phản ánh hai tình huống khác nhau về bản chất: khách hàng *không có* lịch sử tín dụng và trường hợp *không truy vấn được* dữ liệu.

2.4.3 Trích xuất nhóm đặc trưng hành vi và biến tương tác

2.4.3.1 Đặc trưng hành vi theo cửa sổ thời gian

Từ lịch sử giao dịch, đề án tính hai mươi ba độ đo trên mỗi cửa sổ thời gian $W \in \{7, 30, 90, 180\}$ ngày, thuộc bốn mảng: *quy mô hoạt động* (số giao dịch, dòng tiền vào, dòng tiền ra, dòng tiền thuần, giá trị giao dịch trung bình); *mức biến động* (độ lệch chuẩn và hệ số biến thiên của giá trị giao dịch); *cơ cấu dòng tiền theo mục đích* (nhận lương, trả nợ, chi tiêu nhóm rủi ro, rút tiền mặt, thương mại điện tử, hóa đơn tiện ích); và *dấu hiệu hành vi* (giao dịch ban đêm, giao dịch giá trị lớn, giao dịch qua kênh di động), cùng năm tỷ số phái sinh từ các độ đo trên.

Bổ sung thêm bảy đặc trưng không phụ thuộc cửa sổ: số ngày kể từ giao dịch gần nhất, ba biến xu thế so sánh cửa sổ ngắn với cửa sổ dài, tỷ lệ dòng tiền vào thực tế so với thu nhập khai báo, mức độ đều đặn của việc nhận lương và độ ổn định thu nhập.

Trong số này, biến *tỷ lệ dòng tiền vào thực tế so với thu nhập khai báo* có ý nghĩa nghiệp vụ riêng: nó cung cấp một phép kiểm chứng độc lập cho thông tin thu nhập khách hàng tự khai, công việc mà quy trình thẩm định truyền thống phải thực hiện thủ công qua đối chiếu chứng từ.

2.4.3.2 Thuật toán bảo đảm tính đúng đắn theo thời điểm

Yêu cầu tính đúng đắn theo thời điểm đặt ra một thách thức về tính toán. Cách làm trực tiếp, tức với mỗi hồ sơ lọc toàn bộ giao dịch của khách hàng trong cửa sổ rồi tổng hợp – có độ phức tạp $O(N \times |W| \times \bar{m})$ với N là số hồ sơ, $|W|$ là số cửa sổ và $\bar{m}$ là số giao dịch trung bình mỗi khách hàng. Với hàng chục nghìn hồ sơ và hàng triệu giao dịch, chi phí này không chấp nhận được.

Đề án sử dụng kỹ thuật **luỹ kế theo nhóm kết hợp ghép gần nhất theo thời gian**. Với mỗi độ đo m, gọi $C_m(i, t)$ là tổng luỹ kế của độ đo đó cho khách hàng i tính

đến thời điểm t. Khi đó tổng của độ đo trong cửa sổ $(t - W, t]$ được tính bằng hiệu hai giá trị luỹ kế:

$$S_m(i, t, W) = C_m(i, t) - C_m(i, t - W). \tag{2.2}$$

Hai giá trị luỹ kế được truy xuất bằng phép ghép gần nhất hướng lùi (`merge_asof`), tương đương thao tác "tìm bản ghi gần nhất không vượt quá mốc thời gian" với độ phức tạp tuyến tính sau khi dữ liệu đã được sắp xếp. Nhờ đó, toàn bộ đặc trưng cửa sổ cho N hồ sơ được tính bằng $2 \times |W|$ phép ghép vectơ hóa thay vì $N \times |W|$ truy vấn riêng lẻ.

Phương pháp này còn có một ưu điểm về mặt đúng đắn: vì công thức chỉ sử dụng giá trị luỹ kế tại hai mốc thời gian, nó *không thể* vô tình bao gồm giao dịch phát sinh sau thời điểm nộp hồ sơ. Tính đúng đắn theo thời điểm được bảo đảm bởi chính cấu trúc thuật toán chứ không phụ thuộc vào việc kiểm tra bổ sung.

2.4.3.3 Biến tổ hợp và biến tương tác

Mười ba biến phái sinh được xây dựng nhằm biểu diễn các chỉ tiêu nghiệp vụ then chốt mà không biến gốc nào thể hiện được:

Biến `disposable_income` sử dụng mô hình chi phí sinh hoạt gồm hai thành phần: một mức sàn cố định phụ thuộc số người phụ thuộc, và một phần tỷ lệ thuận với thu nhập. Cách mô hình hóa này khắc phục nhược điểm của việc dùng một mức cố định duy nhất, vốn quá khắt khe với nhóm thu nhập thấp và quá nới lỏng với nhóm thu nhập cao.

2.4.4 Đánh giá mức độ quan trọng của các đặc trưng

Đề án sử dụng ba phương pháp bổ trợ nhau để đánh giá tầm quan trọng của đặc trưng, mỗi phương pháp trả lời một câu hỏi khác nhau.

Information Value – năng lực dự báo đơn biến. Trả lời câu hỏi: mỗi đặc trưng, xét riêng lẻ, phân biệt hồ sơ tốt và xấu tốt đến mức nào? Ưu điểm là chi phí tính toán thấp và không phụ thuộc mô hình. Hạn chế là không tính đến tương tác: một biến có IV thấp vẫn có thể có giá trị khi kết hợp với biến khác.

Bảng 2.5: Các biến tổ hợp và biến tương tác

Biến	Công thức	Ý nghĩa nghiệp vụ
`dti`	$\frac{\text{Trả góp mới + Nợ hiện hữu}}{\text{Thu nhập}}$	Tổng gánh nặng nợ trên thu nhập, chỉ tiêu trung tâm của đánh giá khả năng trả nợ
`pti`	$\frac{\text{trả góp khoản vay mới}}{\text{thu nhập}}$	Gánh nặng riêng của khoản vay đang xét
`disposable_income`	thu nhập − trả nợ − chi phí sinh hoạt	Thu nhập còn lại thực tế sau khi trừ nghĩa vụ và chi phí tối thiểu
`credit_history_ratio`	$\frac{\text{độ dài lịch sử tín dụng}}{\text{số tháng từ tuổi 18}}$	Mức độ tham gia thị trường tín dụng so với độ tuổi
`dpd_x_institutions`	số ngày quá hạn × số tổ chức	Biến tương tác: quá hạn tại nhiều tổ chức nghiêm trọng hơn quá hạn tại một tổ chức
`high_dti_short_tenure`	$\mathbb{1}[\text{DTI} > 0{,}5 \wedge \text{thâm niên} < 12]$	Cờ rủi ro kết hợp: gánh nặng nợ cao đi kèm công việc chưa ổn định
`income_verification_ratio`	$\frac{\text{dòng tiền vào 30 ngày}}{\text{thu nhập khai báo}}$	Kiểm chứng độc lập thông tin thu nhập tự khai

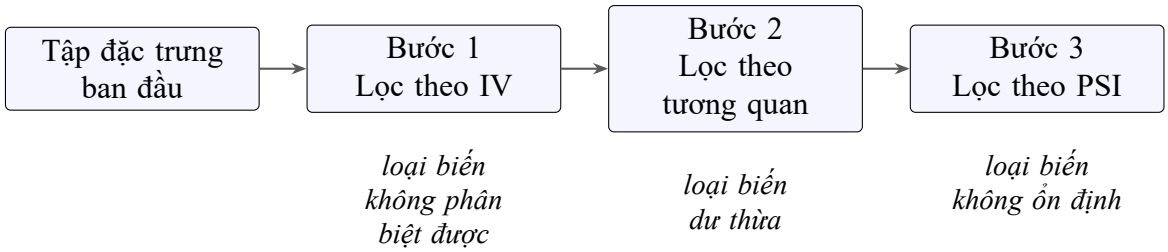
SHAP – đóng góp trong mô hình đã huấn luyện. Trả lời câu hỏi: trong mô hình cụ thể đã được huấn luyện, đặc trưng nào thực sự chi phối kết quả dự báo? Phương pháp này tính đến tương tác và cho kết quả ở cả cấp độ toàn cục lẫn cấp độ từng hồ sơ.

Phép hoán vị – kiểm chứng chéo. Trả lời câu hỏi: nếu phá vỡ quan hệ giữa một đặc trưng và nhãn bằng cách xáo trộn ngẫu nhiên giá trị của nó, chất lượng dự báo suy giảm bao nhiêu? Phương pháp này độc lập với cấu trúc nội bộ của mô hình, nên dùng làm phép kiểm chứng chéo cho kết quả SHAP.

2.4.5 Lựa chọn tập đặc trưng tối ưu cho mô hình

Tập đặc trưng ban đầu gồm 154 biến, trong đó nhiều biến được sinh theo cùng một mẫu trên bốn cửa sổ thời gian khác nhau nên tương quan mạnh với nhau. Đề án áp dụng quy trình lọc ba bước nối tiếp, sắp xếp từ rẻ đến đắt về chi phí tính toán (Hình 2.1).

Bước 1 – lọc theo năng lực dự báo. Loại các đặc trưng có IV $< 0{,}02$, ngưỡng mà theo thực hành ngành tương ứng với "không có khả năng phân biệt". Ngưỡng trên



Hình 2.1: Quy trình lựa chọn tập đặc trưng qua ba bộ lọc nối tiếp

được đặt ở mức IV = 2,0 để phát hiện trường hợp rò rỉ nhãn. Lưu ý rằng nhóm đặc trưng CIC vốn có IV cao (khoảng 0,9–1,3) do phản ánh trực tiếp lịch sử trả nợ; các biến này đã được kiểm tra tính đúng đắn theo thời điểm nên IV cao là bản chất của dữ liệu chứ không phải dấu hiệu rò rỉ.

Bước 2 – lọc theo tương quan. Trong mỗi cặp biến có hệ số tương quan tuyệt đối vượt 0,95, giữ lại biến có IV cao hơn. Bước này chủ yếu loại bỏ các biến trùng lặp giữa các cửa sổ thời gian liền kề.

Bước 3 – lọc theo độ ổn định. Loại các đặc trưng có PSI > 0,25 giữa giai đoạn huấn luyện và giai đoạn kiểm thử. Mô hình phụ thuộc vào biến không ổn định sẽ suy giảm nhanh khi vận hành.

2.5 Xây dựng nhãn và xác định quy tắc phê duyệt

2.5.1 Định nghĩa trạng thái rủi ro và tiêu chuẩn nợ xấu

Tiêu chuẩn nợ xấu. Đề án sử dụng định nghĩa theo quy định phân loại nợ hiện hành [2]: khoản vay bị coi là nợ xấu khi được phân vào nhóm 3, 4 hoặc 5, tương ứng với số ngày quá hạn từ 90 ngày trở lên. Định nghĩa này trùng với ngưỡng mà chuẩn mực Basel [33] sử dụng cho khái niệm vỡ nợ, nhờ đó kết quả nghiên cứu có thể đối chiếu với các công trình quốc tế.

Cửa sổ quan sát. Một hồ sơ chỉ được gán nhãn sau khi đã trải qua cửa sổ quan sát hiệu quả trả nợ đủ dài. Đề án chọn cửa sổ 12 tháng dựa trên hai căn cứ đối lập nhau cần cân bằng: cửa sổ quá ngắn bỏ sót phần lớn trường hợp vỡ nợ muộn, làm tỷ lệ nợ xấu quan sát được thấp hơn thực tế và mô hình lệch về phía lạc quan; cửa sổ quá dài

buộc phải loại nhiều hồ sơ gần đây khỏi tập huấn luyện, làm dữ liệu cũ đi và mô hình kém phản ánh điều kiện hiện tại.

Căn cứ định lượng cho lựa chọn này là **phân tích vintage**: đo tỷ lệ nợ xấu tích luỹ theo từng tháng kể từ thời điểm cấp tín dụng. Điểm mà đường cong tích luỹ bắt đầu đi ngang chính là độ dài cửa sổ hợp lý. Kết quả phân tích được trình bày ở mục 3.1.3.5.

2.5.2 Phương pháp gán nhãn dữ liệu hồ sơ vay

Quy trình gán nhãn gồm ba bước:

(1) **Xác định thời điểm kết thúc cửa sổ quan sát** cho từng hồ sơ, bằng thời điểm cấp tín dụng cộng với độ dài cửa sổ.

(2) **Phân loại trạng thái.** Hồ sơ có thời điểm kết thúc cửa sổ vượt quá mốc trích xuất dữ liệu được gán `INDETERMINATE`. Trong số các hồ sơ còn lại, hồ sơ phát sinh nợ xấu *trong* cửa sổ được gán `BAD`, phần còn lại được gán `GOOD`. Trường hợp vỡ nợ muộn hơn cửa sổ không được tính là `BAD`, vì nằm ngoài phạm vi dự báo của mô hình.

(3) **Loại nhóm chưa xác định** khỏi tập dữ liệu mô hình hóa.

2.5.3 Xác định điểm cắt phê duyệt

2.5.3.1 Vì sao ngưỡng 0,5 không phù hợp

Ngưỡng mặc định 0,5 của bài toán phân loại nhị phân không phù hợp với bài toán tín dụng vì hai lý do. Thứ nhất, dữ liệu mất cân bằng: với tỷ lệ nợ xấu khoảng 15%, rất ít hồ sơ có PD vượt 0,5, nên dùng ngưỡng này gần như duyệt toàn bộ. Thứ hai, chi phí hai loại sai lầm rất khác nhau: bỏ sót một hồ sơ xấu gây tổn thất bằng một phần đáng kể dư nợ, trong khi từ chối sai một hồ sơ tốt chỉ làm mất phần lãi biên.

2.5.3.2 Ba tiêu chí xác định điểm cắt

Đề án hiện thực ba phương pháp xác định điểm cắt, tương ứng ba cách đặt bài toán khác nhau trong thực tế nghiệp vụ.

Tiêu chí 1 – tối thiểu chi phí kỳ vọng. Chọn ngưỡng τ làm cực tiểu chi phí kỳ vọng:

$$\tau^* = \arg\min_{\tau} \left[c_{FN} \cdot \mathrm{FN}(\tau) + c_{FP} \cdot \mathrm{FP}(\tau) \right] / n, \tag{2.3}$$

với $c_{FN} : c_{FP} = 12 : 1$. Áp dụng khi tổ chức tín dụng ước lượng được chi phí của hai loại sai lầm.

Tiêu chí 2 – đạt tỷ lệ duyệt mục tiêu. Chọn ngưỡng bằng phân vị tương ứng với tỷ lệ duyệt mong muốn. Áp dụng khi ngưỡng bị ràng buộc bởi kế hoạch tăng trưởng dư nợ.

Tiêu chí 3 – bảo đảm trần nợ xấu. Chọn ngưỡng cao nhất mà tỷ lệ nợ xấu trong nhóm được duyệt vẫn dưới mức trần cho phép. Chọn ngưỡng *cao nhất* thỏa mãn ràng buộc nhằm tối đa hóa quy mô cấp tín dụng trong giới hạn khẩu vị rủi ro.

2.5.3.3 Hai ngưỡng cho ba vùng quyết định

Hệ thống hỗ trợ kiểm duyệt cần **hai** ngưỡng chứ không phải một, chia thang PD thành ba vùng:

$$\text{Khuyến nghị} = \begin{cases} \texttt{APPROVE}, & \mathrm{PD} \le \tau_{\text{duyệt}}, \\ \texttt{REVIEW}, & \tau_{\text{duyệt}} < \mathrm{PD} \le \tau_{\text{từ chối}}, \\ \texttt{REJECT}, & \mathrm{PD} > \tau_{\text{từ chối}}. \end{cases} \tag{2.4}$$

Hai ngưỡng được đặt đối xứng quanh điểm cắt tối ưu chi phí, sao cho tỷ lệ hồ sơ rơi vào vùng chuyển thẩm định xấp xỉ một mức mục tiêu định trước. Tỷ lệ này là *tham số chính sách* chứ không phải tham số kỹ thuật: tăng lên thì mức độ an toàn cao hơn nhưng khối lượng thẩm định thủ công lớn hơn; giảm xuống thì tự động hóa cao hơn nhưng rủi ro khuyến nghị sai tăng. Đề án đặt mục tiêu vùng thẩm định ở mức 20%.

2.6 Thiết kế mô hình học máy kiểm duyệt tín dụng

2.6.1 Lựa chọn các thuật toán học máy dự kiến

Đề án lựa chọn mười hai mô hình để so sánh, trong đó năm thuật toán là trọng tâm nghiên cứu – hồi quy logistic, cây quyết định, rừng ngẫu nhiên, máy vectơ hỗ trợ và gradient boosting – và bảy mô hình còn lại là các biến thể hiện đại của cùng những họ

thuật toán đó, đưa vào nhằm đánh giá xem mức cải thiện thực tế có tương xứng với chi phí triển khai hay không (Bảng 2.6).

Bảng 2.6: Danh mục mô hình được thiết kế và so sánh

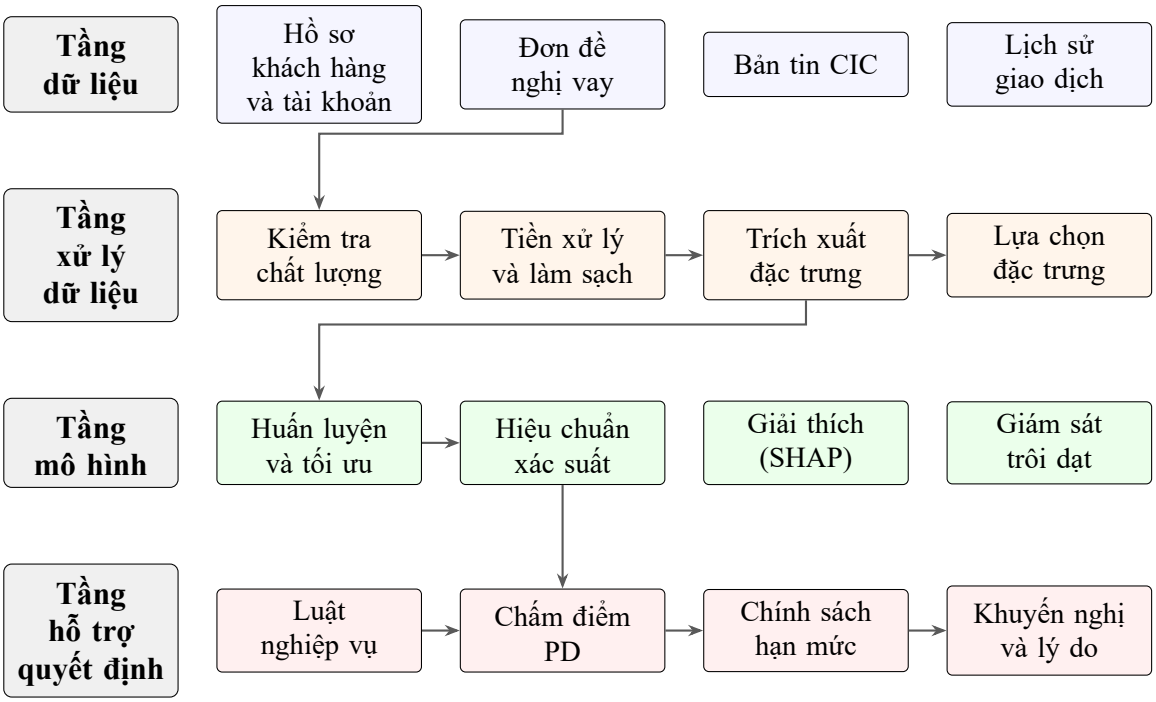
TT	Mô hình	Nhóm	Vai trò trong so sánh
1	Hồi quy logistic	Tuyến tính	Mô hình cơ sở tham chiếu
2	Thẻ điểm WOE	Tuyến tính	Chuẩn mực thực tiễn ngân hàng
3	Cây quyết định (CART)	Cây đơn	Mô hình phi tuyến đơn giản nhất
4	Rừng ngẫu nhiên	Bagging	Học tập hợp song song
5	Extra Trees	Bagging	Biến thể tăng mức ngẫu nhiên hóa
6	Máy vectơ hỗ trợ	SVM	Tiếp cận theo lề cực đại
7	Hist Gradient Boosting	Boosting	Học tập hợp tuần tự
8	XGBoost	Boosting	Biến thể có điều chuẩn tường minh
9	LightGBM	Boosting	Biến thể sinh cây theo chiều lá
10	CatBoost	Boosting	Biến thể xử lý biến định tính
11	Mạng nơ-ron (MLP)	Mạng nơ-ron	Mô hình phi tuyến toàn cục
12	Kết hợp xếp tầng	Ensemble	Tổ hợp các mô hình cơ sở khác biệt

Ghi chú về hiện thực SVM. Như đã phân tích ở mục 1.4.4, SVM hạt nhân có chi phí huấn luyện từ $O(n^2)$ đến $O(n^3)$, không khả thi với tập huấn luyện hàng chục nghìn hồ sơ. Đề án sử dụng phép xấp xỉ Nystroem với 600 điểm mốc, sau đó huấn luyện SVM tuyến tính trên không gian đặc trưng xấp xỉ. Xác suất đầu ra được quy đổi từ giá trị hàm quyết định bằng phương pháp Platt qua kiểm định chéo ba tầng.

2.6.2 Thiết kế kiến trúc tổng thể của mô hình học máy hỗ trợ ra quyết định

2.6.2.1 Kiến trúc phân tầng

Hệ thống được tổ chức thành bốn tầng (Hình 2.2), tách bạch giữa phần *xây dựng mô hình* (thực hiện định kỳ, ngoại tuyến) và phần *sử dụng mô hình* (thực hiện mỗi khi có hồ sơ mới).



Hình 2.2: Kiến trúc phân tầng của mô hình hỗ trợ kiểm duyệt tín dụng

2.6.2.2 Logic tổng hợp khuyến nghị

Khuyến nghị cuối cùng là kết quả của một chuỗi ưu tiên rõ ràng, trong đó luật nghiệp vụ có quyền phủ quyết cao hơn mô hình thống kê:

1. Có luật loại trừ cứng bị vi phạm ⇒ `REJECT`
2. Mô hình gặp lỗi khi chấm điểm ⇒ `REVIEW`
3. Không truy vấn được dữ liệu CIC ⇒ `REVIEW`
4. PD $> \tau_{\text{từ chối}}$ ⇒ `REJECT`
5. Có luật yêu cầu thẩm định bị vi phạm ⇒ `REVIEW`
6. PD $> \tau_{\text{duyệt}}$ ⇒ `REVIEW`
7. Hạn mức tính được bằng 0 ⇒ `REJECT`
8. Các trường hợp còn lại ⇒ `APPROVE`

Thứ tự này phản ánh một nguyên tắc thiết kế: *ràng buộc tuân thủ đứng trước đánh giá thống kê*. Một hồ sơ vi phạm điều kiện pháp lý hoặc chính sách phải bị từ chối bất kể mô hình cho điểm rủi ro thấp đến đâu. Ngược lại, khi hệ thống không đủ thông tin hoặc không đủ chắc chắn, kết quả mặc định là chuyển cho con người xem xét chứ không phải tự quyết.

2.6.2.3 Bộ luật nghiệp vụ

Đề án xây dựng bộ luật gồm hai mươi mốt luật, chia theo sáu nhóm và ba mức hành động (Bảng 2.7).

Bảng 2.7: Cơ cấu bộ luật nghiệp vụ theo nhóm và mức hành động

Nhóm luật	Nội dung kiểm tra	Ví dụ
Điều kiện vay	Độ tuổi, thu nhập tối thiểu, thâm niên công việc	Tuổi ngoài khoảng 20–62 ⇒ từ chối
Lịch sử tín dụng	Nhóm nợ, số ngày quá hạn, nợ đã xử lý rủi ro	Nhóm nợ xấu nhất 12 tháng > 2 ⇒ từ chối
Khả năng trả nợ	DTI, thu nhập còn lại sau trả nợ	DTI > 0,6 ⇒ từ chối
Tài sản bảo đảm	Tỷ lệ vay trên giá trị tài sản	LTV > 0,85 ⇒ chuyển thẩm định
Chất lượng dữ liệu	Thiếu dữ liệu CIC, khách hàng thin-file	Không có bản tin CIC ⇒ chuyển thẩm định
Dấu hiệu bất thường	Số lần truy vấn tín dụng, hành vi giao dịch	Truy vấn tín dụng > 5 lần trong 3 tháng ⇒ chuyển thẩm định

Ba mức hành động gồm: `HARD_REJECT` (từ chối, có quyền phủ quyết cao nhất), `REVIEW` (buộc chuyển thẩm định thủ công) và `WARNING` (ghi nhận vào danh sách lý do nhưng không thay đổi khuyến nghị).

2.6.3 Xác định các hàm mất mát

Hàm mất mát huấn luyện. Toàn bộ mô hình sử dụng hàm entropy chéo nhị phân (1.4). Lựa chọn này không phải quy ước tùy tiện: log-loss là quy tắc chấm điểm chính đáng, nghĩa là kỳ vọng của nó đạt cực tiểu khi và chỉ khi giá trị dự báo bằng đúng xác suất thật. Đặc điểm này có ý nghĩa quyết định vì hệ thống sử dụng giá trị PD trực tiếp chứ không chỉ dùng để xếp hạng.

Bù mất cân bằng lớp. Với tỷ lệ nợ xấu khoảng 15%, hàm mất mát được bổ sung trọng số lớp:

$$\ell_w(y,p) = -\left[\, w_1\, y \log p + w_0\,(1-y)\log(1-p)\,\right], \qquad w_1 = \frac{n_0}{n_1},\ w_0 = 1, \tag{2.5}$$

trong đó n_0, n_1 là số quan sát của lớp âm và lớp dương. Việc dùng trọng số lớp làm xác suất đầu ra bị lệch hệ thống về phía cao hơn thực tế; đây là lý do bước hiệu chuẩn xác suất trở thành bắt buộc chứ không phải tùy chọn.

Hàm chi phí nghiệp vụ. Tách biệt với hàm mất mát huấn luyện, hàm chi phí nghiệp vụ được dùng ở bước chọn ngưỡng quyết định:

$$\mathscr{C}(\tau) = \frac{1}{n}\Big[c_{FN} \cdot \mathrm{FN}(\tau) + c_{FP} \cdot \mathrm{FP}(\tau)\Big]. \tag{2.6}$$

Việc tách hai hàm này là một lựa chọn thiết kế có chủ đích: mô hình được huấn luyện để ước lượng xác suất đúng, còn chính sách chi phí được áp dụng ở bước quyết định. Nhờ vậy, khi tổ chức tín dụng thay đổi khẩu vị rủi ro, chỉ cần điều chỉnh ngưỡng mà không phải huấn luyện lại mô hình.

2.6.4 Lựa chọn chỉ số đánh giá hiệu năng

Trên cơ sở bộ chỉ tiêu đã trình bày ở mục 1.4.6, đề án bổ sung nhóm chỉ tiêu thứ năm mang tính nghiệp vụ nhằm quy đổi chất lượng thống kê thành hệ quả kinh doanh. Bảng 2.8 nêu vai trò của từng nhóm trong quy trình đánh giá.

Bảng 2.8: Hệ thống chỉ tiêu đánh giá và vai trò trong quy trình

Nhóm	Chỉ tiêu	Vai trò
Phân loại phổ quát	Accuracy, Precision, Recall, F1, PR-AUC	Báo cáo đầy đủ; Recall được ưu tiên hơn Precision do chi phí bỏ sót hồ sơ xấu cao
Đặc thù tín dụng	AUC, Gini, KS	Tiêu chí chính để xếp hạng và lựa chọn mô hình; không phụ thuộc ngưỡng
Hiệu chuẩn	Brier, ECE, đường cong hiệu chuẩn	Điều kiện cần để dùng PD trong phân vùng quyết định và tính tổn thất kỳ vọng
Vận hành	Thời gian huấn luyện, thời gian chấm điểm, mức độ giải thích được	Quyết định khả năng triển khai thực tế
Nghiệp vụ	Tỷ lệ duyệt, tỷ lệ nợ xấu nhóm duyệt, chi phí kỳ vọng, bảng gains	Quy đổi chất lượng thống kê thành hệ quả kinh doanh

2.6.5 Tích hợp cơ chế giải thích mô hình

Cơ chế giải thích được tích hợp ở hai cấp độ.

Cấp độ toàn cục. Phân tích SHAP trên một mẫu đại diện của tập kiểm thử cho biết đặc trưng nào chi phối kết quả dự báo của mô hình nói chung, và mỗi nhóm nguồn dữ liệu đóng góp bao nhiêu phần vào quyết định. Kết quả này phục vụ hai mục đích: kiểm chứng rằng mô hình học được quan hệ hợp lý về mặt nghiệp vụ, và định lượng giá trị của từng nguồn dữ liệu để làm cơ sở cho quyết định đầu tư dữ liệu.

Cấp độ từng hồ sơ. Với mỗi hồ sơ được chấm điểm, mô hình sinh danh sách lý do gồm ba thành phần theo thứ tự ưu tiên: (i) các luật nghiệp vụ bị vi phạm – đây là loại lý do tường minh và dễ hiểu nhất; (ii) các chỉ tiêu định lượng then chốt kèm giá trị thực tế của hồ sơ; và (iii) các đặc trưng có đóng góp SHAP lớn nhất. Danh sách này được trả về cùng kết quả chấm điểm, cho phép cán bộ tín dụng đánh giá xem khuyến nghị của mô hình có hợp lý hay không.

2.7 Quy trình huấn luyện và tối ưu mô hình

2.7.1 Thiết lập môi trường và công cụ huấn luyện

Toàn bộ quy trình được hiện thực bằng Python, tổ chức thành một gói phần mềm mà mỗi gói con tương ứng một mục của chương này: `data` cho khâu thu thập và kiểm tra chất lượng dữ liệu, `preprocessing` cho tiền xử lý, `features` cho trích xuất và lựa chọn đặc trưng, `labeling` cho gán nhãn và điểm cắt, `models` cho huấn luyện và đánh giá mô hình, `decision` cho bộ máy hỗ trợ quyết định, `serving` cho dịch vụ REST và `monitoring` cho giám sát. Cấu trúc thư mục chi tiết được trình bày tại Phụ lục A.

Các thư viện chính gồm: scikit-learn cho các mô hình cơ sở và khung pipeline; XGBoost, LightGBM, CatBoost cho các biến thể gradient boosting; SHAP cho giải thích mô hình; pandas và NumPy cho xử lý dữ liệu; FastAPI cho dịch vụ REST. Toàn bộ tham số được đặt tập trung trong một file cấu hình duy nhất, và hạt giống ngẫu nhiên được cố định để bảo đảm khả năng tái lập.

2.7.2 Quy trình thử nghiệm và kiểm tra chéo

Kiểm định ngoài thời gian cho đánh giá cuối cùng. Việc đánh giá chất lượng mô hình được thực hiện trên tập kiểm thử gồm các hồ sơ thuộc giai đoạn sau giai đoạn huấn luyện. Đây là phương pháp phản ánh đúng điều kiện vận hành.

Kiểm định chéo theo chuỗi thời gian cho tinh chỉnh tham số. Với việc tinh chỉnh siêu tham số, đề án sử dụng `TimeSeriesSplit` – phương pháp chia tập huấn luyện thành nhiều lần khớp liên tiếp, trong đó mỗi lần dùng dữ liệu quá khứ để huấn luyện và dữ liệu kế tiếp để đánh giá:

Lần khớp	Phân chia
1	Huấn luyện: đoạn 1 → Đánh giá: đoạn 2
2	Huấn luyện: đoạn 1–2 → Đánh giá: đoạn 3
3	Huấn luyện: đoạn 1–3 → Đánh giá: đoạn 4

Phương pháp này khác với kiểm định chéo *k*-fold thông thường ở chỗ nó không bao giờ dùng dữ liệu tương lai để huấn luyện – điều kiện bắt buộc với dữ liệu có cấu trúc thời gian.

2.7.3 Phương pháp tối ưu hóa siêu tham số

Đề án sử dụng **tìm kiếm ngẫu nhiên** thay vì tìm kiếm lưới. Lựa chọn này dựa trên kết quả của Bergstra và Bengio [29]: với cùng một ngân sách tính toán, tìm kiếm ngẫu nhiên thường tìm được cấu hình tốt hơn tìm kiếm lưới. Nguyên nhân là trong không gian siêu tham số nhiều chiều, chỉ một số ít chiều thực sự ảnh hưởng tới kết quả; tìm kiếm lưới lãng phí phần lớn số lần thử để dò các giá trị khác nhau của những chiều không quan trọng, trong khi tìm kiếm ngẫu nhiên bao phủ được nhiều giá trị khác biệt hơn ở những chiều quan trọng.

Không gian tìm kiếm được xác định cho ba mô hình có nhiều siêu tham số nhất – LightGBM, XGBoost và rừng ngẫu nhiên – bao gồm các tham số về độ sâu/số lá, tốc độ học, số quan sát tối thiểu tại lá, tỷ lệ lấy mẫu quan sát và đặc trưng, cùng các hệ số điều chuẩn. Tiêu chí lựa chọn là AUC trung bình trên các lần khớp của kiểm định chéo theo chuỗi thời gian.

Để bảo đảm tính nhất quán, việc tinh chỉnh siêu tham số phải được thực hiện trên *đúng tập đặc trưng* mà mô hình cuối cùng sẽ sử dụng. Nếu tinh chỉnh trên tập đầy đủ rồi áp dụng tham số cho tập đã rút gọn, siêu tham số tìm được không còn tối ưu.

2.7.4 Mức độ kiểm soát hiện tượng quá khớp

Đề án áp dụng bốn cơ chế kiểm soát quá khớp, tác động ở các giai đoạn khác nhau của quy trình.

Điều chuẩn trong hàm mục tiêu. Hồi quy logistic và SVM sử dụng điều chuẩn L_2; các mô hình boosting sử dụng đồng thời điều chuẩn L_1 và L_2 trên giá trị lá.

Ràng buộc cấu trúc mô hình. Giới hạn độ sâu cây, số lá tối đa và số quan sát tối thiểu tại mỗi lá. Với cây quyết định đơn, bổ sung tỉa nhánh theo độ phức tạp chi phí (1.12).

Dừng sớm. Các mô hình boosting theo dõi AUC trên tập `train_es` và dừng khi chỉ tiêu này ngừng cải thiện trong một số vòng lặp liên tiếp. Cần chỉ định AUC là chỉ tiêu dừng *duy nhất*: khi sử dụng trọng số lớp, hàm log-loss trên tập đánh giá xấu đi rất sớm do xác suất bị lệch hệ thống, nên nếu để cơ chế mặc định theo dõi nhiều chỉ tiêu, quá trình huấn luyện sẽ dừng quá sớm và mô hình bị dưới khớp.

Lấy mẫu ngẫu nhiên. Rừng ngẫu nhiên và các mô hình boosting sử dụng lấy mẫu con quan sát và đặc trưng ở mỗi bước, vừa giảm tương quan giữa các cây vừa đóng vai trò điều chuẩn ngẫu nhiên.

Mức độ quá khớp được đo bằng chênh lệch AUC giữa tập kiểm định và tập kiểm thử; chênh lệch lớn là dấu hiệu mô hình phụ thuộc quá mức vào đặc thù của giai đoạn huấn luyện. Kết quả đo được trình bày tại mục 3.3.3.6.

2.7.5 Phương pháp đánh giá độ ổn định mô hình theo thời gian

Độ ổn định được đánh giá trên hai phương diện.

Ổn định của dữ liệu đầu vào. Đo bằng chỉ số PSI (1.23) cho từng đặc trưng, so sánh phân phối giữa giai đoạn huấn luyện và giai đoạn kiểm thử. Ngưỡng cảnh báo 0,10 và ngưỡng báo động 0,25.

Ổn định của chất lượng dự báo. Chia tập kiểm thử theo tháng và tính AUC, KS cùng tỷ lệ nợ xấu thực tế cho từng tháng. Xu hướng giảm liên tục của AUC là dấu hiệu mô hình đang mất dần hiệu lực và cần được huấn luyện lại.

Hai phương diện này bổ trợ nhau: PSI phát hiện sớm sự thay đổi của dữ liệu đầu vào ngay cả khi chưa có nhãn, trong khi chất lượng dự báo theo tháng chỉ đo được sau khi nhãn đã sẵn sàng. Trong vận hành thực tế, PSI đóng vai trò cảnh báo sớm còn chất lượng dự báo đóng vai trò xác nhận.

Kết luận chương 2

Chương 2 đã trình bày quá trình xây dựng mô hình học máy hỗ trợ kiểm duyệt tín dụng, từ phân tích bài toán tới thiết kế quy trình huấn luyện mô hình, với bốn nhóm kết quả.

Về *phân tích bài toán*: xác định biến mục tiêu là xác suất phát sinh nợ xấu trong 12 tháng, phân biệt ba trạng thái khi gán nhãn, thiết kế thang bảy hạng rủi ro và năm thành phần của kết quả đầu ra; hệ thống hóa mười yêu cầu chức năng, bốn yêu cầu phi chức năng và năm nhóm yêu cầu pháp lý.

Về *xử lý dữ liệu*: thiết lập quy tắc ghép nối bảo đảm tính đúng đắn theo thời điểm, xây dựng bộ mười lăm ràng buộc kiểm tra tính hợp lệ kèm cơ chế kiểm chứng bằng phép tiêm lỗi, phân biệt hai cách xử lý khác nhau cho dữ liệu không hợp lệ và giá trị ngoại lệ, thiết kế chiến lược phân chia bốn tập với vai trò tách bạch.

Về *đặc trưng*: trình bày cách trích xuất năm nhóm đặc trưng cùng thuật toán luỹ kế bảo đảm tính đúng đắn theo thời điểm với chi phí tuyến tính, và quy trình lựa chọn ba bước theo năng lực dự báo, mức tương quan và độ ổn định.

Về *mô hình*: lựa chọn mười hai mô hình để so sánh, thiết kế kiến trúc phân tầng với logic tổng hợp khuyến nghị theo tám mức ưu tiên, tách hàm mất mát huấn luyện khỏi hàm chi phí nghiệp vụ, và thiết lập bốn cơ chế kiểm soát quá khớp.

Toàn bộ thiết kế này được kiểm chứng bằng thực nghiệm ở Chương 3.

Chương 3

TRIỂN KHAI THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

Chương 3 trình bày kịch bản thực nghiệm, kết quả huấn luyện mô hình học máy và đánh giá hiệu năng mô hình kiểm duyệt tín dụng. Nội dung chương tập trung mô phỏng vận hành và bàn luận, đối chiếu kết quả thực nghiệm thu được.

3.1 Thiết lập kịch bản và môi trường thực nghiệm

3.1.1 Hạ tầng phần cứng, phần mềm và thư viện sử dụng

Toàn bộ thực nghiệm được thực hiện trên một máy tính cá nhân với cấu hình và môi trường phần mềm trình bày tại Bảng 3.1.

Bảng 3.1: Cấu hình phần cứng và môi trường phần mềm

Thành phần	Thông số
Hệ điều hành	Windows 11 (64-bit)
Ngôn ngữ lập trình	Python 3.12
Xử lý dữ liệu	pandas, NumPy, PyArrow (định dạng lưu trữ Parquet)
Mô hình cơ sở	scikit-learn 1.9
Mô hình boosting	XGBoost, LightGBM, CatBoost
Giải thích mô hình	SHAP
Dịch vụ REST	FastAPI, Uvicorn
Trực quan hóa	Matplotlib, Streamlit

Các số đo thời gian trong chương này được thực hiện trên một máy đơn, một tiến trình, nên phản ánh chi phí tính toán của thuật toán chứ không bao gồm thời gian truyền qua mạng hay ảnh hưởng của tải đồng thời; chúng có giá trị để *so sánh tương đối* giữa các mô hình (xem thêm mục 3.5.3).

Toàn bộ tham số của thực nghiệm được đặt tập trung trong một file cấu hình duy nhất và hạt giống ngẫu nhiên được cố định, bảo đảm kết quả tái lập được. Quy trình thực nghiệm gồm sáu bước, mỗi bước là một chương trình độc lập: chuẩn bị dữ liệu,

phân tích và lựa chọn đặc trưng, tinh chỉnh siêu tham số, huấn luyện mô hình, mô phỏng quy trình kiểm duyệt, và xuất kết quả.

3.1.2 Kịch bản thực nghiệm các mô hình học máy

Thực nghiệm được thiết kế theo nguyên tắc **so sánh công bằng**: toàn bộ 12 mô hình được huấn luyện trên cùng một tập dữ liệu, cùng một tập đặc trưng, cùng cách chia dữ liệu và được đánh giá bằng cùng một bộ chỉ tiêu. Mỗi mô hình đi qua đúng bốn bước:

(1) Huấn luyện trên tập `train_fit`; các mô hình boosting bổ sung cơ chế dừng sớm trên tập `train_es`;
(2) Hiệu chuẩn xác suất bằng hồi quy đẳng hướng trên tập `valid`;
(3) Lựa chọn ngưỡng quyết định theo hàm chi phí trên tập `valid`;
(4) Đánh giá cuối cùng trên tập `test` – chỉ thực hiện một lần.

Về mặt phương pháp, mọi quyết định liên quan tới mô hình đều dựa trên tập `valid`. Tập `test` hoàn toàn không tham gia vào bất kỳ lựa chọn nào, nhờ đó ước lượng hiệu năng cuối cùng không bị lạc quan.

3.1.3 Thiết kế và kiểm chứng tập dữ liệu thực nghiệm

3.1.3.1 Cơ sở lựa chọn dữ liệu mô phỏng

Dữ liệu tín dụng cá nhân thuộc nhóm dữ liệu nhạy cảm, chịu ràng buộc chặt chẽ về bảo mật. Việc tiếp cận dữ liệu thực của một tổ chức tín dụng cho mục đích nghiên cứu học thuật đòi hỏi quy trình phê duyệt phức tạp và thường không khả thi trong khuôn khổ một đề án tốt nghiệp. Mặt khác, các bộ dữ liệu tín dụng công khai thường có ba hạn chế khiến chúng không phù hợp với đề án này: quy mô nhỏ (vài nghìn quan sát), không có thông tin thời gian nên không cho phép kiểm định ngoài thời gian, và đặc biệt là *không có dữ liệu giao dịch* – nhóm dữ liệu mà đề án muốn đánh giá đóng góp.

Vì vậy đề án sử dụng dữ liệu mô phỏng được sinh bằng chương trình tự xây dựng. Cách tiếp cận này có một ưu điểm phương pháp luận quan trọng ngoài việc giải quyết vấn đề tiếp cận dữ liệu: vì quá trình sinh dữ liệu xác định tường minh xác suất vỡ nợ thật của từng hồ sơ, ta biết được **trần Bayes** – giới hạn lý thuyết mà không mô hình nào có thể vượt qua. Nhờ đó có thể đánh giá một mô hình còn cách giới hạn lý thuyết bao xa, điều không thể làm được với dữ liệu thực.

Giới hạn tương ứng của cách tiếp cận này là các chỉ tiêu chất lượng thu được **không nên được hiểu là dự báo về hiệu quả trên dữ liệu thực**. Giá trị của thực nghiệm nằm ở việc so sánh *tương đối* giữa các mô hình trong cùng điều kiện và ở việc kiểm chứng tính đúng đắn của toàn bộ quy trình từ dữ liệu tới quyết định.

3.1.3.2 Mô hình sinh dữ liệu biến tiềm ẩn

Dữ liệu được sinh theo một mô hình xác suất có cấu trúc, trong đó mỗi khách hàng i được gán một **biến tiềm ẩn** $z_i \sim \mathcal{N}(0,1)$ biểu diễn mức độ tín nhiệm nội tại – đại lượng không quan sát được trong thực tế. Từ z_i, chương trình sinh ra ba nhóm dữ liệu quan sát được:

- **Thông tin nhân khẩu và tài chính**: thu nhập, nghề nghiệp, thâm niên công việc phụ thuộc z_i với nhiễu;
- **Lịch sử tín dụng tại CIC**: điểm CIC, nhóm nợ, số ngày quá hạn là các *phép đo có nhiễu* của z_i;
- **Hành vi giao dịch**: tính ổn định dòng tiền, tỷ trọng chi tiêu nhóm rủi ro cũng phụ thuộc z_i với nhiễu độc lập.

Nhãn vỡ nợ được sinh từ một hàm log-odds phi tuyến của z_i và các đặc trưng đã tính đúng theo thời điểm:

$$\mathrm{PD}_i^{\text{thật}} = \sigma(\eta(z_i, \mathbf{x}_i) + \beta_0), \qquad y_i \sim \mathrm{Bernoulli}(\mathrm{PD}_i^{\text{thật}}), \tag{3.1}$$

trong đó hệ số chặn β_0 được hiệu chỉnh bằng phương pháp số để đạt tỷ lệ vỡ nợ mục tiêu.

Cấu trúc này tạo ra một đặc điểm quan trọng: vì CIC và hành vi giao dịch chỉ là các phép đo *có nhiễu* của z_i, mô hình học máy chỉ có thể phục hồi một phần thông tin về z_i. Điều này tạo ra một giới hạn trên tự nhiên cho chất lượng dự báo – chính là trần Bayes – giống như tình huống thực tế, nơi không có mô hình nào đạt AUC = 1.

Quá trình sinh dữ liệu còn đưa vào ba hiện tượng đặc thù của dữ liệu tín dụng thực: nhóm khách hàng thiếu lịch sử tín dụng (chiếm 9,66%), giá trị khuyết ở một số trường khai báo, và hiện tượng trôi dạt theo thời gian với mức độ xác định trước.

3.1.3.3 Quy mô và đặc điểm tập dữ liệu

Bảng 3.2 trình bày quy mô các bảng dữ liệu thu được. Tập dữ liệu gồm 40.000 khách hàng, 73.023 tài khoản, 4.538.127 giao dịch và 60.000 hồ sơ vay trải trên khoảng thời gian hai năm, với thời gian sinh 39,5 giây.

Bảng 3.2: Quy mô các bảng dữ liệu sử dụng trong đề án

Bảng dữ liệu	Số bản ghi	Nội dung
Khách hàng	40.000	Thông tin nhân khẩu học, nghề nghiệp, thu nhập
Tài khoản	73.023	Tài khoản thanh toán/tiết kiệm và số dư bình quân
Giao dịch	4.538.127	Giao dịch tài khoản dùng để tính đặc trưng hành vi
Hồ sơ vay	60.000	Hồ sơ đề nghị cấp tín dụng
Bản tin CIC	60.000	Thông tin lịch sử tín dụng từ CIC
Nhãn rủi ro	60.000	Trạng thái vỡ nợ sau cửa sổ quan sát

Hình 3.1 mô tả phân bố của một số biến chính trong tập dữ liệu.



Hình 3.1: Phân bố các biến chính trong tập dữ liệu thực nghiệm

3.1.3.4 Kiểm tra chất lượng dữ liệu

Bộ 15 ràng buộc nghiệp vụ được áp dụng cho ba bảng dữ liệu chính, phát hiện 0 bản ghi vi phạm. Kết quả này không đáng ngạc nhiên với dữ liệu mô phỏng, nhưng bản thân nó *không chứng minh được* rằng cơ chế kiểm tra hoạt động đúng – một bộ kiểm tra hỏng cũng cho kết quả tương tự.

Để phân biệt hai khả năng, đề án thực hiện phép tiêm lỗi: tạo bản sao dữ liệu, cố ý đưa vào 1% lỗi ứng với từng loại ràng buộc, rồi chạy lại cơ chế kiểm tra. Kết quả tại Bảng 3.3 cho thấy toàn bộ lỗi đã tiêm đều được phát hiện (tỷ lệ phát hiện 100%).

Bảng 3.3: Kiểm chứng cơ chế phát hiện dữ liệu không hợp lệ bằng phép tiêm lỗi

Mã ràng buộc	Nội dung ràng buộc	Số lỗi tiêm vào	Số lỗi phát hiện	Kết quả
CUS_AGE_ RANGE	Tuổi khách hàng phải nằm trong khoảng 18-75	400	400	Phát hiện đủ
CUS_INCOME_ POSITIVE	Thu nhập khai báo phải lớn hơn 0	400	400	Phát hiện đủ
APP_AMOUNT_ POSITIVE	Số tiền đề nghị vay phải lớn hơn 0	600	600	Phát hiện đủ
APP_RATE_ RANGE	Lãi suất phải nằm trong khoảng 0-40%/năm	600	600	Phát hiện đủ
CIC_SCORE_ RANGE	Điểm CIC phải nằm trong khoảng 300-850	600	600	Phát hiện đủ
CIC_GROUP_ ORDER	Nhóm nợ xấu nhất 12 tháng không thể tốt hơn nhóm nợ hiện tại	600	600	Phát hiện đủ

Phép tiêm lỗi được thực hiện trên một bản sao dữ liệu với tỷ lệ 1% mỗi loại lỗi; dữ liệu gốc không bị thay đổi.

Về giá trị khuyết, 9 trên tổng số đặc trưng có dữ liệu trống, với tỷ lệ cao nhất là 11,65% – tương ứng nhóm khách hàng thiếu lịch sử tín dụng (Bảng 3.4). Về giá trị ngoại lệ, 122 đặc trưng có quan sát nằm ngoài ngưỡng 3×IQR (Bảng 3.5); các giá trị này được xử lý bằng phép cắt ngọn thay vì loại bỏ quan sát.

3.1.3.5 Kết quả gán nhãn rủi ro

Bảng 3.6 trình bày phân bố ba trạng thái rủi ro sau khi gán nhãn theo tiêu chuẩn nợ nhóm 3–5 với cửa sổ quan sát 12 tháng.

Bảng 3.4: Các đặc trưng có giá trị khuyết và chiến lược xử lý

Đặc trưng	Nhóm	Tỷ lệ khuyết (%)	Cách xử lý
oldest_account_months	Lịch sử tín dụng (CIC)	11,65	Quy ước nghiệp vụ + cờ chỉ báo khuyết
credit_utilization	Lịch sử tín dụng (CIC)	10,93	Quy ước nghiệp vụ + cờ chỉ báo khuyết
cic_score	Lịch sử tín dụng (CIC)	9,66	Quy ước nghiệp vụ + cờ chỉ báo khuyết
current_group	Lịch sử tín dụng (CIC)	9,66	Quy ước nghiệp vụ + cờ chỉ báo khuyết
total_outstanding	Lịch sử tín dụng (CIC)	9,66	Quy ước nghiệp vụ + cờ chỉ báo khuyết
dpd_max_12m	Lịch sử tín dụng (CIC)	9,66	Quy ước nghiệp vụ + cờ chỉ báo khuyết
worst_group_12m	Lịch sử tín dụng (CIC)	9,66	Quy ước nghiệp vụ + cờ chỉ báo khuyết
num_bad_debt_ institutions	Lịch sử tín dụng (CIC)	9,66	Quy ước nghiệp vụ + cờ chỉ báo khuyết
monthly_debt_payment	Lịch sử tín dụng (CIC)	9,66	Quy ước nghiệp vụ + cờ chỉ báo khuyết

Bảng 3.5: Các đặc trưng có tỷ lệ giá trị ngoại lệ cao nhất (quy tắc 3×IQR)

Đặc trưng	Tỷ lệ ngoại lệ (%)	Phân vị 1%	Phân vị 99%
utility_amt_7d	24,75	0	1,49
ecom_amt_7d	21,90	0	3,22
current_group	20,84	1	5
outflow_ratio_30d	18,67	0	14447060,00
dpd_x_institutions	17,97	0	87,20
cash_wd_amt_7d	14,86	0	4,91
cash_ratio_7d	14,86	0	1,00
cash_wd_cnt_7d	14,85	0	2
repay_amt_7d	13,29	0	8,64
repay_burden_7d	13,29	0	6209040,00

Giá trị ngoại lệ được xử lý bằng phép cắt ngọn tại phân vị 1% và 99% học từ tập huấn luyện, không loại bỏ quan sát.

Bảng 3.6: Phân bố trạng thái rủi ro sau khi gán nhãn

Trạng thái	Số hồ sơ	Tỷ trọng (%)
Tốt (không phát sinh nợ xấu)	50.867	84,78
Xấu (nợ nhóm 3-5, quá hạn ≥ 90 ngày)	9.133	15,22

Cơ sở định lượng cho lựa chọn cửa sổ 12 tháng được trình bày tại Bảng 3.7: đường cong tỷ lệ nợ xấu tích luỹ cho thấy cửa sổ 12 tháng ghi nhận được 100% tổng số trường hợp vỡ nợ, trong khi cửa sổ 6 tháng chỉ ghi nhận được khoảng 56%. Rút ngắn cửa sổ xuống 6 tháng sẽ khiến gần một nửa số hồ sơ thực sự xấu bị gán nhãn tốt – sai lệch đủ lớn để làm hỏng mô hình.

Bảng 3.7: Tỷ lệ nợ xấu tích luỹ theo số tháng kể từ khi cấp tín dụng

Tháng kể từ khi cấp tín dụng	Số hồ sơ phát sinh nợ xấu	Tỷ lệ nợ xấu tích luỹ (%)	Tỷ lệ ghi nhận được (%)
3	1.460	2,43	16,0
6	5.078	8,46	55,6
9	7.632	12,72	83,6
12	9.133	15,22	100
15	9.133	15,22	100
18	9.133	15,22	100

Cửa sổ quan sát 12 tháng được chọn tại điểm đường cong tích luỹ bắt đầu đi ngang.

3.1.4 Phương pháp phân chia tập dữ liệu thử nghiệm

Kết quả phân chia dữ liệu theo thời gian được trình bày tại Bảng 3.8.

Bảng 3.8: Phân chia dữ liệu theo thời gian

Tập	Số hồ sơ	Tỷ lệ	Vai trò
Huấn luyện (train_fit)	35.700	59,5%	Ước lượng tham số mô hình
Dừng sớm (train_es)	6.300	10,5%	Xác định số vòng lặp tối ưu
Kiểm định (valid)	9.000	15,0%	Hiệu chuẩn xác suất, chọn ngưỡng
Kiểm thử (test)	9.000	15,0%	Đánh giá cuối cùng, dùng một lần

Giai đoạn huấn luyện: 2024-07-01 đến 2025-11-24; giai đoạn kiểm thử: 2026-03-12 đến 2026-06-30.

Tỷ lệ nợ xấu tăng dần qua các giai đoạn, từ 14,35% ở tập huấn luyện lên 17,68% ở tập kiểm thử. Đây chính là biểu hiện của hiện tượng trôi dạt đã được đưa vào quá trình sinh dữ liệu. Sự chênh lệch này khiến bài toán trở nên khó hơn so với chia ngẫu nhiên và làm cho kết quả đánh giá sát với điều kiện vận hành thực tế hơn.

3.2 Kết quả huấn luyện và tính toán mô hình

3.2.1 Kết quả xây dựng và lựa chọn đặc trưng

Tập đặc trưng ban đầu gồm 154 biến, phân bố theo năm nhóm nguồn dữ liệu như trình bày tại Bảng 3.9.

Bảng 3.9: Cơ cấu tập đặc trưng theo nhóm và nguồn dữ liệu

Nhóm	Nguồn dữ liệu	Số đặc trưng
Hành vi giao dịch	GIAO DỊCH	99
Lịch sử tín dụng (CIC)	BẢN TIN CIC	16
Thông tin cá nhân	HỒ SƠ KH	15
Biến tổ hợp	TÍNH TOÁN	13
Tham số khoản vay	ĐƠN VAY	11

3.2.1.1 Phân tích Information Value

Bảng 3.10 liệt kê mười lăm đặc trưng có năng lực dự báo cao nhất.

Kết quả cho thấy nhóm đặc trưng CIC chiếm ưu thế ở phần đầu bảng xếp hạng, với giá trị IV cao nhất đạt 1,244. Điều này phù hợp với trực giác nghiệp vụ: lịch sử trả nợ trong quá khứ là chỉ báo mạnh nhất về khả năng trả nợ trong tương lai. Giá trị IV vượt ngưỡng 0,5 thông thường là dấu hiệu cần kiểm tra rò rỉ nhãn; trong trường hợp này, việc kiểm tra ràng buộc thời gian (CIC_QUERY_BEFORE_APPLY) xác nhận mọi bản tin CIC đều được truy vấn trước thời điểm nộp hồ sơ, nên IV cao phản ánh bản chất của dữ liệu chứ không phải lỗi phương pháp.

Bảng 3.11 tổng hợp IV theo nhóm nguồn dữ liệu.

Xét theo IV trung bình, nhóm CIC dẫn đầu rõ rệt: mỗi đặc trưng CIC mang nhiều thông tin hơn hẳn. Nhưng xét theo *tổng* IV, nhóm hành vi giao dịch lại chiếm vị trí cao nhất nhờ số lượng đặc trưng lớn. Hai cách nhìn này không mâu thuẫn mà bổ sung cho nhau: dữ liệu CIC là nguồn thông tin cô đọng nhất, còn dữ liệu giao dịch là nguồn

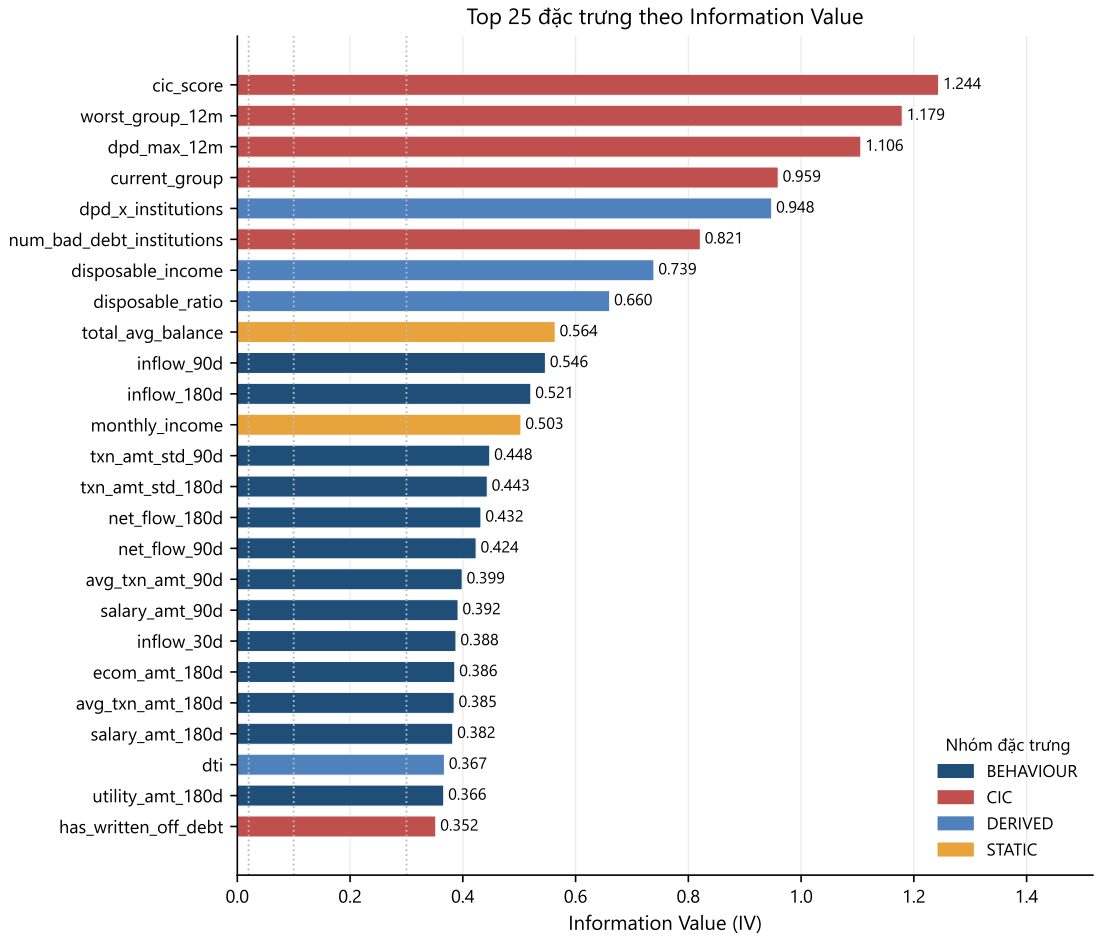
Bảng 3.10: Mười lăm đặc trưng có năng lực dự báo cao nhất theo Information Value

Đặc trưng	Nhóm	IV	Mức độ
cic_score	Lịch sử tín dụng (CIC)	1,244	Rất mạnh (cần kiểm tra rò rỉ nhãn)
worst_group_12m	Lịch sử tín dụng (CIC)	1,179	Rất mạnh (cần kiểm tra rò rỉ nhãn)
dpd_max_12m	Lịch sử tín dụng (CIC)	1,106	Rất mạnh (cần kiểm tra rò rỉ nhãn)
current_group	Lịch sử tín dụng (CIC)	0,959	Rất mạnh (cần kiểm tra rò rỉ nhãn)
dpd_x_institutions	Biến tổ hợp	0,948	Rất mạnh (cần kiểm tra rò rỉ nhãn)
num_bad_debt_institutions	Lịch sử tín dụng (CIC)	0,821	Rất mạnh (cần kiểm tra rò rỉ nhãn)
disposable_income	Biến tổ hợp	0,739	Rất mạnh (cần kiểm tra rò rỉ nhãn)
disposable_ratio	Biến tổ hợp	0,660	Rất mạnh (cần kiểm tra rò rỉ nhãn)
total_avg_balance	Thông tin cá nhân	0,564	Rất mạnh (cần kiểm tra rò rỉ nhãn)
inflow_90d	Hành vi giao dịch	0,546	Rất mạnh (cần kiểm tra rò rỉ nhãn)
inflow_180d	Hành vi giao dịch	0,521	Rất mạnh (cần kiểm tra rò rỉ nhãn)
monthly_income	Thông tin cá nhân	0,503	Rất mạnh (cần kiểm tra rò rỉ nhãn)
txn_amt_std_90d	Hành vi giao dịch	0,448	Mạnh
txn_amt_std_180d	Hành vi giao dịch	0,443	Mạnh
net_flow_180d	Hành vi giao dịch	0,432	Mạnh

Bảng 3.11: Information Value tổng hợp theo nhóm nguồn dữ liệu

Nhóm	Số đặc trưng	Tổng IV	IV trung bình	IV lớn nhất
Hành vi giao dịch	99	13,945	0,141	0,546
Lịch sử tín dụng (CIC)	16	6,780	0,424	1,244
Biến tổ hợp	13	4,253	0,327	0,948
Thông tin cá nhân	15	1,604	0,107	0,564
Tham số khoản vay	11	0,589	0,054	0,190

thông tin dồi dào nhất. Với nhóm khách hàng thiếu lịch sử tín dụng, nơi dữ liệu CIC gần như trống, nhóm thứ hai trở thành nguồn thông tin chủ yếu.



Hình 3.2: Xếp hạng đặc trưng theo Information Value

3.2.1.2 Kết quả lựa chọn tập đặc trưng

Quy trình lọc ba bước rút gọn tập đặc trưng từ 154 xuống 116 biến (Bảng 3.12).

Bảng 3.12: Kết quả lựa chọn tập đặc trưng qua ba bộ lọc

Bước	**Số đặc trưng**	**Đã loại**
Tập đặc trưng ban đầu	154	0
Sau lọc theo IV (≥ 0.02)	126	28
Sau lọc theo tương quan ($\lvert r\rvert \leq 0.95$)	116	10
Sau lọc theo độ ổn định (PSI ≤ 0.25)	116	0

Phân tích cơ cấu sau lựa chọn (Bảng 3.13) cho thấy các bộ lọc hoạt động đúng như thiết kế: nhóm biến tổ hợp giữ lại tỷ lệ cao nhất – hợp lý vì mỗi biến trong nhóm

Bảng 3.13: Cơ cấu tập đặc trưng trước và sau lựa chọn

Nhóm	Ban đầu	Sau lựa chọn	Tỷ lệ giữ lại (%)
Hành vi giao dịch	99	76	76,8
Lịch sử tín dụng (CIC)	16	14	87,5
Thông tin cá nhân	15	8	53,3
Biến tổ hợp	13	12	92,3
Tham số khoản vay	11	6	54,5

này được thiết kế để biểu diễn một chỉ tiêu nghiệp vụ riêng biệt nên ít trùng lặp. Ngược lại, nhóm tham số khoản vay bị loại nhiều nhất, chủ yếu do năng lực dự báo thấp.

Bước lọc theo độ ổn định không loại bỏ đặc trưng nào: chỉ số PSI lớn nhất trên toàn bộ tập đặc trưng chỉ đạt 0,0598, thấp hơn nhiều so với ngưỡng cảnh báo 0,10. Kết quả này cho thấy mức trôi dạt trong dữ liệu thực nghiệm tập trung ở *quan hệ giữa đặc trưng và nhãn* chứ không ở phân phối biên của đặc trưng – một dạng trôi dạt khó phát hiện hơn bằng giám sát PSI đơn thuần.

3.2.2 Kết quả trên các mô hình cơ sở

Nhóm mô hình cơ sở gồm hồi quy logistic, thẻ điểm WOE và cây quyết định – các mô hình có cấu trúc đơn giản và khả năng giải thích cao.

Hồi quy logistic đạt AUC $= 0,8579$ trên tập kiểm thử, thẻ điểm WOE đạt 0,8570, còn cây quyết định đơn đạt 0,8206. Khoảng cách giữa hai mô hình tuyến tính và cây quyết định là đáng kể – gần 0,04 điểm AUC – cho thấy hạn chế về phương sai cao của cây đơn đã được phân tích ở mục 1.4.2 thể hiện rõ trong thực nghiệm.

Việc hồi quy logistic – mô hình đơn giản nhất trong nhóm – lại đạt kết quả gần sát với các mô hình phức tạp là một quan sát quan trọng, sẽ được bàn kỹ ở mục 3.3.3.

3.2.3 Kết quả trên các mô hình học máy nâng cao

Nhóm mô hình nâng cao gồm các mô hình học tập hợp (rừng ngẫu nhiên, Extra Trees, bốn biến thể gradient boosting), máy vectơ hỗ trợ, mạng nơ-ron và mô hình kết hợp xếp tầng.

Trong nhóm này, mô hình kết hợp xếp tầng đạt AUC danh nghĩa cao nhất (0,8620), ngay sau là ba biến thể gradient boosting: CatBoost 0,8614, XGBoost 0,8612

và LightGBM 0,8590. Máy vectơ hỗ trợ đạt 0,8540, rừng ngẫu nhiên đạt 0,8527 và Hist Gradient Boosting đạt 0,8575.

Cần nhấn mạnh ngay rằng khoảng cách giữa các mô hình dẫn đầu là *không đáng kể*: chênh lệch giữa mô hình đứng đầu và mô hình thứ hai chỉ 0,0006 điểm AUC. Mục 3.3.3.4 phân tích vì sao mức chênh lệch này không đủ cơ sở để kết luận một thuật toán vượt trội, và vì sao mô hình được chọn triển khai lại không phải mô hình có AUC cao nhất.

Kết quả của SVM cần được bình luận riêng. Mặc dù sử dụng phép xấp xỉ Nystroem thay vì giải bài toán đối ngẫu đầy đủ, mô hình vẫn đạt mức chất lượng tương đương rừng ngẫu nhiên và chỉ kém mô hình tốt nhất 0,0074 điểm AUC, với thời gian huấn luyện khoảng 16,1 giây. Kết quả này cho thấy phép xấp xỉ hạt nhân là giải pháp khả thi để áp dụng SVM ở quy mô dữ liệu mà SVM hạt nhân đầy đủ không huấn luyện được trong thời gian chấp nhận được.

3.2.4 Tối ưu hóa siêu tham số cho mô hình

Kết quả trình bày ở hai mục trên đã sử dụng siêu tham số được tinh chỉnh ở bước này; mục này trình bày chi tiết quá trình tinh chỉnh đó.

Ba mô hình có nhiều siêu tham số nhất – LightGBM, XGBoost và rừng ngẫu nhiên – được tinh chỉnh bằng tìm kiếm ngẫu nhiên kết hợp kiểm định chéo theo chuỗi thời gian trên tập huấn luyện. Kết quả trình bày tại Bảng 3.14.

Bảng 3.14: Kết quả tinh chỉnh siêu tham số bằng tìm kiếm ngẫu nhiên

Mô hình	Số lần thử	AUC (CV)	Thời gian (phút)
lightgbm	14	0,8499	1,5
xgboost	14	0,8623	2,9
random_forest	14	0,8576	9,5

Kiểm định chéo theo chuỗi thời gian (TimeSeriesSplit) ba lần khớp trên tập huấn luyện.

Hai điểm cần lưu ý về phương pháp. Thứ nhất, việc tinh chỉnh được thực hiện trên *đúng tập đặc trưng* mà mô hình cuối cùng sử dụng – tập 116 biến sau lựa chọn, không phải tập đầy đủ ban đầu. Nếu tinh chỉnh trên tập đầy đủ rồi áp dụng tham số cho tập đã rút gọn, siêu tham số tìm được không còn tối ưu. Thứ hai, toàn bộ quá trình tinh chỉnh chỉ sử dụng tập huấn luyện; tập kiểm định và tập kiểm thử không tham gia, nhờ đó không tạo ra rò rỉ thông tin.

3.3 Đánh giá hiệu năng và so sánh kết quả thực nghiệm

3.3.1 Đánh giá qua các chỉ số phân loại

Bảng 3.15 trình bày đầy đủ kết quả của 12 mô hình theo bảy chỉ tiêu chất lượng dự báo.

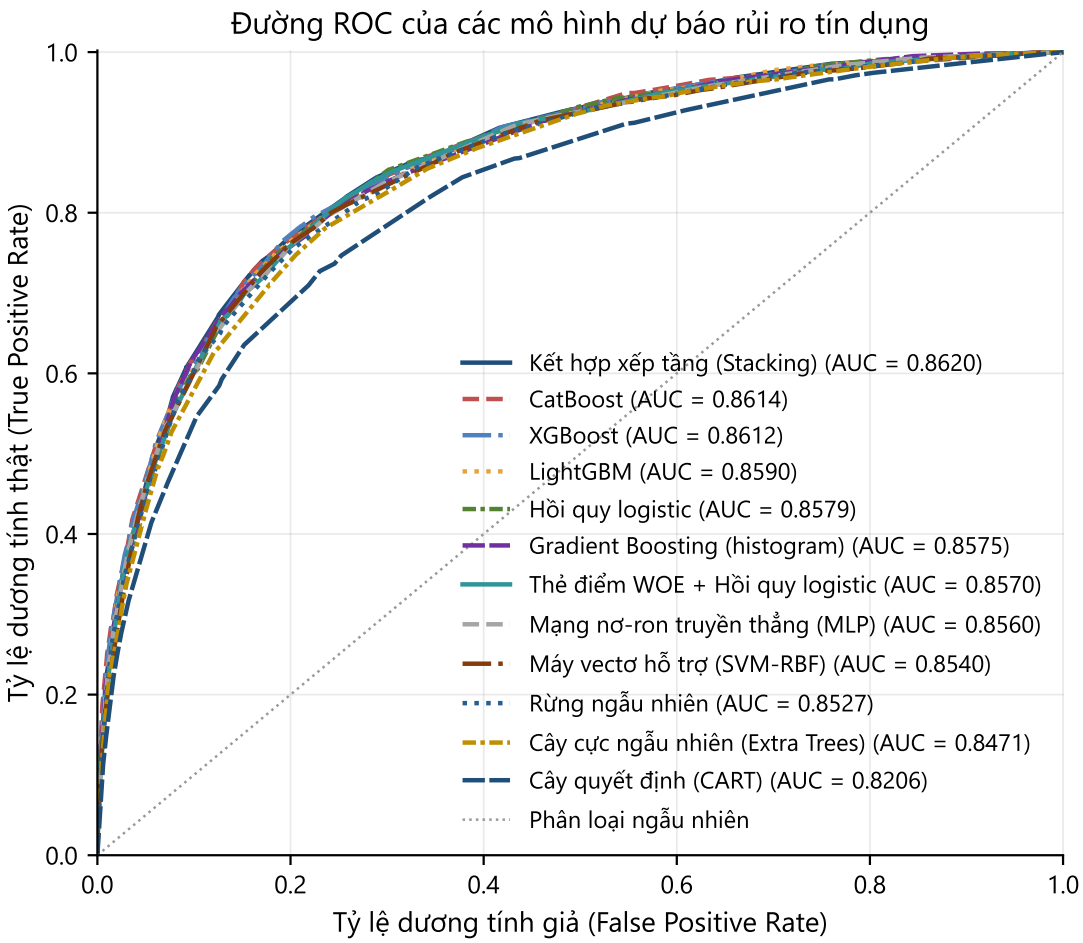
Bảng 3.15: So sánh chất lượng dự báo của các mô hình trên tập kiểm thử

Mô hình	AUC	Gini	KS	PR-AUC	F1	Brier	ECE
Kết hợp xếp tầng (Stacking)	**0,8620**	**0,7240**	**0,5702**	**0,6141**	**0,4445**	**0,0981**	**0,0063**
CatBoost	0,8614	0,7229	0,5689	0,6257	0,4731	0,0976	0,0075
XGBoost	0,8612	0,7223	0,5729	0,6213	0,4689	0,0980	0,0101
LightGBM	0,8590	0,7181	0,5647	0,6107	0,4482	0,0988	0,0053
Hồi quy logistic	0,8579	0,7158	0,5629	0,5914	0,4418	0,1007	0,0070
Gradient Boosting (histogram)	0,8575	0,7150	0,5594	0,5999	0,4453	0,0993	0,0107
Thẻ điểm WOE + Hồi quy logistic	0,8570	0,7140	0,5621	0,6025	0,4627	0,1000	0,0112
Mạng nơ-ron truyền thẳng (MLP)	0,8560	0,7119	0,5602	0,6012	0,4649	0,0999	0,0083
Máy vectơ hỗ trợ (SVM-RBF)	0,8540	0,7080	0,5619	0,5953	0,4517	0,1005	0,0070
Rừng ngẫu nhiên	0,8527	0,7054	0,5531	0,5930	0,4654	0,1008	0,0064
Cây cực ngẫu nhiên (Extra Trees)	0,8471	0,6942	0,5448	0,5808	0,4360	0,1030	0,0078
Cây quyết định (CART)	0,8206	0,6412	0,4970	0,5299	0,4052	0,1092	0,0066

Sắp xếp theo ROC-AUC giảm dần. Trần Bayes (tính từ xác suất vỡ nợ thực của quá trình sinh dữ liệu) là 0,9109.

Mô hình được chọn triển khai – CatBoost – đạt AUC $= 0,8614$, Gini $= 0,7229$, KS $= 0,5689$ và $F_1 = 0,4731$. Về chất lượng hiệu chuẩn, điểm Brier đạt 0,0976 và sai số hiệu chuẩn kỳ vọng chỉ 0,0075; mức sai số thấp này cho phép sử dụng trực tiếp xác suất đầu ra làm căn cứ phân vùng quyết định.

Hình 3.3 và Hình 3.4 minh họa khả năng phân biệt và mức độ hiệu chuẩn của các mô hình.

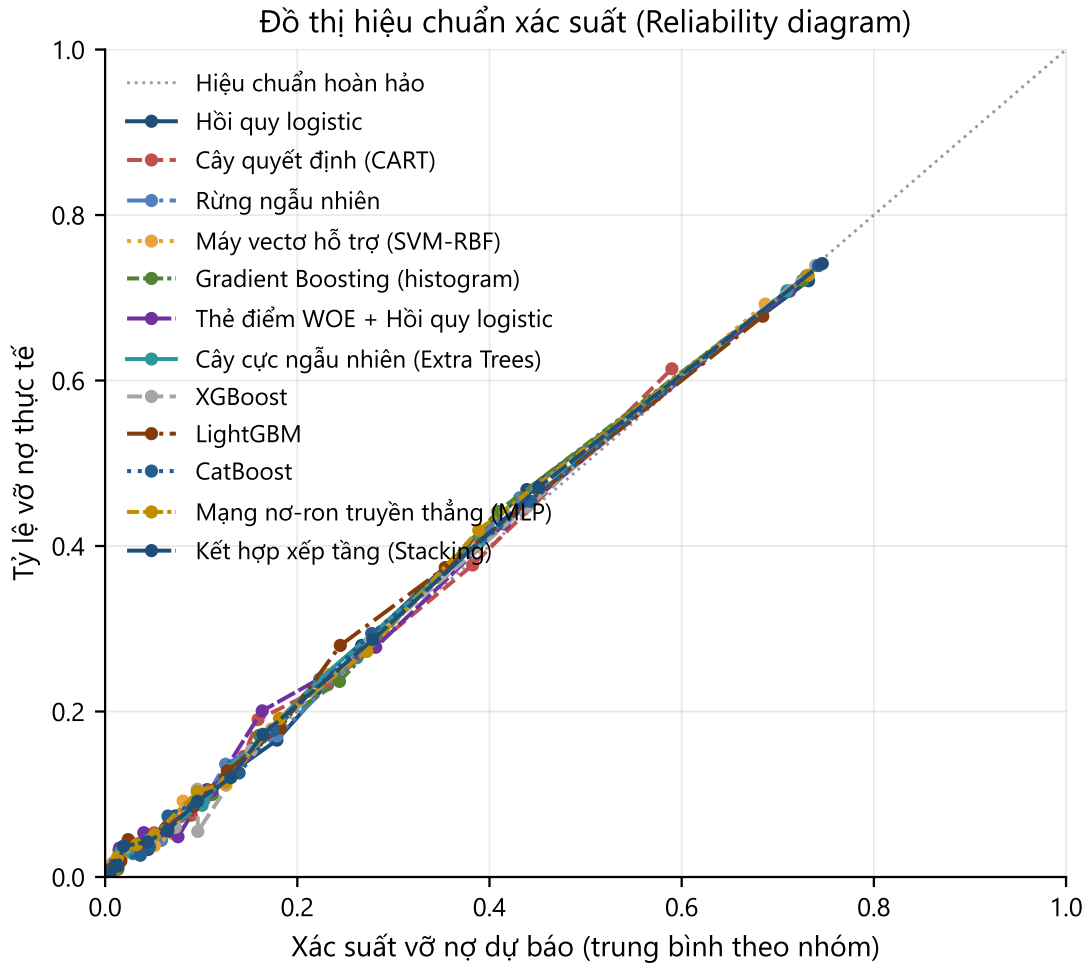


Hình 3.3: Đường cong ROC của các mô hình trên tập kiểm thử

3.3.1.1 So sánh với trần Bayes

Vì quá trình sinh dữ liệu xác định tường minh xác suất vỡ nợ thật của từng hồ sơ, có thể tính được trần Bayes – giới hạn lý thuyết của mọi mô hình trên tập dữ liệu này. Trần Bayes trên tập kiểm thử là 0,9109.

Mô hình tốt nhất đạt 0,8614, tức còn cách trần Bayes 0,0495 điểm AUC. Khoảng cách này có ý nghĩa quan trọng về mặt diễn giải: nó cho thấy mô hình đã khai thác được phần lớn thông tin có trong dữ liệu, và phần còn thiếu không phải do thuật toán yếu mà do bản thân dữ liệu quan sát được chỉ là phép đo có nhiễu của mức tín nhiệm thật. Nói cách khác, việc đầu tư thêm vào thuật toán phức tạp hơn sẽ cho lợi ích giảm dần; cải thiện đáng kể hơn chỉ đến từ việc bổ sung nguồn dữ liệu mới mang thông tin bổ sung.



Hình 3.4: Đường cong hiệu chuẩn xác suất sau khi hiệu chuẩn đẳng hướng

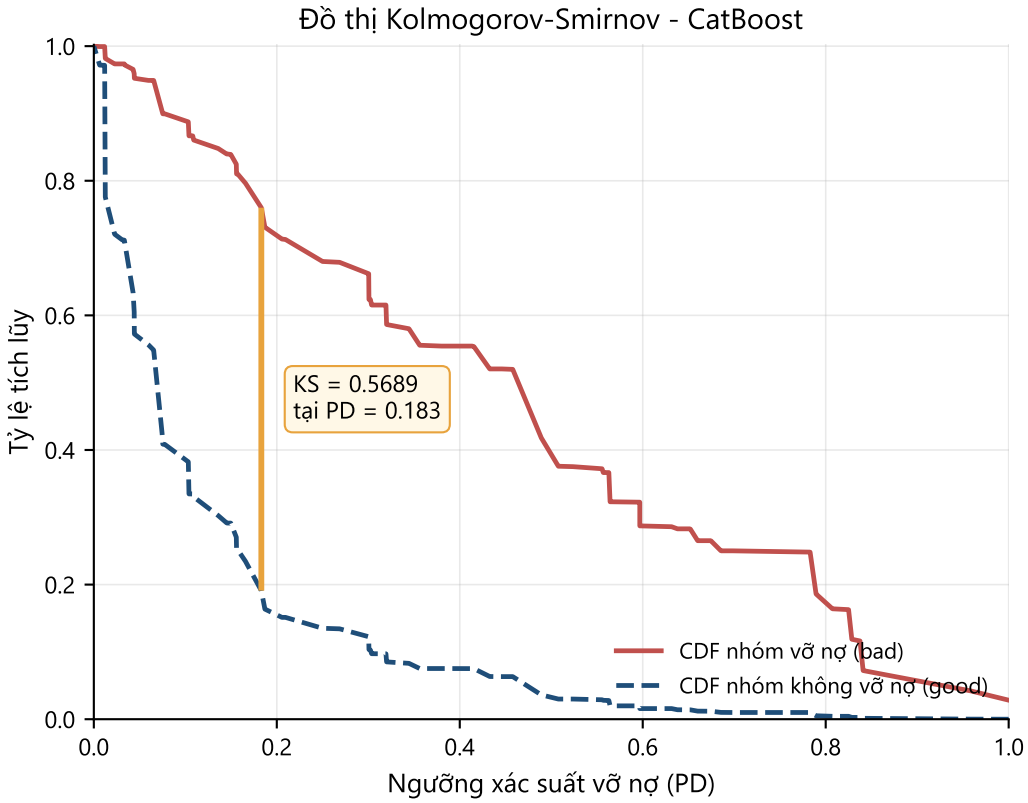
3.3.2 Đánh giá khả năng phân tách rủi ro

Khả năng phân tách rủi ro được đánh giá qua ba công cụ bổ trợ nhau.

Thống kê KS. Mô hình được chọn đạt KS $= 0,5689$, nghĩa là tại điểm cắt tối ưu, khoảng cách giữa phân phối tích lũy của nhóm tốt và nhóm xấu đạt 56,9 điểm phần trăm. Theo thực hành ngành, giá trị KS trên 0,40 được coi là mô hình có khả năng phân tách tốt.

Phân tích theo thập phân vị. Bảng 3.16 trình bày phân bố hồ sơ xấu theo mười nhóm điểm rủi ro.

Kết quả cho thấy thập phân vị rủi ro cao nhất tập trung 40,7% tổng số hồ sơ xấu – gấp hơn bốn lần mức phân bố ngẫu nhiên. Ba thập phân vị rủi ro cao nhất chứa 76,8% tổng số hồ sơ xấu. Đây là thước đo trực tiếp giá trị vận hành của mô hình: nếu tổ chức



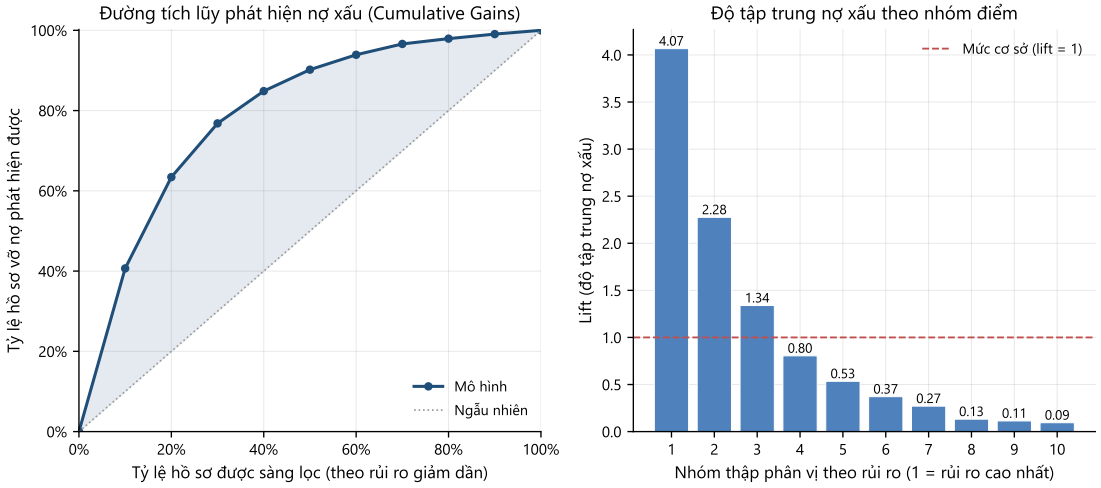
Hình 3.5: Đường cong Kolmogorov–Smirnov của mô hình được chọn triển khai

Bảng 3.16: Phân tích theo thập phân vị điểm rủi ro

Nhóm	Số hồ sơ	Số hồ sơ xấu	PD trung bình	Tỷ lệ nợ xấu (%)	Tỷ trọng nợ xấu (%)	Nợ xấu tích luỹ (%)	Lift	Lift tích luỹ
1	900	647	0,7130	71,89	40,67	40,67	4,07	4,07
2	900	362	0,3976	40,22	22,75	63,42	2,28	3,17
3	900	213	0,2196	23,67	13,39	76,81	1,34	2,56
4	900	128	0,1556	14,22	8,05	84,85	0,80	2,12
5	900	85	0,0975	9,44	5,34	90,19	0,53	1,80
6	900	59	0,0663	6,56	3,71	93,90	0,37	1,57
7	900	43	0,0482	4,78	2,70	96,61	0,27	1,38
8	900	21	0,0258	2,33	1,32	97,93	0,13	1,22
9	900	18	0,0119	2	1,13	99,06	0,11	1,10
10	900	15	0,0091	1,67	0,94	100	0,09	1

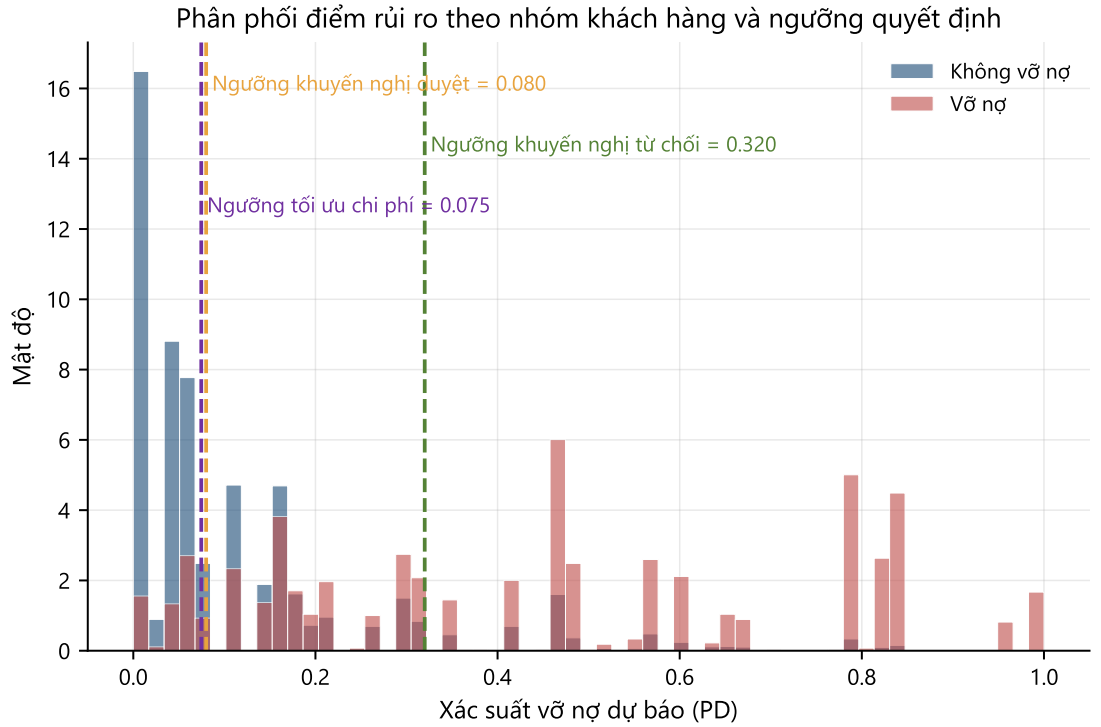
Nhóm 1 gồm 10% hồ sơ có điểm rủi ro cao nhất. Lift là tỷ số giữa mật độ nợ xấu của nhóm và mật độ nợ xấu trung bình.

tín dụng chỉ có nguồn lực để thẩm định kỹ 30% số hồ sơ, việc ưu tiên theo điểm rủi ro của mô hình cho phép bao phủ hơn ba phần tư số hồ sơ có vấn đề.



Hình 3.6: Đường cong gains và lift theo thập phân vị điểm rủi ro

Phân bố điểm rủi ro. Hình 3.7 cho thấy phân bố điểm rủi ro của hai nhóm hồ sơ và vị trí của các ngưỡng quyết định.



Hình 3.7: Phân bố xác suất vỡ nợ dự báo theo nhóm hồ sơ thực tế

3.3.3 So sánh hiệu năng giữa các thuật toán

3.3.3.1 Chênh lệch giữa các thuật toán là nhỏ

Quan sát nổi bật nhất từ Bảng 3.15 là **khoảng cách giữa các mô hình rất hẹp**. Chênh lệch AUC giữa mô hình được chọn triển khai (CatBoost) và hồi quy logistic chỉ là 0,0035 – chưa tới nửa điểm phần trăm. Trong khi đó, hồi quy logistic có ba ưu thế rõ rệt: thời gian huấn luyện ngắn hơn hàng chục lần, mỗi hệ số có thể diễn giải trực tiếp, và xác suất đầu ra vốn đã được hiệu chuẩn tốt mà không cần bước hiệu chuẩn bổ sung.

Kết quả này phù hợp với phát hiện của Lessmann và cộng sự [8] trên các bộ dữ liệu tín dụng thực: các mô hình học tập hợp cho kết quả tốt hơn nhưng mức chênh lệch so với hồi quy logistic không lớn.

3.3.3.2 Giới hạn độ phân giải của phép đo

Khoảng cách hẹp giữa các mô hình đặt ra một câu hỏi phương pháp mà phần lớn nghiên cứu so sánh thuật toán không nêu: *chênh lệch* AUC *nhỏ tới đâu thì còn mang thông tin?*

Để trả lời, đề án chạy lại toàn bộ bước huấn luyện trên cùng tập dữ liệu, cùng siêu tham số và cùng hạt giống ngẫu nhiên. Kết quả tái lập chính xác tới bốn chữ số thập phân ở cả 12 mô hình. Tuy nhiên khi chạy lại *bước tinh chỉnh siêu tham số*, giá trị AUC kiểm định chéo đo được dao động khoảng 3×10^{-4} giữa các lần chạy. Nguyên nhân mang tính kỹ thuật thuần túy: các thư viện boosting dựng biểu đồ tần suất song song nhiều luồng, nên thứ tự cộng dồn số thực dấu phẩy động thay đổi theo cách hệ điều hành cấp phát luồng.

Mức dao động này nhỏ, nhưng không nhỏ hơn khoảng cách giữa các mô hình dẫn đầu. Hệ quả trực tiếp đã được quan sát trong quá trình thực nghiệm: hai bộ siêu tham số của XGBoost có AUC kiểm định chéo cách nhau $1{,}6 \times 10^{-4}$ đã đổi chỗ cho nhau giữa hai lần chạy, kéo theo thứ hạng của chính mô hình đó trên tập kiểm thử cũng thay đổi.

Kết luận rút ra có ý nghĩa với mọi nghiên cứu so sánh thuật toán trên bài toán này: **thứ hạng ở chữ số thập phân thứ tư của** AUC **không phải là bằng chứng về sự vượt trội**. Các mô hình chênh nhau dưới ngưỡng đó cần được coi là tương đương, và việc lựa chọn phải dựa trên các tiêu chí khác – chi phí tính toán, khả năng giải thích, độ ổn định – chứ không dựa trên bảng xếp hạng.

3.3.3.3 Đánh đổi giữa chất lượng và chi phí tính toán

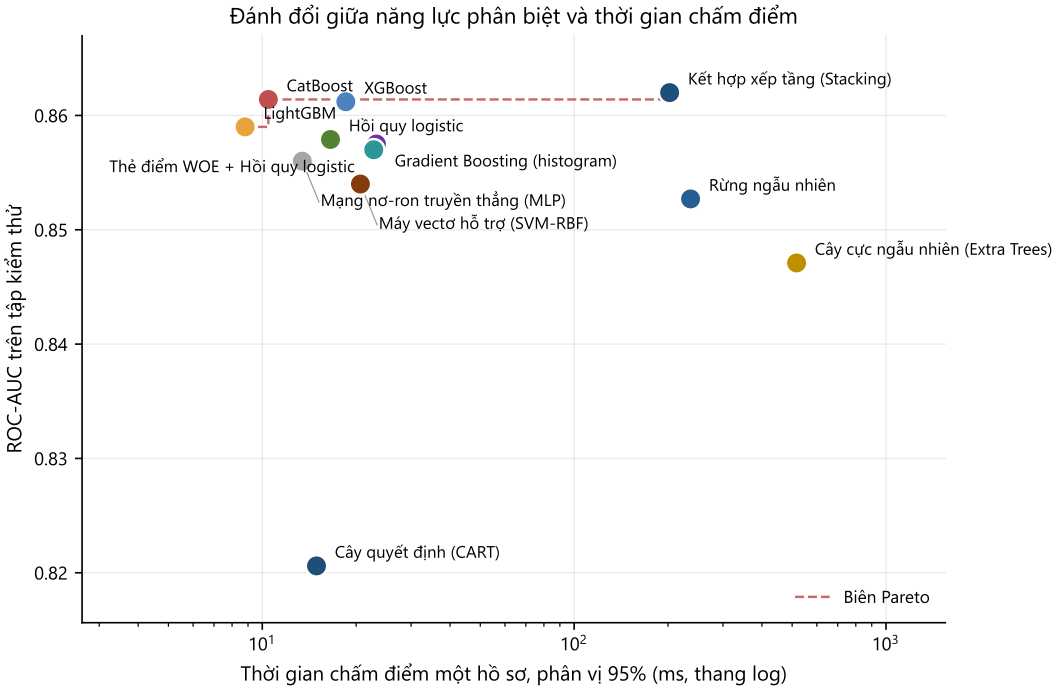
Bảng 3.17 trình bày chi phí huấn luyện và thời gian chấm điểm một hồ sơ của từng mô hình.

Bảng 3.17: Chi phí huấn luyện và thời gian chấm điểm một hồ sơ

Mô hình	Nhóm	Thời gian HL (s)	Chấm điểm p50 (ms)	Chấm điểm p95 (ms)	Số vòng lặp
Kết hợp xếp tầng (Stacking)	Kết hợp xếp tầng	214,8	141,38	202,39	–
CatBoost	Học tập hợp tuần tự	91,5	4,61	10,46	353
XGBoost	Học tập hợp tuần tự	20,7	16,78	18,53	706
LightGBM	Học tập hợp tuần tự	10,8	7,85	8,81	156
Hồi quy logistic	Tuyến tính	3,2	10,63	16,55	94
Gradient Boosting (histogram)	Học tập hợp tuần tự	50,5	13,14	23,23	184
Thẻ điểm WOE + Hồi quy logistic	Tuyến tính	7,6	11,12	22,77	74
Mạng nơ-ron truyền thẳng (MLP)	Mạng nơ-ron	24,1	6,42	13,44	35
Máy vectơ hỗ trợ (SVM-RBF)	Máy vectơ hỗ trợ	16,1	15,10	20,64	–
Rừng ngẫu nhiên	Học tập hợp song song	24	188,81	236,25	–
Cây cực ngẫu nhiên (Extra Trees)	Học tập hợp song song	11,8	383,00	516,63	–
Cây quyết định (CART)	Cây quyết định	5,5	12,06	14,93	–

Hình 3.8 biểu diễn quan hệ giữa chất lượng dự báo và thời gian chấm điểm.

Đồ thị cho thấy một số mô hình nằm rõ rệt phía dưới đường biên hiệu quả. Rõ nhất là mô hình kết hợp xếp tầng: nó đổi 0,0006 điểm AUC lấy thời gian chấm điểm cao gấp 19,4 lần (202,39 ms so với 10,46 ms ở phân vị 95). Extra Trees và rừng ngẫu nhiên vừa chậm hơn vừa kém chính xác hơn nhóm boosting. Với bài toán kiểm duyệt trực tuyến – nơi kết quả phải trả về trong lúc cán bộ tín dụng đang làm việc với hồ sơ – những mô hình này không phải lựa chọn hợp lý dù chỉ xét riêng góc độ kỹ thuật.



Hình 3.8: Đánh đổi giữa chất lượng dự báo và thời gian chấm điểm một hồ sơ

3.3.3.4 Tiêu chí chọn mô hình triển khai

Hai phân tích trên dẫn tới một quy tắc lựa chọn cụ thể, thay cho cách lấy thẳng mô hình đứng đầu bảng xếp hạng AUC. Quy tắc gồm hai bước:

(1) **Xác định nhóm tương đương về chất lượng:** mọi mô hình có AUC nằm trong khoảng 0,002 so với mô hình dẫn đầu. Ngưỡng này được chọn lớn hơn một bậc so với dao động đo đạc đã xác định ở mục 3.3.3.2, đồng thời vẫn nhỏ hơn mức chênh lệch có ý nghĩa nghiệp vụ.

(2) **Trong nhóm đó, chọn mô hình có thời gian chấm điểm thấp nhất** – tức mô hình nằm trên biên Pareto của Hình 3.8.

Áp dụng trên kết quả thực nghiệm, nhóm tương đương gồm 3 mô hình: kết hợp xếp tầng (0,8620), CatBoost (0,8614) và XGBoost (0,8612). Thời gian chấm điểm ở phân vị 95 của ba mô hình lần lượt là 202,39 ms, 10,46 ms và 18,53 ms. Mô hình được chọn triển khai là CatBoost.

Lựa chọn này có hai căn cứ. Thứ nhất, nếu lấy mô hình kết hợp xếp tầng, thời gian xử lý một hồ sơ sẽ vượt mục tiêu 100 ms đặt ra tại mục 2.1.3 – nghĩa là đánh đổi một yêu cầu đã công bố lấy 0,0006 điểm AUC nằm trong vùng nhiễu đo. Thứ hai, quy tắc này cho kết quả *ổn định*: khi thứ hạng trong nhóm dẫn đầu đảo chiều giữa các lần

chạy, mô hình được chọn không đổi, vì tiêu chí quyết định là thời gian chấm điểm – đại lượng chênh nhau hàng chục lần chứ không phải vài phần vạn.

3.3.3.5 Tác động nghiệp vụ

Bảng 3.18 quy đổi chất lượng thống kê thành các chỉ tiêu nghiệp vụ tại ngưỡng tối ưu chi phí.

Bảng 3.18: Tác động nghiệp vụ của các mô hình tại ngưỡng tối ưu chi phí

Mô hình	Ngưỡng	Tỷ lệ duyệt	Nợ xấu sau duyệt	Chi phí	Accuracy	Precision	Recall
Kết hợp xếp tầng (Stacking)	**0,0501**	**44,0%**	**2,98%**	**0,5532**	**0,5910**	**0,2925**	**0,9258**
CatBoost	0,0746	50,5%	3,52%	0,5497	0,6459	0,3210	0,8994
XGBoost	0,0789	49,2%	3,32%	0,5431	0,6366	0,3161	0,9076
LightGBM	0,0758	45,2%	3,19%	0,5586	0,6003	0,2965	0,9183
Hồi quy logistic	0,0729	43,4%	2,94%	0,5550	0,5856	0,2899	0,9277
Gradient Boosting (histogram)	0,0749	44,7%	3,21%	0,5624	0,5952	0,2938	0,9189
Thẻ điểm WOE + Hồi quy logistic	0,0848	48,0%	3,26%	0,5464	0,6259	0,3101	0,9114
Mạng nơ-ron truyền thẳng (MLP)	0,0778	48,7%	3,40%	0,5510	0,6311	0,3126	0,9063
Máy vectơ hỗ trợ (SVM-RBF)	0,0702	46,1%	3,28%	0,5588	0,6074	0,2999	0,9145
Rừng ngẫu nhiên	0,0682	49,4%	3,62%	0,5618	0,6350	0,3140	0,8988
Cây cực ngẫu nhiên (Extra Trees)	0,0866	42,8%	3,17%	0,5714	0,5777	0,2854	0,9233
Cây quyết định (CART)	0,0707	38,1%	4,08%	0,6444	0,5267	0,2605	0,9120

Ngưỡng được chọn theo hàm chi phí với tỷ lệ $c_{FN} : c_{FP} = 12 : 1$ *trên tập kiểm định.*

3.3.3.6 Mức độ quá khớp và độ ổn định theo thời gian

Mức độ quá khớp. Bảng 3.19 đối chiếu AUC trên tập kiểm định với AUC trên tập kiểm thử. Chênh lệch trung bình giữa hai tập là 0,0027 và mức lớn nhất là 0,0050 – đều rất nhỏ so với bản thân giá trị AUC. Kết quả này cho thấy bốn cơ chế kiểm soát quá khớp trình bày ở mục 2.7.4 đã phát huy tác dụng: không mô hình nào phụ thuộc quá mức vào đặc thù của giai đoạn huấn luyện.

Bảng 3.19: Mức độ quá khớp đo bằng chênh lệch AUC giữa hai tập dữ liệu

Mô hình	AUC (kiểm định)	AUC (kiểm thử)	Chênh lệch
Kết hợp xếp tầng (Stacking)	0,8639	0,8620	0,0019
CatBoost	0,8633	0,8614	0,0019
XGBoost	0,8646	0,8612	0,0034
LightGBM	0,8595	0,8590	0,0005
Hồi quy logistic	0,8590	0,8579	0,0011
Gradient Boosting (histogram)	0,8616	0,8575	0,0041
Thẻ điểm WOE + Hồi quy logistic	0,8610	0,8570	0,0040
Mạng nơ-ron truyền thẳng (MLP)	0,8554	0,8560	-0,0006
Máy vectơ hỗ trợ (SVM-RBF)	0,8578	0,8540	0,0038
Rừng ngẫu nhiên	0,8565	0,8527	0,0038
Cây cực ngẫu nhiên (Extra Trees)	0,8521	0,8471	0,0050
Cây quyết định (CART)	0,8231	0,8206	0,0025

Chênh lệch dương lớn cho thấy mô hình phụ thuộc quá mức vào đặc thù của giai đoạn huấn luyện.

Trôi dạt phân phối dữ liệu. Bảng 3.20 trình bày mười đặc trưng có mức trôi dạt lớn nhất. Toàn bộ tập đặc trưng có PSI dưới ngưỡng cảnh báo, với giá trị lớn nhất là 0,0598; số đặc trưng ở mức cảnh báo là 0 và ở mức báo động là 0.

Chất lượng dự báo theo thời gian. Bảng 3.21 theo dõi chất lượng dự báo theo từng tháng của giai đoạn kiểm thử. Giá trị AUC dao động trong khoảng hẹp quanh mức 0,86 mà không có xu hướng giảm rõ rệt, và chênh lệch giữa tỷ lệ nợ xấu thực tế với mức PD trung bình dự báo luôn dưới một điểm phần trăm. Trong phạm vi bốn tháng quan sát, mô hình giữ được cả khả năng phân biệt lẫn mức hiệu chuẩn. Tuy nhiên, bốn tháng là

Bảng 3.20: Mười đặc trưng có mức trôi dạt phân phối lớn nhất

Đặc trưng	PSI	Trạng thái
salary_cnt_90d	0,0598	ỔN ĐỊNH
salary_cnt_30d	0,0571	ỔN ĐỊNH
income_stability	0,0533	ỔN ĐỊNH
salary_cnt_180d	0,0504	ỔN ĐỊNH
income_verification_ratio	0,0395	ỔN ĐỊNH
outflow_ratio_30d	0,0388	ỔN ĐỊNH
salary_amt_30d	0,0374	ỔN ĐỊNH
net_flow_30d	0,0363	ỔN ĐỊNH
txn_amt_std_30d	0,0336	ỔN ĐỊNH
inflow_to_installment	0,0291	ỔN ĐỊNH

Ngưỡng cảnh báo PSI = 0,10*; ngưỡng báo động PSI* = 0,25.

khoảng thời gian ngắn so với chu kỳ suy giảm điển hình của mô hình tín dụng trong thực tế, nên kết luận về độ ổn định chỉ có giá trị trong phạm vi dữ liệu thực nghiệm.

Bảng 3.21: Chất lượng dự báo của mô hình theo từng tháng của giai đoạn kiểm thử

Tháng	Số hồ sơ	Nợ xấu thực tế (%)	PD dự báo trung bình (%)	Chênh lệch (đpt)	AUC	KS	Gini
2026-03	1.652	17,86	17,76	-0,09	0,8665	0,5953	0,7330
2026-04	2.485	17,46	17,13	-0,33	0,8584	0,5730	0,7168
2026-05	2.429	18,53	17,74	-0,79	0,8551	0,5673	0,7102
2026-06	2.434	16,93	17,26	0,33	0,8679	0,5782	0,7358

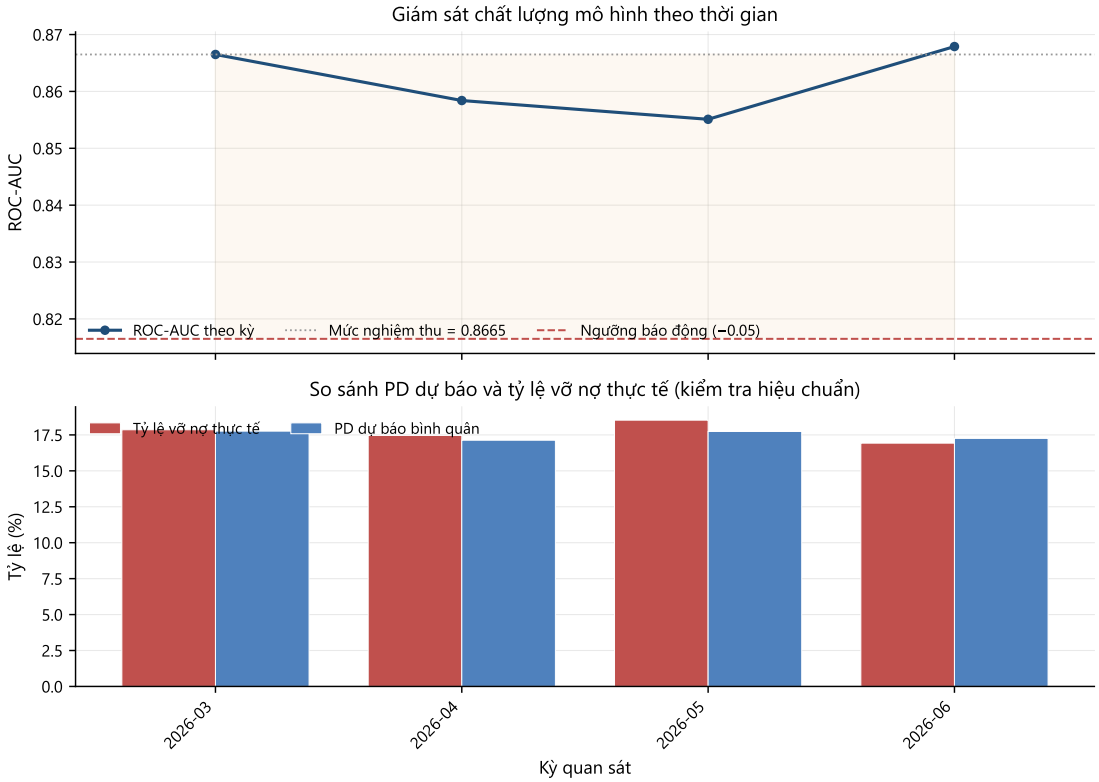
Chênh lệch tính bằng điểm phần trăm giữa mức PD dự báo trung bình và tỷ lệ nợ xấu thực tế của tháng.

3.4 Mô phỏng và giải thích mô hình

3.4.1 Thử nghiệm giải thích quyết định mô hình

3.4.1.1 Giải thích ở cấp độ toàn cục

Phân tích SHAP được thực hiện trên mẫu đại diện của tập kiểm thử. Bảng 3.22 tổng hợp đóng góp theo nhóm nguồn dữ liệu.



Hình 3.9: Diễn biến chất lượng dự báo theo tháng trên giai đoạn kiểm thử

Bảng 3.22: Tỷ trọng đóng góp vào quyết định của mô hình theo nhóm đặc trưng

Nhóm đặc trưng	Số đặc trưng	Tổng |SHAP|	|SHAP| trung bình	|SHAP| lớn nhất	Tỷ trọng đóng góp (%)
Hành vi giao dịch	76	1,2895	0,0170	0,1623	34,00
Lịch sử tín dụng (CIC)	14	1,1692	0,0835	0,4217	30,83
Biến tổ hợp	12	0,9091	0,0758	0,1899	23,97
Thông tin cá nhân	8	0,2662	0,0333	0,0909	7,02
Tham số khoản vay	6	0,1587	0,0264	0,0432	4,18

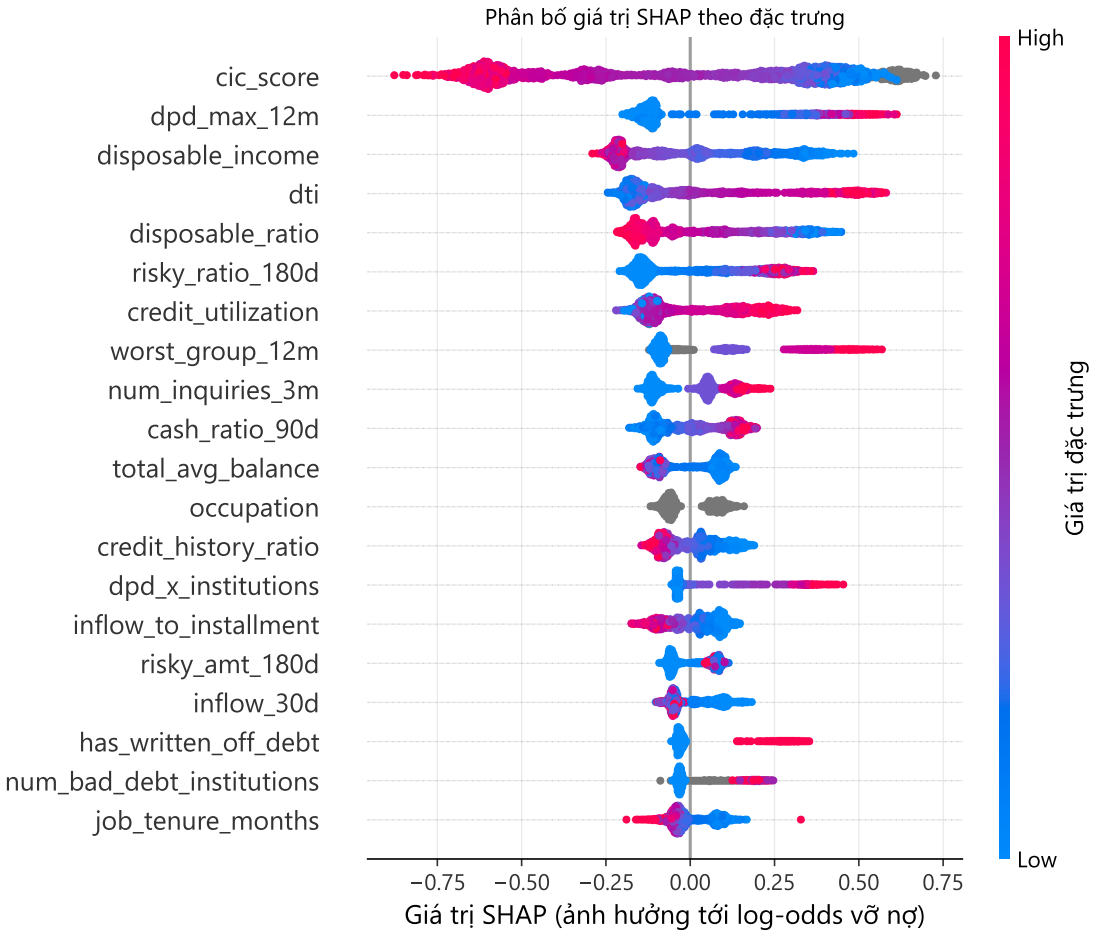
Tính bằng tổng giá trị SHAP tuyệt đối trung bình của các đặc trưng trong từng nhóm, chuẩn hóa về tổng bằng 100%.

Kết quả cho thấy nhóm đặc trưng hành vi giao dịch đóng góp 34,0% vào quyết định của mô hình – cao hơn nhóm CIC (30,8%) vốn được coi là nguồn thông tin truyền thống quan trọng nhất. Nhóm biến tổ hợp đóng góp 24,0%, còn hai nhóm thông tin cá nhân và tham số khoản vay chỉ đóng góp lần lượt 7,0% và 4,2%.

Phát hiện này có ý nghĩa thực tiễn: dữ liệu giao dịch là nguồn mà tổ chức tín dụng tự sở hữu, không phát sinh chi phí truy vấn bên ngoài và luôn có sẵn kể cả với nhóm khách hàng thiếu lịch sử tín dụng. Việc nhóm này đóng góp phần lớn nhất vào

quyết định của mô hình là căn cứ định lượng cho khuyến nghị khai thác dữ liệu giao dịch trong công tác kiểm duyệt tín dụng.

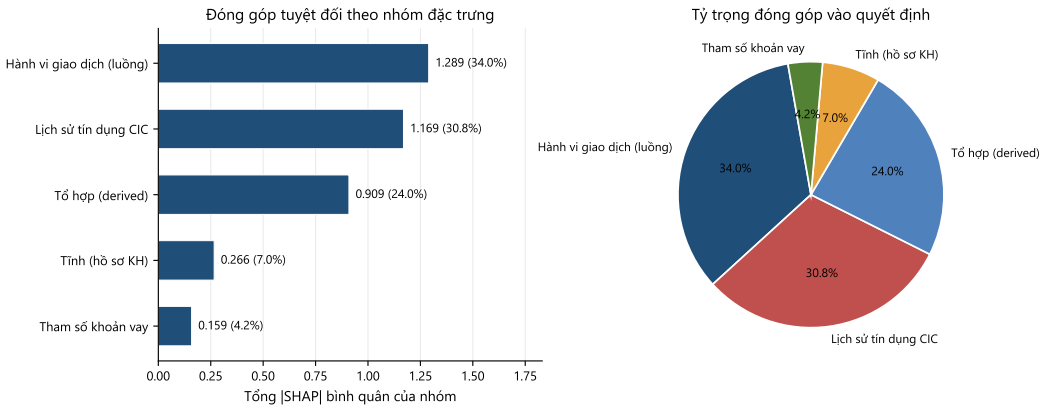
Kết quả trên cần được đặt cạnh phân tích IV ở mục 3.2.1 để tránh diễn giải sai. Xét từng đặc trưng riêng lẻ, biến CIC mạnh hơn hẳn biến giao dịch. Nhưng trong mô hình hoàn chỉnh, tổng đóng góp của nhóm giao dịch lại lớn hơn, vì nhóm này gồm nhiều đặc trưng bổ sung thông tin cho nhau ở những khía cạnh khác nhau của hành vi tài chính.



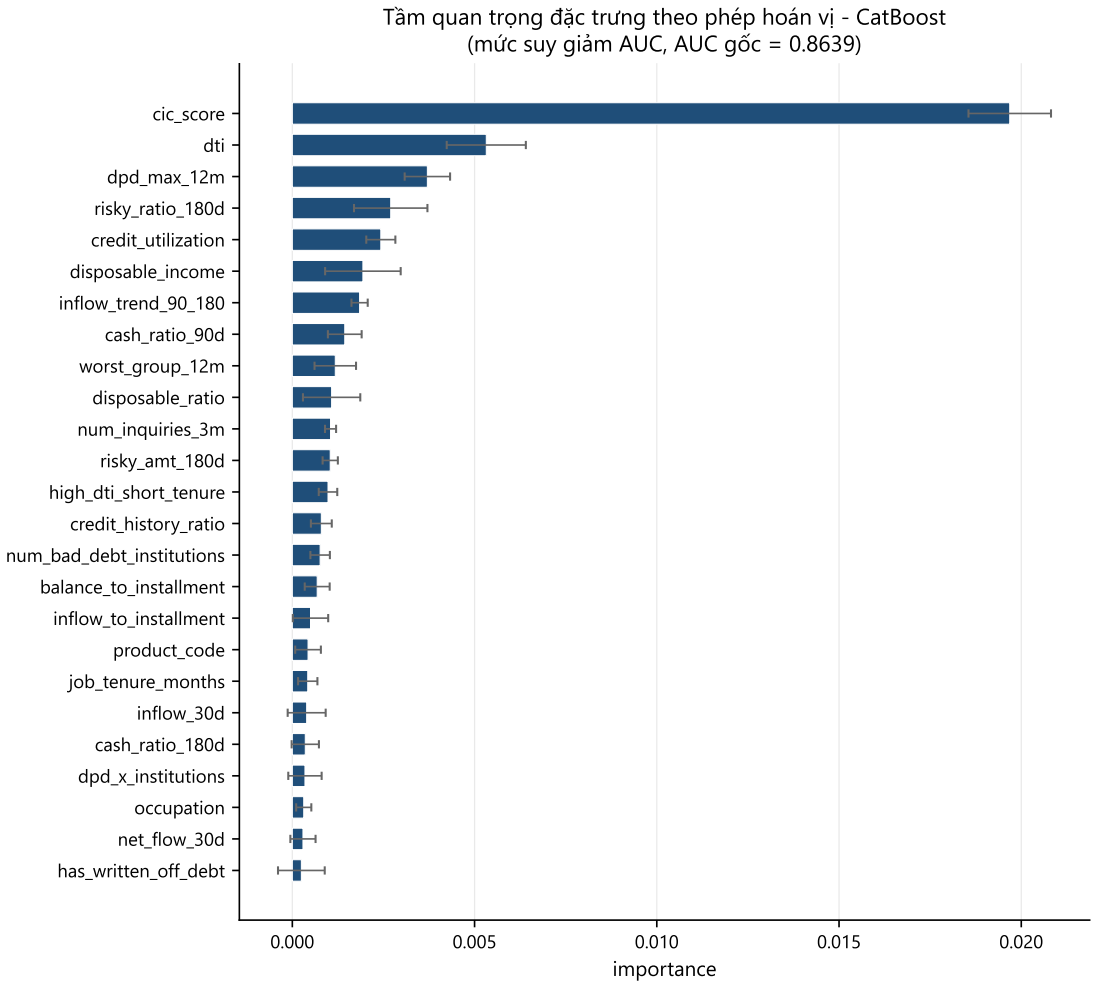
Hình 3.10: Biểu đồ tóm tắt SHAP của hai mươi đặc trưng quan trọng nhất

3.4.1.2 Kiểm chứng chéo bằng phép hoán vị

Kết quả SHAP được kiểm chứng độc lập bằng phép hoán vị: với mỗi đặc trưng, giá trị của nó được xáo trộn ngẫu nhiên và mức suy giảm AUC được ghi nhận. Thứ hạng các đặc trưng theo hai phương pháp về cơ bản trùng khớp ở nhóm đầu bảng, xác nhận rằng kết quả SHAP không phải là sản phẩm của một đặc thù kỹ thuật nào đó trong cách tính.



Hình 3.11: Tỷ trọng đóng góp vào quyết định theo nhóm nguồn dữ liệu



Hình 3.12: Tầm quan trọng đặc trưng theo phép hoán vị

3.4.1.3 Giải thích ở cấp độ từng hồ sơ

Với mỗi hồ sơ, mô hình sinh danh sách lý do gồm ba thành phần: luật nghiệp vụ bị vi phạm, chỉ tiêu định lượng then chốt kèm giá trị thực tế, và các đặc trưng có đóng góp SHAP lớn nhất. Danh sách này được trả về cùng kết quả chấm điểm, cho phép cán bộ tín dụng đánh giá tính hợp lý của khuyến nghị thay vì phải chấp nhận một con số không có căn cứ.

3.4.2 Mô phỏng xác định ngưỡng phê duyệt tín dụng

3.4.2.1 So sánh ba tiêu chí xác định điểm cắt

Bảng 3.23 trình bày kết quả của ba tiêu chí xác định điểm cắt, tính trên tập kiểm định.

Bảng 3.23: So sánh ba tiêu chí xác định điểm cắt phê duyệt

Tiêu chí	Điểm cắt PD	Tỷ lệ duyệt (%)	Nợ xấu nhóm duyệt (%)	Nợ xấu nhóm từ chối (%)	Chi phí kỳ vọng
Tối thiểu chi phí (c_FN:c_FP = 12:1)	0,07	51,64	3,33	31,23	0,54
Tỷ lệ duyệt mục tiêu 70%	0,17	72,30	6,01	45,05	0,67
Trần nợ xấu nhóm duyệt 5%	0,15	65,30	4,92	39,23	0,60

Ba tiêu chí cho ba điểm cắt khác nhau rõ rệt, phản ánh ba cách đặt bài toán khác nhau. Tiêu chí tối thiểu chi phí cho điểm cắt thấp nhất (0,0746) và do đó thận trọng nhất, với tỷ lệ nợ xấu trong nhóm được duyệt chỉ 3,33%. Tiêu chí tỷ lệ duyệt mục tiêu 70% cho điểm cắt cao nhất, đổi lại tỷ lệ nợ xấu nhóm duyệt tăng lên 6,01%. Tiêu chí trần nợ xấu 5% nằm ở giữa, với tỷ lệ nợ xấu nhóm duyệt 4,92%.

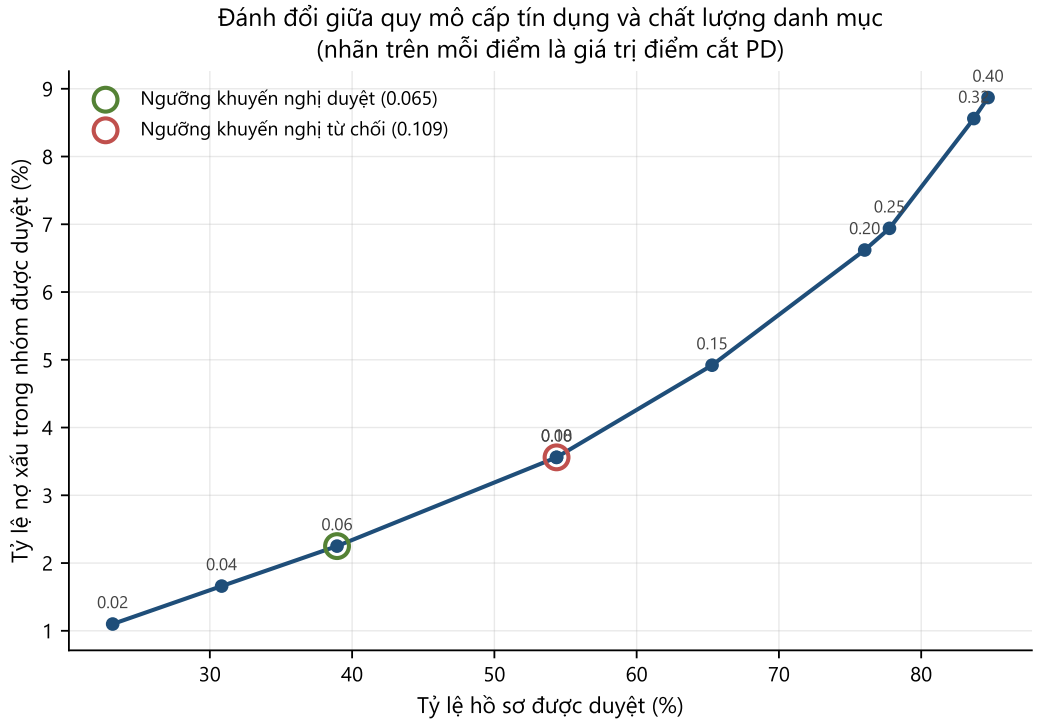
Việc trình bày song song ba tiêu chí – thay vì áp đặt một ngưỡng duy nhất – là có chủ đích: lựa chọn giữa chúng là *quyết định chính sách* thuộc thẩm quyền của tổ chức tín dụng, không phải quyết định kỹ thuật của người xây dựng mô hình.

3.4.2.2 Độ nhạy của kết quả theo điểm cắt

Bảng 3.24 và Hình 3.13 định lượng đánh đổi giữa quy mô cấp tín dụng và chất lượng danh mục.

Bảng 3.24: Độ nhạy của kết quả kiểm duyệt theo điểm cắt

Điểm cắt PD	Số hồ sơ duyệt	Tỷ lệ duyệt (%)	Nợ xấu nhóm duyệt (%)	Nợ xấu bị chặn (%)	Chi phí kỳ vọng
0.02	2.085	23,17	1,10	21,56	0,63
0.04	2.775	30,83	1,66	23,58	0,59
0.06	3.505	38,94	2,25	26,11	0,56
0.08	4.893	54,37	3,56	32,63	0,54
0.1	4.893	54,37	3,56	32,63	0,54
0.15	5.877	65,30	4,92	39,23	0,60
0.2	6.843	76,03	6,62	49,19	0,73
0.25	6.999	77,77	6,94	51,37	0,76
0.32	7.533	83,70	8,56	59,24	0,93
0.4	7.623	84,70	8,87	60,86	0,96



Hình 3.13: Đánh đổi giữa tỷ lệ duyệt và tỷ lệ nợ xấu theo điểm cắt

Đường cong này là công cụ đối thoại giữa bộ phận mô hình và bộ phận kinh doanh: thay vì tranh luận về một giá trị ngưỡng trừu tượng, mỗi lựa chọn được quy đổi thành hệ quả cụ thể về tỷ lệ duyệt và tỷ lệ nợ xấu.

3.4.2.3 Hai ngưỡng cho ba vùng quyết định

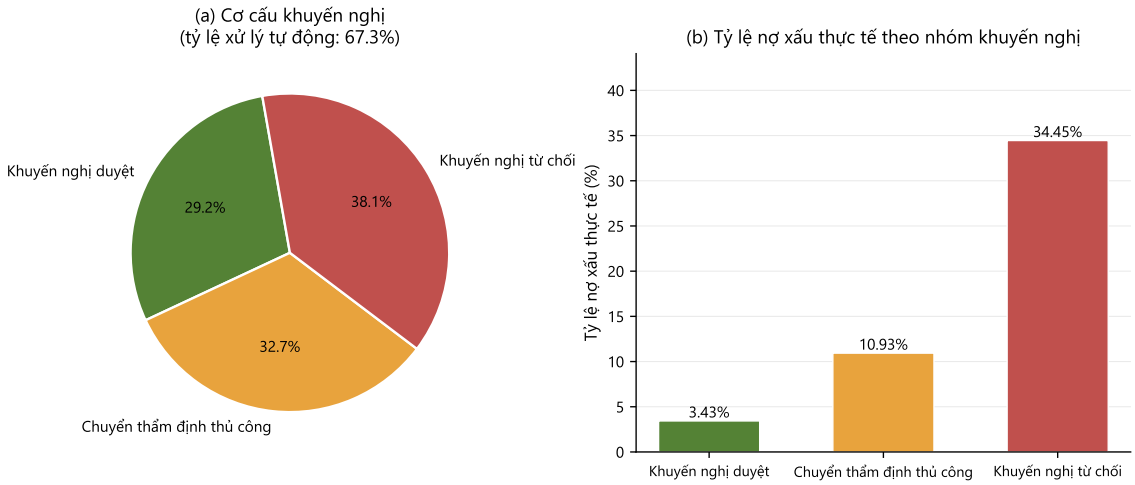
Từ điểm cắt tối ưu chi phí, hai ngưỡng phân vùng được xác định: $\tau_{\text{duyệt}} = 0,0654$ và $\tau_{\text{từ chối}} = 0,1092$. Kết quả áp dụng trên tập kiểm thử được trình bày tại Bảng 3.25.

Bảng 3.25: Cơ cấu khuyến nghị của mô hình và tỷ lệ nợ xấu thực tế theo từng nhóm

Kết quả	Số hồ sơ	Tỷ trọng (%)	Tỷ lệ nợ xấu thực tế (%)
Khuyến nghị duyệt	1.459	29,18	3,43
Chuyển thẩm định thủ công	1.637	32,74	10,93
Khuyến nghị từ chối	1.904	38,08	34,45

Kết quả xác nhận mô hình hoạt động đúng thiết kế: tỷ lệ nợ xấu thực tế tăng đơn điệu theo ba nhóm khuyến nghị, lần lượt là 3,43% ở nhóm khuyến nghị duyệt, 10,93% ở nhóm chuyển thẩm định và 34,45% ở nhóm khuyến nghị từ chối. Mức chênh lệch hơn mười lần giữa nhóm đầu và nhóm cuối cho thấy khả năng phân tách thực tế của mô hình.

Tỷ lệ hồ sơ được xử lý tự động đạt 67,26%, nghĩa là khoảng một phần ba số hồ sơ (32,74%) vẫn cần cán bộ tín dụng xem xét. Đây là kết quả phù hợp với định hướng *hỗ trợ* của đề án: những hồ sơ mà mô hình không đủ chắc chắn được chuyển cho con người thay vì bị quyết định máy móc.



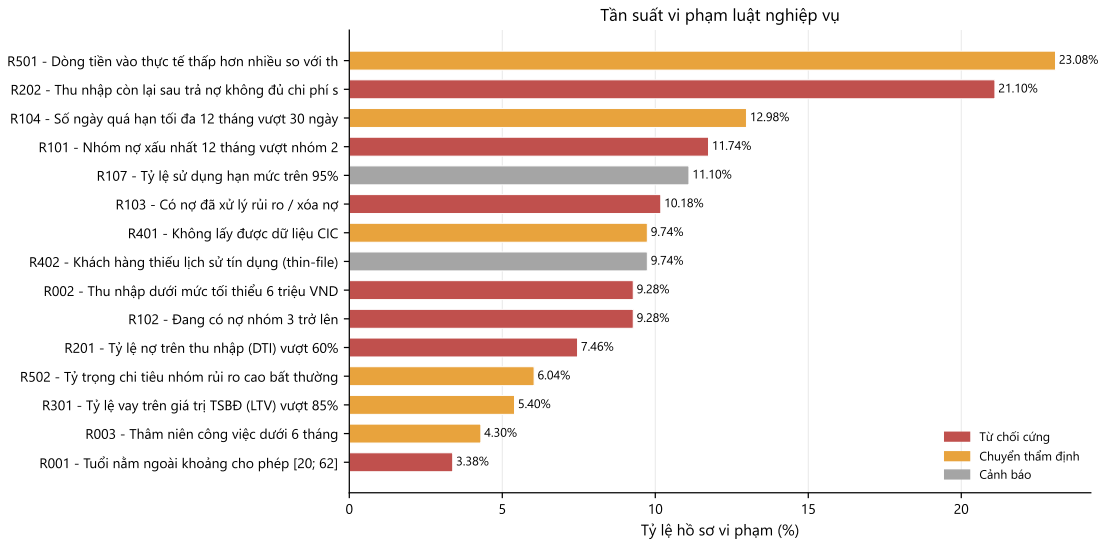
Hình 3.14: Cơ cấu khuyến nghị và tỷ lệ nợ xấu thực tế theo từng nhóm

3.4.2.4 Tần suất vi phạm luật nghiệp vụ

Bảng 3.26 trình bày tần suất vi phạm của 21 luật nghiệp vụ trong quá trình mô phỏng.

Bảng 3.26: Tần suất vi phạm các luật nghiệp vụ

Mã luật	Tên luật	Hành động	Tỷ lệ vi phạm
R501	Dòng tiền vào thực tế thấp hơn nhiều so với thu nhập khai báo	REVIEW	23,08%
R202	Thu nhập còn lại sau trả nợ không đủ chi phí sinh hoạt	HARD_ REJECT	21,10%
R104	Số ngày quá hạn tối đa 12 tháng vượt 30 ngày	REVIEW	12,98%
R101	Nhóm nợ xấu nhất 12 tháng vượt nhóm 2	HARD_ REJECT	11,74%
R107	Tỷ lệ sử dụng hạn mức trên 95%	WARNING	11,10%
R103	Có nợ đã xử lý rủi ro / xóa nợ	HARD_ REJECT	10,18%
R401	Không lấy được dữ liệu CIC	REVIEW	9,74%
R402	Khách hàng thiếu lịch sử tín dụng (thin-file)	WARNING	9,74%
R002	Thu nhập dưới mức tối thiểu 6 triệu VND	HARD_ REJECT	9,28%
R102	Đang có nợ nhóm 3 trở lên	HARD_ REJECT	9,28%
R201	Tỷ lệ nợ trên thu nhập (DTI) vượt 60%	HARD_ REJECT	7,46%
R502	Tỷ trọng chi tiêu nhóm rủi ro cao bất thường	REVIEW	6,04%



Hình 3.15: Tần suất vi phạm các luật nghiệp vụ

3.4.3 Thử nghiệm tích hợp API và luồng xử lý hồ sơ

3.4.3.1 Kết quả tích hợp dịch vụ REST

Hệ thống được đóng gói thành một dịch vụ REST với năm điểm cuối. Kết quả thử nghiệm tích hợp trình bày tại Bảng 3.27.

Bảng 3.27: Kết quả thử nghiệm tích hợp dịch vụ REST

Điểm cuối	Mô tả	Mã HTTP	Kết quả
GET /health	Kiểm tra trạng thái dịch vụ	200	Đạt
POST /api/v1/screen	Kiểm duyệt từng hồ sơ (50 lần gọi)	200	50/50 thành công, 62.4 ms/hồ sơ
POST /api/v1/screen/batch	Kiểm duyệt theo lô 50 hồ sơ	200	50 hồ sơ, 2245 ms (44.79 ms/hồ sơ)
GET /api/v1/features/{id}	Truy xuất vector đặc trưng đầu vào	200	157 đặc trưng
GET /admin/rules	Danh mục luật nghiệp vụ đang áp dụng	200	21 luật

Toàn bộ điểm cuối hoạt động đúng. Điểm cuối kiểm duyệt theo lô cho thời gian xử lý bình quân mỗi hồ sơ thấp hơn so với gọi từng hồ sơ riêng lẻ, phản ánh phần chi phí cố định của mỗi lần gọi dịch vụ được phân bổ trên nhiều hồ sơ.

3.4.3.2 Thời gian xử lý một hồ sơ

Bảng 3.28 phân rã thời gian xử lý một hồ sơ theo từng chặng.

Bảng 3.28: Thời gian xử lý một hồ sơ theo từng chặng

Chặng xử lý	Trung bình (ms)	p50 (ms)	p95 (ms)	p99 (ms)
Chấm điểm mô hình	40,174	34,773	74,507	98,067
Áp dụng luật nghiệp vụ	0,048	0,046	0,086	0,126
Áp dụng chính sách	0,053	0,051	0,088	0,154
Tổng cộng	40,327	34,928	74,657	98,372

Đo trên một tiến trình đơn, không tính thời gian truyền qua mạng và thời gian truy vấn dữ liệu từ hệ thống nguồn.

Kết quả cho thấy **chấm điểm mô hình chiếm gần như toàn bộ** thời gian xử lý: trung bình 40,33 ms cho một hồ sơ, trong đó phần áp dụng luật nghiệp vụ và chính sách chỉ chiếm chưa tới 0,1 ms. Phân vị 95% của tổng thời gian là 74,66 ms và phân vị 99% là 98,37 ms, đều nằm dưới mục tiêu 100 ms đã đặt ra ở mục 2.1.3.

Thời gian chấm điểm trong mô phỏng quy trình (40,33 ms) cao hơn số đo ở bước huấn luyện (10,46 ms tại phân vị 95%) do hai phép đo thực hiện trong điều kiện khác nhau: bước huấn luyện đo trên ma trận đặc trưng đã chuẩn bị sẵn, còn mô phỏng quy trình đo toàn bộ đường xử lý từ dữ liệu đầu vào thô, bao gồm cả việc dựng khung dữ liệu, ép kiểu và ánh xạ hạng mục. Phần chênh lệch chính là chi phí của lớp tích hợp. Đây là kết quả có giá trị thực tiễn: khi triển khai, chi phí chuẩn bị dữ liệu đầu vào có thể lớn hơn chi phí suy luận của bản thân mô hình, nên việc tối ưu hiệu năng cần bắt đầu từ khâu này.

3.5 Đánh giá chung

3.5.1 So sánh với quy trình thẩm định truyền thống

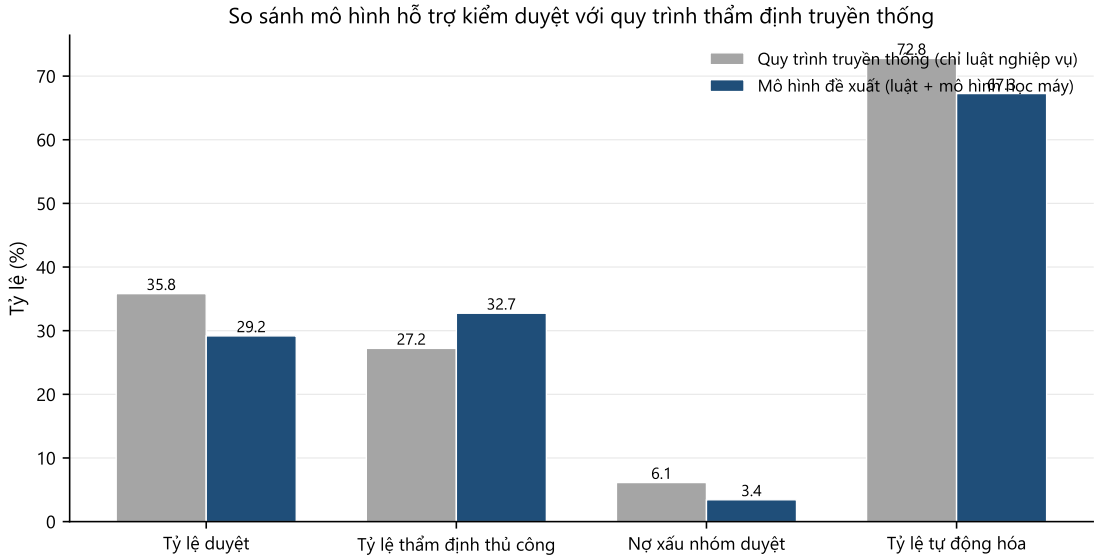
Để đánh giá giá trị thực tế của mô hình, đề án mô phỏng quy trình thẩm định truyền thống bằng chính bộ luật nghiệp vụ đang áp dụng, không sử dụng mô hình học máy: hồ sơ vi phạm luật loại trừ cứng bị từ chối, hồ sơ vi phạm luật cảnh báo được chuyển thẩm định, phần còn lại được duyệt. Hai phương pháp được chạy trên cùng một tập hồ sơ; kết quả trình bày tại Bảng 3.29.

Bảng 3.29: So sánh mô hình đề xuất với quy trình thẩm định truyền thống

Chỉ tiêu	Truyền thống	Đề xuất
Tỷ lệ duyệt (%)	35.82	29.18
Tỷ lệ thẩm định thủ công (%)	27.22	32.74
Tỷ lệ từ chối (%)	36.96	38.08
Nợ xấu nhóm duyệt (%)	6.14	3.43
Nợ xấu chặn được (%)	33.93	34.45
Tỷ lệ tự động hóa (%)	72.78	67.26
Thời gian xử lý (ms/hồ sơ)	0.262	40.327

Quy trình truyền thống được mô phỏng bằng bộ luật nghiệp vụ đang áp dụng, không sử dụng mô hình học máy.

Kết quả phản ánh một đánh đổi gồm bốn khía cạnh.



Hình 3.16: So sánh mô hình đề xuất với quy trình thẩm định truyền thống

Về chất lượng danh mục – cải thiện rõ rệt. Tỷ lệ nợ xấu trong nhóm hồ sơ được duyệt giảm từ 6,14% xuống 3,43%, tức giảm 2,71 điểm phần trăm, tương đương mức giảm tương đối 44,1%. Đây là chỉ tiêu có ý nghĩa kinh tế trực tiếp: với cùng quy mô dư nợ được cấp, tổn thất tín dụng kỳ vọng giảm gần một nửa.

Về quy mô cấp tín dụng – giảm. Đổi lại, tỷ lệ hồ sơ được duyệt giảm từ 35,82% xuống 29,18%. Hệ thống thận trọng hơn quy trình truyền thống: nó phát hiện và loại ra những hồ sơ mà bộ quy tắc cố định bỏ sót.

Về khối lượng công việc thủ công – tăng nhẹ. Tỷ lệ hồ sơ chuyển thẩm định thủ công tăng từ 27,22% lên 32,74%. Đây là hệ quả trực tiếp của thiết kế ba vùng: mô hình chủ động thừa nhận vùng không chắc chắn của mình thay vì đưa ra khuyến nghị dứt khoát cho mọi hồ sơ.

Về thời gian xử lý. Quy trình chỉ dùng luật nhanh hơn nhiều về mặt tính toán (dưới 0,2 ms so với 40,33 ms). Tuy nhiên so sánh này không phản ánh thực tế vận hành: trong quy trình truyền thống, phần lớn thời gian nằm ở công đoạn cán bộ tín dụng thu thập, đối chiếu và đánh giá hồ sơ – tính bằng phút hoặc giờ – chứ không phải ở việc kiểm tra bộ quy tắc. Mức chênh lệch vài chục mili giây giữa hai phương pháp là không đáng kể trên thang thời gian đó.

Diễn giải tổng hợp. Đánh đổi mà mô hình mang lại là: chấp nhận giảm 6,64 điểm phần trăm tỷ lệ duyệt và tăng 5,52 điểm phần trăm khối lượng thẩm định thủ công, để đổi lấy việc giảm gần một nửa tỷ lệ nợ xấu trong nhóm được duyệt. Mức đánh đổi này có phù hợp hay không phụ thuộc khẩu vị rủi ro và chiến lược kinh doanh của từng tổ chức. Khác biệt cơ bản so với bộ quy tắc cố định là mô hình *cho phép điều chỉnh* đánh đổi thông qua hai ngưỡng phân vùng, trong khi bộ quy tắc không có cơ chế tương đương.

3.5.2 Đối chiếu kết quả với các công trình nghiên cứu liên quan

Về thứ hạng giữa các thuật toán. Kết quả của đề án phù hợp với kết luận của Lessmann và cộng sự [8]: nhóm học tập hợp đứng đầu nhưng khoảng cách với hồi quy logistic không lớn. Chênh lệch AUC đo được trong đề án là 0,0035, thậm chí còn hẹp hơn khoảng 0,01–0,03 mà công trình trên ghi nhận trên các bộ dữ liệu tín dụng thực. Chênh lệch hẹp hơn có thể giải thích bằng đặc điểm của dữ liệu mô phỏng: quan hệ giữa biến tiềm ẩn và nhãn được sinh theo một hàm log-odds có cấu trúc tương đối trơn, nên phần quan hệ phi tuyến mà các mô hình học tập hợp khai thác được so với mô hình tuyến tính là hạn chế. Trên dữ liệu thực, nơi quan hệ giữa các biến phức tạp hơn, khoảng cách này nhiều khả năng sẽ rộng hơn. Các tổng quan hệ thống gần đây [9] cũng đi tới kết luận tương tự về thứ hạng giữa các nhóm thuật toán.

Về vai trò của đặc trưng so với thuật toán. Kết quả phân tích SHAP của đề án củng cố nhận định phổ biến trong các tổng quan: yếu tố quyết định chất lượng mô hình nằm ở chất lượng và độ phong phú của đặc trưng nhiều hơn ở việc lựa chọn thuật toán. Việc nhóm đặc trưng hành vi giao dịch đóng góp 34,0% – vượt cả nhóm CIC truyền thống – là minh chứng cụ thể cho nhận định này, đồng thời phù hợp với quan sát của Onay và Öztürk [10] về vai trò ngày càng lớn của dữ liệu hành vi trong bối cảnh dữ liệu lớn.

Về khoảng cách so với các nghiên cứu trong nước. Các nghiên cứu ứng dụng học máy trong đánh giá rủi ro tín dụng tại Việt Nam [4, 5] chủ yếu tập trung vào việc so sánh chất lượng dự báo giữa các thuật toán trên dữ liệu dạng bảng có sẵn. Đề án này bổ sung ba nội dung mà các công trình đó chưa đề cập đầy đủ: (i) tích hợp mô hình vào một quy trình hỗ trợ kiểm duyệt hoàn chỉnh có luật nghiệp vụ và cơ chế giải thích; (ii) đánh giá chất lượng hiệu chuẩn xác suất – điều kiện cần để dùng PD trong phân vùng quyết định; và (iii) đối chiếu định lượng với quy trình thẩm định truyền thống.

Về điểm khác biệt trong thiết kế thực nghiệm. Phần lớn nghiên cứu về chấm điểm tín dụng đánh giá mô hình bằng cách chia dữ liệu ngẫu nhiên. Đề án sử dụng kiểm định ngoài thời gian, cho kết quả thấp hơn nhưng sát thực tế hơn. Ngoài ra, việc bổ sung hai chỉ tiêu thường bị bỏ qua – độ hiệu chuẩn xác suất và thời gian chấm điểm – cho phép đánh giá khả năng triển khai chứ không chỉ chất lượng thống kê.

3.5.3 Nhận diện hạn chế và định hướng phát triển

3.5.3.1 Hạn chế của kết quả thực nghiệm

Hạn chế về dữ liệu. Đây là hạn chế cơ bản nhất. Dữ liệu mô phỏng được sinh theo một mô hình xác suất do chính đề án thiết kế, nên cấu trúc phụ thuộc giữa các biến phản ánh giả định của người thiết kế chứ không phải quy luật thực tế. Ba hệ quả cụ thể: (i) giá trị tuyệt đối của các chỉ tiêu chất lượng không có ý nghĩa dự báo về hiệu quả trên dữ liệu thực; (ii) quan hệ giữa các đặc trưng thực tế có thể phức tạp hơn nhiều so với mô hình sinh; (iii) dữ liệu thực còn chứa các dạng nhiễu mà mô hình sinh không tái tạo được, như sai sót nhập liệu có hệ thống hay hành vi khai báo thiếu trung thực.

Hạn chế về phạm vi đo lường. Các số đo thời gian được thực hiện trên một máy đơn, một tiến trình, không bao gồm thời gian truyền qua mạng, truy vấn cơ sở dữ liệu nguồn hay ảnh hưởng của tải đồng thời. Chúng có giá trị so sánh tương đối giữa các mô hình nhưng không phải dự báo về thời gian phản hồi trong môi trường sản xuất.

Hạn chế về phạm vi nghiệp vụ. Đề án chỉ mô hình hóa thành phần PD trong phân rã tổn thất kỳ vọng; LGD và EAD không thuộc phạm vi. Ngoài ra, đề án chưa xử lý bài toán *reject inference*: mô hình được huấn luyện trên các hồ sơ đã được cấp tín dụng, trong khi trong thực tế còn một nhóm hồ sơ bị từ chối không có kết quả trả nợ. Bỏ qua nhóm này có thể dẫn tới sai lệch chọn mẫu.

Hạn chế về thời gian quan sát. Đánh giá độ ổn định chỉ dựa trên bốn tháng dữ liệu kiểm thử – quá ngắn so với chu kỳ suy giảm điển hình của mô hình tín dụng. Kết luận về độ ổn định vì vậy mang tính tham khảo.

Hạn chế về kiểm định công bằng. Đề án chưa thực hiện kiểm định công bằng thuật toán (*fairness testing*) – đánh giá xem mô hình có tạo ra chênh lệch có hệ thống giữa

các nhóm khách hàng hay không. Đây là yêu cầu ngày càng được chú trọng đối với mô hình sử dụng trong cấp tín dụng.

3.5.3.2 Định hướng phát triển

Từ các hạn chế trên, đề án xác định năm hướng phát triển tiếp theo:

(1) **Kiểm chứng trên dữ liệu thực.** Áp dụng toàn bộ quy trình đã xây dựng trên dữ liệu ẩn danh của một tổ chức tín dụng để đối chiếu kết quả. Đây là hướng có giá trị cao nhất vì nó trực tiếp giải quyết hạn chế cơ bản nhất.

(2) **Bổ sung xử lý reject inference.** Áp dụng các phương pháp suy luận nhãn cho nhóm hồ sơ bị từ chối để khắc phục sai lệch chọn mẫu.

(3) **Mở rộng sang mô hình** LGD **và** EAD**.** Hoàn thiện khung tính tổn thất kỳ vọng, cho phép định giá theo rủi ro một cách đầy đủ.

(4) **Bổ sung kiểm định công bằng và giám sát liên tục.** Xây dựng bộ chỉ tiêu đánh giá công bằng và cơ chế cảnh báo tự động khi phát hiện suy giảm chất lượng hoặc chênh lệch giữa các nhóm khách hàng.

(5) **Nghiên cứu cơ chế cập nhật mô hình.** Thiết kế quy trình huấn luyện lại định kỳ có kiểm soát, bao gồm tiêu chí kích hoạt, quy trình kiểm định mô hình mới trước khi thay thế và cơ chế quay lui khi phát hiện vấn đề.

Kết luận chương 3

Chương 3 đã trình bày toàn bộ kết quả thực nghiệm của đề án, với năm nhóm kết quả chính.

Về dữ liệu và đặc trưng: tập dữ liệu gồm 60.000 hồ sơ vay với 154 đặc trưng ban đầu, rút gọn còn 116 biến sau ba bộ lọc. Cơ chế kiểm tra chất lượng dữ liệu được kiểm chứng bằng phép tiêm lỗi với tỷ lệ phát hiện 100%; phân tích vintage xác nhận cửa sổ quan sát 12 tháng ghi nhận được 100% tổng số trường hợp vỡ nợ.

Về chất lượng mô hình: 12 mô hình được huấn luyện và so sánh trên cùng điều kiện. Mô hình CatBoost đạt AUC $= 0,8614$, Gini $= 0,7229$ và KS $= 0,5689$, còn cách trần Bayes 0,9109 0,0495 điểm. Sai số hiệu chuẩn kỳ vọng 0,0075 cho phép sử dụng trực tiếp giá trị PD trong phân vùng quyết định.

Về so sánh thuật toán: chênh lệch giữa mô hình tốt nhất và hồi quy logistic chỉ 0,0035 điểm AUC, phù hợp với các công trình đối sánh quốc tế và đặt ra câu hỏi về việc đánh đổi giữa mức cải thiện nhỏ với chi phí mất khả năng giải thích.

Về giải thích mô hình: nhóm đặc trưng hành vi giao dịch đóng góp 34,0% vào quyết định của mô hình, vượt nhóm CIC truyền thống (30,8%).

Về mô phỏng quy trình kiểm duyệt: mô phỏng trên tập kiểm thử cho tỷ lệ xử lý tự động 67,26% với tỷ lệ nợ xấu thực tế tăng đơn điệu qua ba nhóm khuyến nghị (3,43% – 10,93% – 34,45%). So với quy trình thẩm định truyền thống, mô hình giảm tỷ lệ nợ xấu trong nhóm được duyệt từ 6,14% xuống 3,43% (giảm tương đối 44,1%), đổi lại giảm 6,64 điểm phần trăm tỷ lệ duyệt và tăng 5,52 điểm phần trăm khối lượng thẩm định thủ công. Thời gian xử lý một hồ sơ ở phân vị 95% là 74,66 ms, đạt mục tiêu đề ra.

KẾT LUẬN

1. Kết quả nghiên cứu

Đề án đã hoàn thành mục tiêu nghiên cứu, thiết kế và xây dựng thử nghiệm mô hình học máy hỗ trợ kiểm duyệt tín dụng. Các kết quả chính đạt được gồm năm nhóm.

1.1. Về cơ sở lý luận

Đề án đã hệ thống hóa cơ sở lý thuyết về tín dụng, kiểm duyệt tín dụng và đánh giá rủi ro tín dụng, trong đó làm rõ hai nội dung có ý nghĩa định hướng cho toàn bộ thiết kế. Thứ nhất là sự phân biệt giữa *kiểm duyệt* – quá trình đánh giá, sàng lọc hồ sơ – với *phê duyệt* – hành vi ra quyết định của cấp có thẩm quyền; sự phân biệt này xác định vai trò hỗ trợ chứ không thay thế của hệ thống. Thứ hai là việc xác định vị trí của bài toán trong khung lý thuyết rủi ro tín dụng: trong phân rã EL = PD × LGD × EAD, đề án tập trung ước lượng thành phần PD.

Đề án cũng đã phân tích bốn hạn chế mang tính cấu trúc của phương pháp kiểm duyệt truyền thống, ba đặc thù của bài toán tín dụng so với bài toán phân loại thông thường, và trình bày nguyên lý cùng ưu nhược điểm của năm nhóm thuật toán học máy được nghiên cứu.

1.2. Về quy trình xử lý dữ liệu

Đề án đã xây dựng quy trình hoàn chỉnh từ thu thập dữ liệu tới tập đặc trưng sẵn sàng cho mô hình, với ba đóng góp cụ thể:

- **Bộ ràng buộc kiểm tra chất lượng dữ liệu** gồm 15 ràng buộc nghiệp vụ, kèm cơ chế kiểm chứng bằng phép tiêm lỗi nhằm xác nhận bản thân cơ chế kiểm tra hoạt động đúng.
- **Thuật toán tính đặc trưng bảo đảm tính đúng đắn theo thời điểm** bằng kỹ thuật luỹ kế kết hợp ghép gần nhất theo thời gian, đưa chi phí tính toán từ $O(N \times |W| \times \bar{m})$ xuống tuyến tính. Quan trọng hơn chi phí, phương pháp này bảo đảm tính đúng đắn bằng chính cấu trúc thuật toán chứ không phụ thuộc vào kiểm tra bổ sung.

- **Quy trình lựa chọn đặc trưng ba bước** theo năng lực dự báo, mức tương quan và độ ổn định, rút gọn tập đặc trưng từ 154 xuống 116 biến.

1.3. Về mô hình học máy

Đề án đã huấn luyện, hiệu chuẩn và so sánh 12 mô hình trên cùng một điều kiện thực nghiệm. Mô hình được chọn triển khai là CatBoost, đạt AUC = $0,8614$, Gini = $0,7229$, KS = $0,5689$ và sai số hiệu chuẩn kỳ vọng 0,0075.

Ngoài các con số cụ thể, thực nghiệm cho ba kết quả có giá trị nhận thức. Thứ nhất, **khoảng cách giữa các thuật toán là nhỏ**: chênh lệch AUC giữa mô hình được chọn và hồi quy logistic chỉ 0,0035, trong khi hồi quy logistic có ưu thế rõ rệt về khả năng giải thích, chi phí huấn luyện và chất lượng hiệu chuẩn tự nhiên. Thứ hai, **bảng xếp hạng** AUC **có giới hạn độ phân giải**: phép đo dao động khoảng 3×10^{-4} giữa các lần chạy, tức cùng bậc với khoảng cách giữa các mô hình dẫn đầu, nên thứ hạng ở chữ số thập phân thứ tư không phải bằng chứng về sự vượt trội. Đề án vì vậy chọn mô hình triển khai theo tiêu chí biên Pareto – nhanh nhất trong nhóm tương đương về chất lượng – thay vì lấy thẳng mô hình đứng đầu bảng. Thứ ba, **khoảng cách tới trần Bayes cho biết giới hạn của việc cải tiến thuật toán**: mô hình được chọn còn cách trần Bayes 0,9109 khoảng 0,0495 điểm AUC, và phần chênh lệch này bắt nguồn từ việc dữ liệu quan sát được chỉ là phép đo có nhiễu của mức tín nhiệm thật, chứ không phải do thuật toán yếu. Hệ quả thực tiễn là cải thiện đáng kể chỉ đến từ việc bổ sung nguồn dữ liệu mới, không phải từ thuật toán phức tạp hơn.

1.4. Về giá trị của các nguồn dữ liệu

Phân tích SHAP cho thấy nhóm đặc trưng hành vi giao dịch đóng góp 34,0% vào quyết định của mô hình, cao hơn nhóm lịch sử tín dụng CIC (30,8%) vốn được coi là nguồn thông tin truyền thống quan trọng nhất. Đây là căn cứ định lượng cho khuyến nghị khai thác dữ liệu giao dịch trong công tác kiểm duyệt tín dụng: nguồn dữ liệu này do tổ chức tín dụng tự sở hữu, không phát sinh chi phí truy vấn bên ngoài, phản ánh tình trạng tài chính hiện tại và luôn có sẵn kể cả với nhóm khách hàng thiếu lịch sử tín dụng.

1.5. Về quy trình hỗ trợ kiểm duyệt

Đề án đã hiện thực quy trình hoàn chỉnh kết hợp 21 luật nghiệp vụ với mô hình học máy theo logic ưu tiên tám mức, đóng gói thành dịch vụ REST với năm điểm cuối hoạt động đúng. Mô phỏng trên tập kiểm thử cho tỷ lệ nợ xấu thực tế tăng đơn điệu qua ba nhóm khuyến nghị (3,43% – 10,93% – 34,45%), tỷ lệ xử lý tự động 67,26% và thời gian xử lý một hồ sơ ở phân vị 95% là 74,66 ms.

So với quy trình thẩm định truyền thống chỉ dựa trên luật nghiệp vụ, mô hình giảm tỷ lệ nợ xấu trong nhóm hồ sơ được duyệt từ 6,14% xuống 3,43%, tức giảm tương đối 44,1%. Đổi lại, tỷ lệ duyệt giảm 6,64 điểm phần trăm và khối lượng thẩm định thủ công tăng 5,52 điểm phần trăm. Đánh đổi này điều chỉnh được thông qua hai ngưỡng phân vùng, trong khi bộ quy tắc cố định không có cơ chế tương đương.

2. Hạn chế của nghiên cứu

Các hạn chế của kết quả thực nghiệm đã được phân tích chi tiết tại mục 3.5.3. Ở tầm tổng thể, đề án có ba hạn chế cơ bản.

Thứ nhất là hạn chế về dữ liệu. Do đặc thù bảo mật của dữ liệu tín dụng cá nhân, đề án sử dụng dữ liệu mô phỏng sinh theo một mô hình xác suất do chính đề án thiết kế, nên cấu trúc phụ thuộc giữa các biến phản ánh giả định của người thiết kế chứ không phải quy luật thực tế. Giá trị tuyệt đối của các chỉ tiêu chất lượng vì vậy không có ý nghĩa dự báo về hiệu quả trên dữ liệu thực; giá trị của thực nghiệm nằm ở việc so sánh *tương đối* giữa các mô hình trong cùng điều kiện và ở việc kiểm chứng tính đúng đắn của toàn bộ quy trình.

Thứ hai là hạn chế về phương pháp. Đề án chưa xử lý bài toán suy luận nhãn cho hồ sơ bị từ chối (*reject inference*) nên có thể chịu sai lệch chọn mẫu; chưa thực hiện kiểm định công bằng thuật toán; và việc đánh giá độ ổn định chỉ dựa trên bốn tháng dữ liệu kiểm thử, quá ngắn so với chu kỳ suy giảm điển hình của mô hình tín dụng.

Thứ ba là hạn chế về phạm vi. Đề án chỉ mô hình hóa thành phần PD trong phân rã tổn thất kỳ vọng; LGD và EAD không thuộc phạm vi nghiên cứu. Mô hình được xây dựng ở mức nguyên mẫu trong môi trường nghiên cứu, chưa triển khai trên hệ thống nghiệp vụ thực tế của một tổ chức tín dụng, và các số đo thời gian chỉ có giá trị so sánh tương đối giữa các mô hình.

3. Hướng phát triển

Trên cơ sở các hạn chế đã nhận diện, đề án đề xuất năm hướng phát triển tiếp theo, sắp xếp theo mức độ ưu tiên:

(1) **Kiểm chứng trên dữ liệu thực** của một tổ chức tín dụng. Đây là hướng có giá trị cao nhất vì trực tiếp giải quyết hạn chế cơ bản nhất của đề án; mã nguồn đã được thiết kế để chuyển sang dữ liệu thực chỉ bằng cách thay thành phần tiếp nhận dữ liệu.

(2) **Bổ sung xử lý suy luận nhãn cho hồ sơ bị từ chối**, mở rộng phạm vi áp dụng của mô hình tới toàn bộ hồ sơ nộp vào.

(3) **Mở rộng sang mô hình** LGD **và** EAD để hoàn thiện khung tính tổn thất kỳ vọng, cho phép định giá theo rủi ro đầy đủ.

(4) **Bổ sung kiểm định công bằng thuật toán và cơ chế cảnh báo tự động** khi phát hiện suy giảm chất lượng hoặc chênh lệch giữa các nhóm khách hàng.

(5) **Nghiên cứu cơ chế cập nhật mô hình có kiểm soát**, gồm tiêu chí kích hoạt huấn luyện lại, quy trình kiểm định mô hình mới và cơ chế quay lui khi phát hiện vấn đề trong vận hành.

Tóm lại, đề án đã xây dựng được một mô hình học máy hỗ trợ kiểm duyệt tín dụng hoàn chỉnh từ khâu tiếp nhận dữ liệu tới khâu đưa ra khuyến nghị kèm lý giải, đồng thời đánh giá định lượng giá trị mà mô hình mang lại so với quy trình thẩm định truyền thống. Kết quả nghiên cứu cho thấy việc kết hợp mô hình học máy với bộ luật nghiệp vụ, trong đó mô hình đóng vai trò cung cấp thông tin định lượng còn quyết định cuối cùng vẫn thuộc về người có thẩm quyền, là hướng tiếp cận vừa khả thi về kỹ thuật vừa phù hợp với yêu cầu quản trị rủi ro và tuân thủ của hoạt động cấp tín dụng.

DANH MỤC TÀI LIỆU THAM KHẢO

Tài liệu tham khảo tiếng Việt

[1] Ngân hàng Nhà nước Việt Nam (2023), *Thông tư số 15/2023/TT-NHNN quy định về hoạt động thông tin tín dụng của Ngân hàng Nhà nước Việt Nam*, Hà Nội.

[2] Ngân hàng Nhà nước Việt Nam (2021), *Thông tư số 11/2021/TT-NHNN quy định về phân loại tài sản có, mức trích, phương pháp trích lập dự phòng rủi ro và việc sử dụng dự phòng để xử lý rủi ro trong hoạt động của tổ chức tín dụng, chi nhánh ngân hàng nước ngoài*, Hà Nội.

[3] Ngân hàng Nhà nước Việt Nam (2023), *Machine Learning trong quản trị rủi ro tín dụng của ngân hàng*, Tạp chí Ngân hàng.

[4] Huỳnh Thị Ái Thu (2025), *Ứng dụng học máy trong xây dựng mô hình cảnh báo sớm rủi ro tín dụng khách hàng cá nhân tại ngân hàng thương mại Việt Nam*, Luận văn Thạc sĩ, Trường Đại học Kinh tế Thành phố Hồ Chí Minh.

[5] Nguyễn Thị Phương Thảo (2025), *Xây dựng mô hình chấm điểm xếp hạng tín dụng khách hàng doanh nghiệp tại các ngân hàng thương mại ứng dụng các mô hình học máy hiện đại*, Luận văn Thạc sĩ, Trường Đại học Kinh tế Thành phố Hồ Chí Minh.

[6] Nguyễn Minh Sáng, Nguyễn Thị Hồng Vinh (2021), "Lược khảo các nghiên cứu về ứng dụng công nghệ phân tích dữ liệu lớn và trí tuệ nhân tạo trong quản trị rủi ro tín dụng của ngân hàng", *Tạp chí Kinh tế và Ngân hàng châu Á*, số 186.

[7] Nguyễn Thị Hoa, Nguyễn Thị Thu (2025), "Ứng dụng phân tích dữ liệu lớn và trí tuệ nhân tạo trong tối ưu hóa quản trị rủi ro tín dụng tại các ngân hàng số ở Việt Nam", *Tạp chí Khoa học Trường Đại học Mở Hà Nội*, số 2A.

Tài liệu tham khảo tiếng Anh

[8] Lessmann, S., Baesens, B., Seow, H.-V., & Thomas, L. C. (2015), "Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research", *European Journal of Operational Research*, 247(1), pp. 124–136.

[9] Shi, S., Tse, R., Luo, W., D'Addona, S., & Pau, G. (2022), "Machine learning-driven credit risk: A systemic review", *Neural Computing and Applications*, 34, pp. 14327–14339.

[10] Onay, C., & Öztürk, E. (2018), "A review of credit scoring research in the age of Big Data", *Journal of Financial Regulation and Compliance*, 26(3), pp. 382–405.

[11] Ayari, H., Guetari, R., & Kraïem, N. (2026), "Machine learning powered financial credit scoring: A systematic literature review", *Artificial Intelligence Review*, 59, 13.

[12] "Machine Learning for Credit Risk Prediction: A Systematic Literature Review" (2023), *Data*, 8(11), 169.

[13] Cortes, C., & Vapnik, V. (1995), "Support-Vector Networks", *Machine Learning*, 20(3), pp. 273–297.

[14] Vapnik, V. N. (1998), *Statistical Learning Theory*, John Wiley & Sons.

[15] Williams, C. K. I., & Seeger, M. (2001), "Using the Nyström Method to Speed Up Kernel Machines", *Advances in Neural Information Processing Systems*, 13, pp. 682–688.

[16] Platt, J. C. (1999), "Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods", *Advances in Large Margin Classifiers*, MIT Press, pp. 61–74.

[17] Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984), *Classification and Regression Trees*, Wadsworth.

[18] Hastie, T., Tibshirani, R., & Friedman, J. (2009), *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd edition, Springer.

[19] Mitchell, T. M. (1997), *Machine Learning*, McGraw-Hill.

[20] Chen, T., & Guestrin, C. (2016), "XGBoost: A Scalable Tree Boosting System", *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794.

[21] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017), "LightGBM: A Highly Efficient Gradient Boosting Decision Tree", *Advances in Neural Information Processing Systems*, 30, pp. 3146–3154.

[22] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018), "CatBoost: unbiased boosting with categorical features", *Advances in Neural Information Processing Systems*, 31, pp. 6638–6648.

[23] Breiman, L. (2001), "Random Forests", *Machine Learning*, 45(1), pp. 5–32.

[24] Friedman, J. H. (2001), "Greedy function approximation: A gradient boosting machine", *The Annals of Statistics*, 29(5), pp. 1189–1232.

[25] Lundberg, S. M., & Lee, S.-I. (2017), "A Unified Approach to Interpreting Model Predictions", *Advances in Neural Information Processing Systems*, 30, pp. 4765–4774.

[26] Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020), "From local explanations to global understanding with explainable AI for trees", *Nature Machine Intelligence*, 2(1), pp. 56–67.

[27] Zadrozny, B., & Elkan, C. (2002), "Transforming classifier scores into accurate multiclass probability estimates", *Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 694–699.

[28] Niculescu-Mizil, A., & Caruana, R. (2005), "Predicting good probabilities with supervised learning", *Proceedings of the 22nd International Conference on Machine Learning*, pp. 625–632.

[29] Bergstra, J., & Bengio, Y. (2012), "Random Search for Hyper-Parameter Optimization", *Journal of Machine Learning Research*, 13, pp. 281–305.

[30] Siddiqi, N. (2017), *Intelligent Credit Scoring: Building and Implementing Better Credit Risk Scorecards*, 2nd edition, John Wiley & Sons.

[31] Thomas, L. C., Crook, J., & Edelman, D. (2017), *Credit Scoring and Its Applications*, 2nd edition, Society for Industrial and Applied Mathematics.

[32] Baesens, B., Roesch, D., & Scheule, H. (2016), *Credit Risk Analytics: Measurement Techniques, Applications, and Examples in SAS*, John Wiley & Sons.

[33] Basel Committee on Banking Supervision (2006), *International Convergence of Capital Measurement and Capital Standards: A Revised Framework*, Bank for International Settlements.

[34] Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015), "Hidden Technical Debt in Machine Learning Systems", *Advances in Neural Information Processing Systems*, 28, pp. 2503–2511.

[35] Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014), "A survey on concept drift adaptation", *ACM Computing Surveys*, 46(4), pp. 1–37.

[36] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002), "SMOTE: Synthetic Minority Over-sampling Technique", *Journal of Artificial Intelligence Research*, 16, pp. 321–357.

[37] Elkan, C. (2001), "The Foundations of Cost-Sensitive Learning", *Proceedings of the 17th International Joint Conference on Artificial Intelligence*, pp. 973–978.

PHỤ LỤC A

CẤU TRÚC MÃ NGUỒN VÀ HƯỚNG DẪN TÁI LẬP KẾT QUẢ

A.1 Tổ chức mã nguồn

Toàn bộ quy trình được hiện thực bằng Python và tổ chức thành một gói phần mềm có cấu trúc phản ánh đúng mạch nội dung nghiên cứu của đề án. Mỗi gói con tương ứng một mục của Chương 2, nhờ đó người đọc có thể đối chiếu trực tiếp giữa phần trình bày phương pháp và phần hiện thực.

```
config/config.yaml            Cấu hình tập trung toàn bộ quy trình
src/creditreview/
  config.py                   Nạp và truy cập cấu hình
  data/                       2.2 Thu thập và tổng hợp dữ liệu
    generator.py            Sinh dữ liệu mô phỏng (biến tiềm ẩn)
    reference.py            Bảng tham chiếu nghiệp vụ
    profiling.py            Thống kê mô tả, kiểm tra hợp lệ, tiêm lỗi
  preprocessing/              2.3 Tiền xử lý và làm sạch dữ liệu
    cleaning.py               Xử lý giá trị khuyết thiếu và ngoại lệ
    encoding.py               Chuẩn hóa và mã hóa biến
    splitting.py              Phân chia tập dữ liệu
  features/                   2.4 Trích xuất và lựa chọn đặc trưng
    definitions.py            Đăng ký đặc trưng theo nhóm nguồn dữ liệu
    extraction.py             Trích xuất đặc trưng đúng theo thời điểm
    selection.py              Lựa chọn tập đặc trưng qua ba bộ lọc
  labeling/                   2.5 Xây dựng nhãn và quy tắc phê duyệt
    target.py                 Gán nhãn rủi ro, phân tích vintage
    cutoff.py                 Xác định điểm cắt phê duyệt
  models/                     2.6, 2.7 Thiết kế và huấn luyện mô hình
    zoo.py                    Nhà máy mô hình (12 mô hình)
    train.py                  Huấn luyện, hiệu chuẩn, đánh giá
```

```
    tuning.py              Tinh chỉnh siêu tham số
    metrics.py             Bộ chỉ tiêu đánh giá
    woe.py                 Biến đổi WOE và thẻ điểm
    explain.py             Giải thích mô hình (SHAP, phép hoán vị)
    plots.py               Sinh đồ thị
  decision/                Bộ máy hỗ trợ ra quyết định
    rules.py               Bộ luật nghiệp vụ
    policy.py              Chính sách hạn mức và định giá
    engine.py              Tổng hợp khuyến nghị theo thứ tự ưu tiên
  serving/                 Dịch vụ REST
    api.py                 Các điểm cuối nghiệp vụ và vận hành
    repository.py          Kho đặc trưng phục vụ tra cứu
  monitoring/
    drift.py               Giám sát PSI và chất lượng theo thời gian
  dashboard/
    app.py                 Giao diện trực quan hóa kết quả
scripts/                   Bảy bước tái lập kết quả
results/                   Mô hình, bảng và đồ thị kết quả
thesis/                    Mã nguồn LaTeX của đề án
```

A.2 Hướng dẫn tái lập kết quả

A.2.1 Cài đặt môi trường

```
pip install -r requirements.txt
```

Yêu cầu Python phiên bản 3.10 trở lên.

A.2.2 Chạy toàn bộ quy trình

Cách nhanh nhất là chạy toàn bộ bằng một lệnh:

```
python scripts/run_all.py
```

Hoặc chạy tuần tự từng bước để theo dõi kết quả trung gian:

```
# Bước 1 - Chuẩn bị dữ liệu: sinh, kiểm tra chất lượng,
```

```
#          gán nhãn, phân chia tập
python scripts/01_prepare_data.py

# Bước 2 - Phân tích Information Value và lựa chọn đặc trưng
python scripts/02_build_features.py

# Bước 3 - Tinh chỉnh siêu tham số (tùy chọn)
python scripts/03_tune_hyperparams.py --trials 14

# Bước 4 - Huấn luyện và so sánh 12 mô hình
python scripts/04_train_models.py

# Bước 5 - Mô phỏng quy trình kiểm duyệt và đánh giá chung
python scripts/05_simulate_evaluate.py

# Bước 6 - Xuất bảng LaTeX cho đề án
python scripts/06_export_latex_tables.py

# Bước 7 - Xuất từ điển dữ liệu các bảng đầu vào (Excel, tùy chọn)
python scripts/07_export_data_dictionary.py
```

Hạt giống ngẫu nhiên được cố định trong `config/config.yaml` (`project.seed`), bảo đảm kết quả lặp lại được giữa các lần chạy.

A.2.3 Chạy nhanh để kiểm tra

Để kiểm tra quy trình hoạt động mà không mất nhiều thời gian:

```
python scripts/01_prepare_data.py --n-customers 3000 \
    --n-applications 4500
python scripts/02_build_features.py
python scripts/04_train_models.py --no-stacking --no-shap \
    --models logistic_regression lightgbm
python scripts/05_simulate_evaluate.py --n-applications 1000 --no-api
```

A.2.4 Khởi động dịch vụ và giao diện

```
# Dịch vụ REST hỗ trợ kiểm duyệt
uvicorn creditreview.serving.api:app --port 8000
#   Tài liệu API tự sinh: http://localhost:8000/docs

# Giao diện trực quan hóa kết quả
streamlit run src/creditreview/dashboard/app.py
```

A.2.5 Biên dịch đề án

```
cd thesis
xelatex main.tex && xelatex main.tex
```

Cần dùng XeLaTeX do tài liệu sử dụng tiếng Việt và phông Times New Roman. Chạy hai lần để cập nhật mục lục và tham chiếu chéo.

Số liệu trong đề án được sinh tự động từ kết quả thực nghiệm qua `scripts/06_export_latex_tables.py`: chạy lại thực nghiệm là toàn bộ bảng biểu và các con số trích dẫn trong phần diễn giải tự cập nhật, không phải sửa tay.

PHỤ LỤC B

DANH MỤC LUẬT NGHIỆP VỤ

Bảng dưới đây liệt kê đầy đủ bộ luật nghiệp vụ được cài đặt trong mô hình. Ba mức hành động gồm: `HARD_REJECT` – từ chối, có quyền phủ quyết cao nhất; `REVIEW` – buộc chuyển thẩm định thủ công; `WARNING` – ghi nhận vào danh sách lý do nhưng không thay đổi khuyến nghị.

Bảng B.1: Danh mục đầy đủ luật nghiệp vụ được cài đặt trong mô hình

Mã luật	Tên luật	Nhóm	Hành động	Diễn giải
R001	Tuổi nằm ngoài khoảng cho phép [20; 62]	Điều kiện cơ bản	HARD_ REJECT	Khách hàng phải trong độ tuổi từ 20 đến 62 tại thời điểm đề nghị vay
R002	Thu nhập dưới mức tối thiểu 6 triệu VND	Điều kiện cơ bản	HARD_ REJECT	Thu nhập hàng tháng không đạt mức tối thiểu của sản phẩm
R003	Thâm niên công việc dưới 6 tháng	Điều kiện cơ bản	REVIEW	Thâm niên công việc chưa đủ để đánh giá tính ổn định của thu nhập
R101	Nhóm nợ xấu nhất 12 tháng vượt nhóm 2	Lịch sử tín dụng	HARD_ REJECT	Khách hàng phát sinh nợ xấu trong 12 tháng gần nhất
R102	Đang có nợ nhóm 3 trở lên	Lịch sử tín dụng	HARD_ REJECT	Khách hàng đang có khoản nợ được phân loại từ nhóm 3 (nợ dưới tiêu chuẩn)
R103	Có nợ đã xử lý rủi ro / xóa nợ	Lịch sử tín dụng	HARD_ REJECT	Lịch sử có khoản nợ đã được xử lý rủi ro hoặc xóa nợ
R104	Số ngày quá hạn tối đa 12 tháng vượt 30 ngày	Lịch sử tín dụng	REVIEW	Từng chậm trả vượt ngưỡng cho phép trong 12 tháng gần nhất

(xem tiếp trang sau)

(tiếp theo trang trước)

Mã luật	Tên luật	Nhóm	Hành động	Diễn giải
R105	Quan hệ tín dụng với hơn 6 tổ chức	Lịch sử tín dụng	REVIEW	Số lượng tổ chức tín dụng đang có quan hệ ở mức cao, tiềm ẩn rủi ro vay đảo nợ
R106	Truy vấn tín dụng 3 tháng vượt 5 lần	Lịch sử tín dụng	WARNING	Khách hàng tìm kiếm tín dụng dồn dập tại nhiều tổ chức
R107	Tỷ lệ sử dụng hạn mức trên 95%	Lịch sử tín dụng	WARNING	Hạn mức tín dụng hiện có đã được sử dụng gần hết
R201	Tỷ lệ nợ trên thu nhập (DTI) vượt 60%	Khả năng trả nợ	HARD_ REJECT	Tổng nghĩa vụ trả nợ vượt quá khả năng chi trả từ thu nhập
R202	Thu nhập còn lại sau trả nợ không đủ chi phí sinh hoạt	Khả năng trả nợ	HARD_ REJECT	Sau khi trừ nghĩa vụ trả nợ và chi phí sinh hoạt tối thiểu, thu nhập còn lại âm
R203	Tỷ lệ trả góp trên thu nhập (PTI) vượt 45%	Khả năng trả nợ	REVIEW	Riêng khoản vay mới đã chiếm tỷ trọng lớn trong thu nhập
R204	Số tiền vay vượt 60 lần thu nhập hàng tháng	Khả năng trả nợ	REVIEW	Quy mô khoản vay rất lớn so với thu nhập, cần thẩm định bổ sung
R301	Tỷ lệ vay trên giá trị TSBĐ (LTV) vượt 85%	Tài sản bảo đảm	REVIEW	Giá trị tài sản bảo đảm không đủ tỷ lệ bao phủ yêu cầu
R401	Không lấy được dữ liệu CIC	Chất lượng dữ liệu	REVIEW	Hệ thống CIC không phản hồi - chuyển thẩm định thủ công theo quy trình dự phòng
R402	Khách hàng thiếu lịch sử tín dụng (thin-file)	Chất lượng dữ liệu	WARNING	Không có/ít lịch sử tín dụng; đánh giá dựa chủ yếu vào dữ liệu hành vi giao dịch

(xem tiếp trang sau)

(tiếp theo trang trước)

Mã luật	Tên luật	Nhóm	Hành động	Diễn giải
R403	Thiếu dữ liệu hành vi giao dịch	Chất lượng dữ liệu	REVIEW	Số giao dịch trong 180 ngày quá ít để tính đặc trưng hành vi đáng tin cậy
R501	Dòng tiền vào thực tế thấp hơn nhiều so với thu nhập khai báo	Dấu hiệu bất thường	REVIEW	Khách hàng nhận lương qua tài khoản nhưng dòng tiền vào 30 ngày dưới 35% thu nhập khai báo - cần xác minh thu nhập
R502	Tỷ trọng chi tiêu nhóm rủi ro cao bất thường	Dấu hiệu bất thường	REVIEW	Trên 15% dòng tiền ra thuộc nhóm giao dịch rủi ro cao
R503	Không phát sinh giao dịch trong 60 ngày gần nhất	Dấu hiệu bất thường	WARNING	Tài khoản không hoạt động trong thời gian dài trước khi đề nghị vay

PHỤ LỤC C

DANH MỤC ĐẶC TRƯNG

Danh mục đầy đủ các đặc trưng được sử dụng, phân theo nhóm nguồn dữ liệu. Cột "Nguồn dữ liệu" cho biết đặc trưng được tính từ bảng dữ liệu nào.

Bảng C.1: Danh mục đặc trưng đầu vào của mô hình

Tên đặc trưng	Nhóm	Nguồn dữ liệu	Kiểu	Mô tả
age	Thông tin cá nhân	HỒ SƠ KH	num	Tuổi khách hàng
gender	Thông tin cá nhân	HỒ SƠ KH	cat	Giới tính
marital_status	Thông tin cá nhân	HỒ SƠ KH	cat	Tình trạng hôn nhân
num_dependents	Thông tin cá nhân	HỒ SƠ KH	num	Số người phụ thuộc
education_code	Thông tin cá nhân	HỒ SƠ KH	num	Trình độ học vấn (1-5)
occupation	Thông tin cá nhân	HỒ SƠ KH	cat	Nghề nghiệp
employer_type	Thông tin cá nhân	HỒ SƠ KH	cat	Loại hình tổ chức làm việc
job_tenure_months	Thông tin cá nhân	HỒ SƠ KH	num	Thâm niên công việc (tháng)
monthly_income	Thông tin cá nhân	HỒ SƠ KH	num	Thu nhập khai báo hàng tháng
province	Thông tin cá nhân	HỒ SƠ KH	cat	Tỉnh/thành cư trú
residence_type	Thông tin cá nhân	HỒ SƠ KH	cat	Hình thức nhà ở

(xem tiếp trang sau)

(tiếp theo trang trước)

Tên đặc trưng	Nhóm	Nguồn dữ liệu	Kiểu	Mô tả
customer_since_months	Thông tin cá nhân	HỒ SƠ KH	num	Thời gian quan hệ với ngân hàng
has_salary_account	Thông tin cá nhân	HỒ SƠ KH	bin	Có tài khoản nhận lương
n_accounts	Thông tin cá nhân	HỒ SƠ KH	num	Số tài khoản đang mở
total_avg_balance	Thông tin cá nhân	HỒ SƠ KH	num	Tổng số dư bình quân 3 tháng
product_code	Tham số khoản vay	ĐƠN VAY	cat	Mã sản phẩm tín dụng
requested_amount	Tham số khoản vay	ĐƠN VAY	num	Số tiền đề nghị vay
tenor_months	Tham số khoản vay	ĐƠN VAY	num	Kỳ hạn vay (tháng)
interest_rate	Tham số khoản vay	ĐƠN VAY	num	Lãi suất áp dụng (năm)
loan_purpose	Tham số khoản vay	ĐƠN VAY	cat	Mục đích vay
channel	Tham số khoản vay	ĐƠN VAY	cat	Kênh tiếp nhận hồ sơ
has_collateral	Tham số khoản vay	ĐƠN VAY	bin	Có tài sản bảo đảm
monthly_installment	Tham số khoản vay	ĐƠN VAY	num	Khoản trả góp hàng tháng
ltv	Tham số khoản vay	ĐƠN VAY	num	Tỷ lệ vay trên giá trị TSBĐ
apply_hour	Tham số khoản vay	ĐƠN VAY	num	Giờ nộp hồ sơ
apply_dayofweek	Tham số khoản vay	ĐƠN VAY	num	Ngày trong tuần nộp hồ sơ

(xem tiếp trang sau)

(tiếp theo trang trước)

Tên đặc trưng	Nhóm	Nguồn dữ liệu	Kiểu	Mô tả
cic_score	Lịch sử tín dụng (CIC)	BẢN TIN CIC	num	Điểm tín dụng CIC (300-850)
current_group	Lịch sử tín dụng (CIC)	BẢN TIN CIC	num	Nhóm nợ hiện tại (1-5)
worst_group_12m	Lịch sử tín dụng (CIC)	BẢN TIN CIC	num	Nhóm nợ xấu nhất 12 tháng
dpd_max_12m	Lịch sử tín dụng (CIC)	BẢN TIN CIC	num	Số ngày quá hạn tối đa 12 tháng
num_institutions	Lịch sử tín dụng (CIC)	BẢN TIN CIC	num	Số TCTD đang có quan hệ
num_active_contracts	Lịch sử tín dụng (CIC)	BẢN TIN CIC	num	Số hợp đồng còn hiệu lực
num_closed_contracts	Lịch sử tín dụng (CIC)	BẢN TIN CIC	num	Số hợp đồng đã tất toán
total_outstanding	Lịch sử tín dụng (CIC)	BẢN TIN CIC	num	Tổng dư nợ tại các TCTD
credit_utilization	Lịch sử tín dụng (CIC)	BẢN TIN CIC	num	Tỷ lệ sử dụng hạn mức
monthly_debt_payment	Lịch sử tín dụng (CIC)	BẢN TIN CIC	num	Nghĩa vụ trả nợ hàng tháng hiện hữu
num_inquiries_3m	Lịch sử tín dụng (CIC)	BẢN TIN CIC	num	Số lần truy vấn tín dụng 3 tháng
has_written_off_debt	Lịch sử tín dụng (CIC)	BẢN TIN CIC	bin	Có nợ đã xử lý rủi ro
oldest_account_months	Lịch sử tín dụng (CIC)	BẢN TIN CIC	num	Độ dài lịch sử tín dụng (tháng)
num_bad_debt_institutions	Lịch sử tín dụng (CIC)	BẢN TIN CIC	num	Số TCTD từng phát sinh nợ xấu
is_thin_file	Lịch sử tín dụng (CIC)	BẢN TIN CIC	bin	Khách hàng thiếu lịch sử tín dụng

(xem tiếp trang sau)

(tiếp theo trang trước)

Tên đặc trưng	Nhóm	Nguồn dữ liệu	Kiểu	Mô tả
cic_missing	Lịch sử tín dụng (CIC)	BẢN TIN CIC	bin	Không lấy được dữ liệu CIC
txn_cnt_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Số giao dịch trong cửa sổ W ngày
inflow_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Tổng dòng tiền vào trong cửa sổ W ngày
outflow_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Tổng dòng tiền ra trong cửa sổ W ngày
net_flow_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Dòng tiền thuần trong cửa sổ W ngày
avg_txn_amt_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Giá trị giao dịch trung bình trong cửa sổ W ngày
txn_amt_std_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Độ lệch chuẩn giá trị giao dịch trong cửa sổ W ngày
salary_cnt_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Số lần nhận lương trong cửa sổ W ngày
salary_amt_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Tổng lương nhận trong cửa sổ W ngày
repay_amt_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Tổng tiền trả nợ trong cửa sổ W ngày
risky_amt_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Chi tiêu nhóm rủi ro trong cửa sổ W ngày
cash_wd_cnt_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Số lần rút tiền mặt trong cửa sổ W ngày
cash_wd_amt_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Giá trị rút tiền mặt trong cửa sổ W ngày
ecom_amt_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Chi tiêu thương mại điện tử trong cửa sổ W ngày
utility_amt_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Chi tiêu hóa đơn tiện ích trong cửa sổ W ngày

(xem tiếp trang sau)

(tiếp theo trang trước)

Tên đặc trưng	Nhóm	Nguồn dữ liệu	Kiểu	Mô tả
night_txn_cnt_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Số giao dịch ban đêm (0h-5h) trong cửa sổ W ngày
large_txn_cnt_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Số giao dịch giá trị lớn (>50 triệu) trong cửa sổ W ngày
mobile_txn_cnt_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Số giao dịch qua mobile banking trong cửa sổ W ngày
outflow_ratio_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Tỷ lệ dòng tiền ra trên dòng tiền vào trong cửa sổ W ngày
risky_ratio_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Tỷ trọng chi tiêu rủi ro trong cửa sổ W ngày
cash_ratio_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Tỷ trọng rút tiền mặt trong cửa sổ W ngày
night_ratio_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Tỷ trọng giao dịch ban đêm trong cửa sổ W ngày
repay_burden_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Gánh nặng trả nợ trên dòng tiền vào trong cửa sổ W ngày
txn_amt_cv_{W}d	Hành vi giao dịch	GIAO DỊCH	num	Hệ số biến thiên giá trị giao dịch trong cửa sổ W ngày
days_since_last_txn	Hành vi giao dịch	GIAO DỊCH	num	Số ngày từ giao dịch gần nhất
txn_cnt_trend_30_90	Hành vi giao dịch	GIAO DỊCH	num	Xu thế số giao dịch: 30 ngày so với mức trung bình 90 ngày
inflow_trend_30_90	Hành vi giao dịch	GIAO DỊCH	num	Xu thế dòng tiền vào: 30 ngày so với mức trung bình 90 ngày
inflow_trend_90_180	Hành vi giao dịch	GIAO DỊCH	num	Xu thế dòng tiền vào: 90 ngày so với mức trung bình 180 ngày
income_verification_ratio	Hành vi giao dịch	GIAO DỊCH	num	Tỷ lệ dòng tiền vào thực tế so với thu nhập khai báo

(xem tiếp trang sau)

(tiếp theo trang trước)

Tên đặc trưng	Nhóm	Nguồn dữ liệu	Kiểu	Mô tả
salary_regularity	Hành vi giao dịch	GIAO DỊCH	num	Mức độ đều đặn của việc nhận lương trong 180 ngày
income_stability	Hành vi giao dịch	GIAO DỊCH	num	Độ ổn định thu nhập (1 - hệ số biến thiên dòng tiền vào theo tháng)
dti	Biến tổ hợp	TÍNH TOÁN	num	Debt-to-Income: (trả góp mới + nghĩa vụ hiện hữu) / thu nhập
pti	Biến tổ hợp	TÍNH TOÁN	num	Payment-to-Income: trả góp khoản vay mới / thu nhập
amount_to_income	Biến tổ hợp	TÍNH TOÁN	num	Số tiền vay / thu nhập hàng tháng
outstanding_to_ income	Biến tổ hợp	TÍNH TOÁN	num	Tổng dư nợ hiện hữu / thu nhập hàng tháng
disposable_income	Biến tổ hợp	TÍNH TOÁN	num	Thu nhập còn lại sau trả nợ và chi phí sinh hoạt tối thiểu
disposable_ratio	Biến tổ hợp	TÍNH TOÁN	num	Tỷ lệ thu nhập còn lại trên thu nhập
income_per_ dependent	Biến tổ hợp	TÍNH TOÁN	num	Thu nhập bình quân đầu người trong hộ
credit_history_ratio	Biến tổ hợp	TÍNH TOÁN	num	Độ dài lịch sử tín dụng so với tuổi trưởng thành
debt_per_institution	Biến tổ hợp	TÍNH TOÁN	num	Dư nợ bình quân trên mỗi tổ chức tín dụng
dpd_x_institutions	Biến tổ hợp	TÍNH TOÁN	num	Tương tác giữa số ngày quá hạn và số TCTD
high_dti_short_tenure	Biến tổ hợp	TÍNH TOÁN	bin	Cờ rủi ro: DTI > 0,5 và thâm niên công việc < 12 tháng
balance_to_ installment	Biến tổ hợp	TÍNH TOÁN	num	Số dư bình quân / khoản trả góp hàng tháng

(xem tiếp trang sau)

(tiếp theo trang trước)

Tên đặc trưng	Nhóm	Nguồn dữ liệu	Kiểu	Mô tả
inflow_to_installment	Biến tổ hợp	TÍNH TOÁN	num	Dòng tiền vào 30 ngày / khoản trả góp hàng tháng

Kiểu dữ liệu: num – định lượng; cat – định tính; bin – nhị phân. Mỗi đặc trưng có hậu tố `_{W}d` *được tính trên 4 cửa sổ thời gian* $W \in \{7, 30, 90, 180\}$ *ngày; 23 dòng dạng này tương ứng 92 đặc trưng, đưa tổng số đặc trưng lên 154.*